Méthodologie

Vue d'ensemble du Pipeline

- Étape 1 : Définition des Contraintes Cliniques
- Étape 2 : Construction du Prompting Structuré
- Étape 3 : Processus de Génération par LLM
- Étape 4 : Validation Automatique (Matching Relaxed)
- Étape 5 : Évaluation Multi-Dimensionnelle
- Étape 6 : Évaluation par un LLM
- Étape 7 : Évaluation par des experts

Étape 1 : Définition des Contraintes Cliniques

Le but étant de générer des combinaisons réalistes de champs cliniques pour conditionner la génération

Variables Contrôlées (8 champs)

A. Champs Identité (4)

J'ai utilisé la bibliothèque *Faker*, qui dispose déjà d'une base de données intégrée et génère aléatoirement des noms, prénoms et dates de naissance.

Champ	Type	Méthode	Exemple
civilite	Catégorique		"Madame", "Monsieur"
nom	Texte	Faker.last_name()	"MARTINEZ", "DUPONT"
prenom	Texte	Faker.first_name()	"Amélie", "Sophie"
birth_date	Date	Faker.date_of_birth(40-80 ans)	"22/05/1960"

Justification âge : Cancer du sein majoritairement 50-70 ans, étendu 40-80 pour réalisme

B. Champs Cliniques (4)

Pour chaque champ, une valeur est choisie aléatoirement parmi un ensemble de possibilités (values).

1. Side (Latéralité)

Side values	variantes
sein droit	"droit", "hémithorax droit", "côté droit"
sein gauche	"gauche", "hémithorax gauche", "côté gauche"

- Distribution : 50% / 50%
- Justification : Pas de latéralité préférentielle dans cancer sein

2. Subtype (Sous-type moléculaire)

Subtype values	variantes
RH+/HER2-	"rh+/her2-", "rh+ her2-", "rh + her2-" , "récepteurs hormonaux positifs", "her2 négatif"
RH+/HER2+	"rh+/her2+", "rh+ her2+", "rh + her2 +", "récepteurs hormonaux positifs", "her2 positif"
RH-/HER2+	"rh-/her2+", "rh- her2+", "rh - her2 +", "récepteurs hormonaux négatifs", "her2 positif", "HER2+", "her2 enrichi", "her2 amplifié", "récepteurs hormonaux RH-"
triple négatif	"triple négatif", "triple-négatif", "tn", "rh-/her2-", "basal-like", "récepteurs hormonaux négatifs", "her2 négatif"

3. Stage (Classification TNM)

```
STAGE_VALUES = [
    "cT1N0M0",  # Stade I (précoce)
    "cT2N0M0",  # Stade IIA
    "cT2N1M0",  # Stade IIB
    "cT3N0M0"   # Stade IIIA
]
```

- Notation : c = clinique, T = tumeur, N = ganglions, M = métastases

4. Context (Contexte thérapeutique)

Context values	variantes
adjuvant	"adjuvant", "adjuvante", "post-opératoire", "post opératoire", "après chirurgie", "après intervention", "complément", "complémentaire",
néoadjuvant	"néoadjuvant", "néo-adjuvant", "néo adjuvant", "pré-opératoire", "pré opératoire", "préopératoire", "avant chirurgie", "avant intervention", "induction", "première ligne"
Récidive locale	"récidive", "récurrence", "rechute", "locale", "locorégionale", "locorégional", "reprise évolutive", "progression locale"
palliatif	"palliatif", "palliative", "métastatique", "stade iv", "stade 4", "avancé", "généralisé", "soins de confort"

- Adjuvant = contexte le plus fréquent en RT sein

Exemple de Sortie


```
{
  "seed": 1000,
  "civilite": "Madame",
  "nom": "MARTINEZ",
  "prenom": "Amélie",
  "birth_date": "22/05/1960",
  "side": "sein droit",
  "subtype": "RH+/HER2-",
  "stage": "cT3N0M0",
  "context": "néoadjuvant"
}
```

Étape 2 : Construction du Prompting Structuré

Prompt Complet
[System]
Rôle + Contraintes de sortie
[User]
Partie 1 : Instruction principale - Conditionnement sur 8 champs
Partie 2 : Liste 15 éléments obligatoires - Spécification exhaustive
Partie 3 : Consignes mention explicite - Forcing des champs conditionnés
Partie 4 : Few-shot examples (5 CR réels) - Exemple 1 - Exemple 2 - Exemple 3 - Exemple 4 - Exemple 5
Partie 5 : Instruction finale - "Rédigez maintenant le compte rendu complet"

Étape 3 : Processus de Génération par LLM

1. **Modèle** : Mistral-7B-Instruct-v0.2

Spécifications Techniques

Caractéristique	Valeur
Architecture	Transformer decoder-only
Nombre paramètres	7.3 milliards
Context window	32,768 tokens (environs 100 pages)
Vocabulaire	32,000 tokens (byte-pair encoding)
Layers	32
Hidden size	4096
Attention heads	32
FFN dimension	14,336
Instruction-tuned	Oui (format chat)
Langues	Multilingue (excellent français)

Justification du Choix

Avantages	Limitations
• Excellent français • Open-source et reproductible • Rapidité inférence (7B vs 70B)	• Hallucinations factuelles possibles (comme tous LLM 7B) • Pas spécialisé radiothérapie (pas de fine-tuning) • Peut répéter patterns des exemples

2. Paramètres de génération

```
GENERATION_CONFIG = {
    # Sampling parameters
    "temperature": 0.4,          # Créativité modérée
    "top_p": 0.9,                # Nucleus sampling

    # Length control
    "max_new_tokens": 1600,

    # Quality control
    "do_sample": True,           # Stochastic vs greedy
    "repetition_penalty": 1.1,   # Pénalise répétitions

    # Reproducibility
    "seed": seed                 # Fixé (1000-1029)
}
```

3. Paramètres techniques

Configuration Matérielle Utilisée :

```
GPU      : 2× NVIDIA Quadro P6000 (24 GB VRAM chacun, 48 GB total)
           - Architecture Pascal (GP102)
           - 3,840 CUDA cores par GPU
           - Utilisation observée : 26%
           - VRAM utilisée : 3.8 GB / 24 GB (16%)
CPU      : Intel (multi-core)
RAM      : 64+ GB (estimé)
Storage  : SSD (probablement NVMe)
OS       : Linux (Ubuntu 20.04 ou 22.04)
Hostname : decore2
```

Logiciels :

```
Python          : 3.10+
PyTorch         : 2.0+ (compatible CUDA 12.1)
Transformers    : 4.35+
CUDA            : 12.1
Driver NVIDIA   : 530.30.02
Environment     : synthgen (conda)
```

Étape 4 : Validation Automatique (Matching Relaxed)

Le but étant de vérifier la présence des 8 champs conditionnés dans le texte généré avec tolérance sémantique (qlq variantes)

Stratégie Hybride : Exact + Relaxed

Matching Strategy (Hybrid)

EXACT MATCHING
(4 champs identité)

- Civilité
- Nom
- Prénom
- Birth_date

MÉTHODE :
– String match exact

RELAXED MATCHING
(4 champs cliniques)

- Side
- Subtype
- Stage
- context

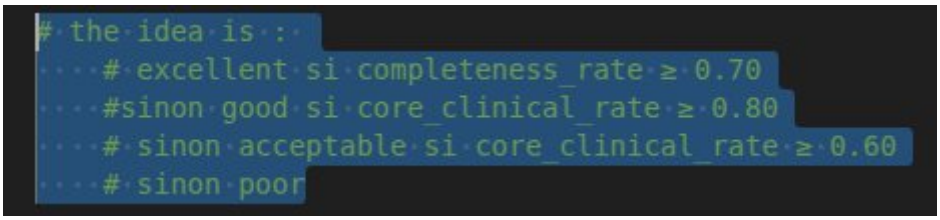
MÉTHODE :
- Variantes sémantiques
- Regex patterns

Comparaison Exact vs Relaxed (sur 30 CR) :

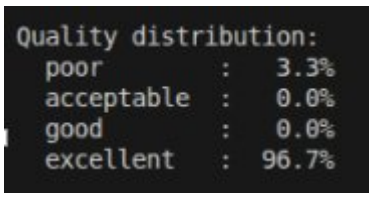
Champ	Exact	Relaxed	Gain	Objectif
civilite	100% (Exact)	100% (Exact)		
nom	100% (Exact)	100% (Exact)		
prenom	100% (Exact)	100% (Exact)		
birth_date	100% (Exact)	100% (Exact)		
side	100% (exact)	100% (relaxed)	+0%	
subtype	90% (exact)	93.3% (relaxed)	+3.3%	
stage	96.7% (exact)	96.7%(relaxed)	+0%	
context	73.3% (relaxed)	73.3% (relaxed)		
Core Clinical	92%	92.7%	+0.7%	≥ 80%
Completeness	95%	95.4%	+0.4%	≥ 70%

Conformité (3 métriques)

- core_clinical_rate : Taux 5 champs critiques = (side + subtype + stage + context + nom) / 5
- completeness_rate : Taux 8 champs totaux = nb_champs_ok / 8
- quality_tier : {excellent, good, acceptable,poor}



```
# the idea is :
    # excellent si completeness_rate ≥ 0.70
    #sinon good si core_clinical_rate ≥ 0.80
    # sinon acceptable si core_clinical_rate ≥ 0.60
    # sinon poor
```



```
Quality distribution:
  poor        :   3.3%
  acceptable  :   0.0%
  good        :   0.0%
  excellent   :  96.7%
```

Étape 5 : Évaluation Multi-Dimensionnelle

- Input: Texte CR + Métadonnées conformité
- Output: JSON métriques agrégées + individuelles

5 catégories de métriques + conformité (above)
Richesse Lexicale (4 métriques) • **TTR** : type-Token ratio : nb_mots_uniques / nb_mots_totaux • **MSTTR-100** : Mean Segmental TTR (fenêtre 100) : TTR moyenné sur des fenêtres de 100 mots (Plus robuste que TTR pour textes longs) • **entropie** : Entropie Shannon (bits) : capture la distribution du vocabulaire (voir formule dans le code) , Plus élevé = vocabulaire plus varié • **hapax_ratio** : Proportion mots n'apparaissant qu'une seule fois, Ratio élevé = vocabulaire diversifié
Métriques Lexicales (7 métriques) densité_terminologie : Densité termes médicaux unique_medical_terms : Nb termes uniques medical_diversity : Diversité vocabulaire structure_completeness : Présence 6 sections structure_completeness, has_dose_total/per_frac/nb : Mentions doses medical_quality_score : Score global
Diversity (3 métriques) • **self_bleu_2** : Self-BLEU 2-grammes : Mesure si le modèle génère des textes variés ou répétitifs. • **self_bleu_3** : Self-BLEU 3-grammes • **self_bleu_4** : Self-BLEU 4-grammes • Si tous les textes générés se ressemblent beaucoup → faible diversité → Self-BLEU élevé • Si les textes sont différents → bonne diversité → Self-BLEU faible
Fluence (3 métriques) **perplexity** : Perplexity estimation based on token entropy (PPL = 2^H) , it's not a linguistic perplexity, it is just an approximation based on lexical diversity. Plus bas = texte plus fluide/naturel • **slor** : fluence syntaxique normalisée (voir formule sur le code) , Plus élevé = meilleure fluence syntaxique • **flesch_reading_ease_fr** :Score de difficulté de lecture (voir formule dans le code)
Statistiques (5 métriques) • word_count • char_count • sentence_count • avg_sentence_length • long_word_ratio : Proportion mots >6 caractères

Agrégation: mean, std, min, max pour chaque métrique

Résultats :

Métrique	Résultat	Objectif	Interprétation
Mean TTR	0.5035	≥ 0.4	Excellent : vocabulaire très riche : 50% de mots uniques
Mean MSTR-100	0.6628	≥ 0.4	Excellent : richesse lexicale maintenue sur la longueur du texte, vocabulaire constamment renouvelé
Lexical entropy	7.0180	5-10 pour textes bien écrits	Bon : imprévisibilité du vocabulaire, ce qui indique une distribution variée des motssans répétitions excessives

Hapax ratio (complémentaire au TTR)	0.3738	0.40-0.60	acceptable
Flesch RE (French)	65.54	20-40	Textes trop faciles à lire pour un document médical (phrases courtes, syllables simples, devrait etre plus dense et technique
Perplexity	129.79	30-80 pour français médical	Très elevé (pas très représentative), il faudra peut etre tester using CamemBERT
SLOR	-0.9525	-2 à 0 pour textes bien formés	Bon : Fluence syntaxique correcte, texte bien structuré avec enchaînements logiques appropriés
self_bleu_2	0.5886	0.25 - 0.40(structure commune acceptable)	acceptable : Similarité modérée entre textes (bigrammes), indique répétition de formulations courantes mais reste acceptable pour CR standardisés
self_bleu_3	0.5262	0.30-0.45	acceptable : Diversité acceptable (trigrammes) malgré présence de phrases-types récurrentes, normal pour documents médicaux structurés
self_bleu_4	0.4815	0.35-0.50	good : Bonne diversité globale (4-grammes) : textes, variés tout en conservant structure commune, équilibre optimal pour CR médicaux

```
================================================================================
                    INTERPRETATION GRID
================================================================================

    | Metric                | Excellent | Good      | Acceptable | Poor      |
    |-----------------------|-----------|-----------|------------|-----------|
    | TTR                   | > 0.5     | 0.4-0.5   | 0.3-0.4    | < 0.3     |
    | Self-BLEU             | < 0.3     | 0.3-0.5   | 0.5-0.7    | > 0.7     |
    | Mention Rate          | > 90%     | 70-90%    | 50-70%     | < 50%     |
    | Flesch RE             | > 60      | 40-60     | 20-40      | < 20      |
    | Medical Density       | > 20%     | 15-20%    | 10-15%     | < 10%     |
    | Structure Complete    | > 85%     | 70-85%    | 50-70%     | < 50%     |
    | Medical Quality       | > 85%     | 70-85%    | 50-70%     | < 50%     |
```

Output final : JSONL + JSON

- mistral_5shot_v5.jsonl : 30 CR avec métadonnées
- metrics_auto_v5.json : Métriques agrégées + individuelles

Étape 6 : Évaluation par un LLM

Étape 7 : Évaluation par des experts

En cours ... Par Christophe, physicien médical au GHM Grenoble