

Création éthique de données textuelles artificielles : application au domaine biomédical

Nicolas Hiebel

▶ **To cite this version:**

Nicolas Hiebel. Création éthique de données textuelles artificielles : application au domaine biomédical. Traitement du texte et du document. Université Paris-Saclay, 2025. Français. ⟨NNT : 2025UPASG033⟩. ⟨tel-05185326⟩

HAL Id: tel-05185326

https://theses.hal.science/tel-05185326v1

Submitted on 24 Jul 2025

HAL is a multi-disciplinary open access archive for the deposit and dissemination of scientific research documents, whether they are published or not. The documents may come from teaching and research institutions in France or abroad, or from public or private research centers.

L'archive ouverte pluridisciplinaire **HAL**, est destinée au dépôt et à la diffusion de documents scientifiques de niveau recherche, publiés ou non, émanant des établissements d'enseignement et de recherche français ou étrangers, des laboratoires publics ou privés.



HAL Authorization

université PARIS-SACLAY

Création éthique de données textuelles artificielles : application au domaine biomédical

Artificial text corpus designed ethically : application to clinical documents

Thèse de doctorat de l'université Paris-Saclay

École doctorale n°580 : Sciences et Technologies de l'Information et de la Communication (STIC)
Spécialité de doctorat : Informatique
Graduate School : Informatique et sciences du numérique. Référent : Faculté des sciences d'Orsay

Thèse préparée dans l'unité(s) de recherche **Laboratoire Interdisciplinaire des Sciences du Numérique (Université Paris-Saclay, CNRS)**, sous la direction de **Aurélie NÉVÉOL**, Directrice de recherche, et le co-encadrement de **Karën FORT**, Professeure des universités, et **Olivier FERRET**, Directeur de recherche

Thèse soutenue à Paris-Saclay, le 20 juin 2025, par

Nicolas HIEBEL

Composition du jury

Membres du jury avec voix délibérative

Gaël VAROQUAUX Directeur de recherche, Inria Saclay	Président
Vincent CLAVEAU Directeur de recherche, Agence Ministérielle pour l'IA de Défense	Rapporteur & Examinateur
Fleur MOUGIN Professeure des universités, Université de Bordeaux	Rapportrice & Examinatrice
Claire GARDENT Directrice de recherche, Université de Lorraine	Examinatrice
Julia IVE Maîtresse de conférence, University College London	Examinatrice

THESE DE DOCTORAT

NNT : 2025UPASG033

université PARIS-SACLAY

ÉCOLE DOCTORALE
Sciences et technologies de l'information et de la communication (STIC)

Titre : Création éthique de données textuelles artificielles : application au domaine biomédical
Mots clés : Traitement automatique des langues biomédicales, Génération automatique de texte, Science responsable, Ressources et évaluation

Résumé : Le partage de ressources dans le domaine clinique est régi par des contraintes de confidentialité. Les corpus librement disponibles sont rares car les documents contiennent des informations confidentielles et ne peuvent donc pas être partagés. Or, des corpus annotés sont nécessaires pour entraîner et évaluer des outils automatiques, outils dont le domaine clinique bénéficierait grandement étant donné la surcharge actuelle des cliniciens. Par ailleurs, les textes cliniques sont utilisés à des fins pédagogiques dans les cursus de formation médicale. Les textes utilisés doivent donc couvrir des situations actuelles et variées. Ce travail s'intéresse à la définition de méthodes de génération de texte et à leur application à des corpus cliniques en français pour produire automatiquement des documents synthétiques comparables à des documents réels d'un point de vue linguistique et ne présentant pas d'informations confidentielles. Nous proposons trois méthodologies de génération d'un type particulier de documents cliniques : les cas cliniques. Ces trois méthodologies se fondent sur des modèles de génération de texte pré-entraînés et affinés sur le domaine clinique en français. Chaque méthodologie se concentre sur un objectif de génération particulier : l'adaptation de modèles au domaine clinique, le contrôle de la génération en fonction de caractéristiques précises et l'observation des limites du contrôle du point de vue des biais. Nous associons à chacune des trois méthodologies un protocole d'évaluation adapté aux objectifs de génération. Les dimensions d'évaluation couvrent la similarité des textes générés aux textes réels, l'utilité des textes synthétiques pour l'entraînement de modèles d'extraction d'informations cliniques, la fluidité des textes, la contrôlabilité et le coût de la génération. La dernière partie de ce travail se focalise la conception et l'implémentation d'un jeu ayant pour but l'évaluation manuelle des textes synthétiques ainsi qu'une analyse des résultats obtenus à ce stade.

université PARIS-SACLAY

ÉCOLE DOCTORALE
Sciences et technologies de l'information et de la communication (STIC)

Title : Artificial text corpus designed ethically : application to clinical documents
Keywords : Biomedical natural language processing, Automatic text generation, Responsible science, Resource and evaluation

Abstract : Resource sharing in the clinical field is subject to confidentiality constraints. Publicly available corpora are rare, as these documents contain sensitive information and cannot be shared. However, annotated corpora are necessary for training and evaluating automated tools, which would be highly beneficial to the clinical field given the current workload of clinicians. Moreover, clinical texts are used for educational purposes in medical training programs, requiring them to cover diverse and up-to-date situations. This study focuses on defining text generation methods and applying them to French clinical corpora to automatically produce synthetic documents that are linguistically comparable to real documents while excluding any confidential information. We introduce three methodologies for generating a specific type of clinical document : clinical cases. These methodologies are based on pre-trained text generation models fine-tuned for the clinical domain in French. Each methodology focuses on a specific generation objective : adapting models to the clinical domain, guiding generation according to specific characteristics, and examining the limitations of control with regard to biases. We associate each of the three methodologies with an evaluation protocol designed to match its generation objectives. The evaluation criteria include the linguistic similarity of generated texts to real texts, the usefulness of synthetic texts for training clinical information extraction models, text fluency, controllability, and generation cost. The final part of this study focuses on the design and implementation of a game aimed at the manual evaluation of synthetic texts, along with an analysis of the results obtained at this stage.

Remerciements

Je tiens tout d'abord à remercier Aurélie, Olivier et Karën qui m'ont accompagné tout au long de cette thèse (et même avant !) et grâce à qui j'ai pu apprendre tant de choses. Merci pour votre disponibilité, votre patience et vos conseils précieux. J'ai du mal à réaliser le chemin parcouru depuis le début de cette thèse (même si le chemin est encore long) et c'est grâce à vous.

Je remercie toutes les personnes impliquées dans le projet CODEINE avec qui j'ai pu échanger. Merci également à Fanny et Hugo avec qui j'ai pu travailler lors de collaborations enrichissantes.

Je remercie les étudiants que j'ai eu l'occasion d'encadrer durant ma thèse, Ziqian, Foucauld, Florian, Camille et Sofia. C'était un plaisir de travailler avec vous et votre travail a permis de faciliter le mien, un grand merci pour cela.

Je tiens également à remercier Gaël Lejeune, à qui je dois beaucoup. Merci d'avoir cru en moi dès le début, les opportunités dont j'ai bénéficié sont en grande partie grâce à toi.

Je remercie les membres du jury : Fleur, Vincent, Claire, Gaël et Julia. Merci d'avoir pris le temps de vous intéresser à mes travaux et pour vos remarques pertinentes qui ont enrichi ma réflexion. Je tiens également à remercier Jean-Claude Martin pour avoir accepté de participer à mon comité de suivi de thèse et pour son accompagnement à l'IUT d'Orsay.

Je remercie les membres du laboratoire que j'ai eu la chance de côtoyer durant ces quatre années de thèse. J'ai pris mon temps, des générations se sont succédé, cela fait donc un nombre important de personnes que je ne vais pas citer en intégralité. Je me permets tout de même une mention spéciale au Testo-Bureau. Quoiqu'il en soit, merci beaucoup pour les repas, discussions, soutiens, rires, et j'en passe.

Je termine par remercier ma famille et mes proches, essentiels pour me soutenir et me changer les idées durant cette période pas toujours facile. Cette thèse m'a parfois isolé et j'ai hâte de pouvoir à nouveau passer du temps avec vous.

Table des matières

1 Introduction **15**
- 1.1 Contexte . . . 15
- 1.2 Questions de recherche . . . 16
- 1.3 Contributions . . . 17
- 1.4 Publications . . . 18

2 La génération de texte : des origines à la génération dans le domaine clinique **21**
- 2.1 Génération de texte : une évolution exponentielle . . . 21
- 2.2 Méthodes symboliques pour la génération de texte . . . 21
- 2.3 Méthodes statistiques . . . 25
  - 2.3.1 Modèles de langue à base de n-grammes . . . 25
  - 2.3.2 Modèles de langue neuronaux . . . 26
- 2.4 Processus de génération des modèles statistiques . . . 28
- 2.5 Contrôle de la génération dans les modèles statistiques . . . 32
  - 2.5.1 Contrôle par l'entraînement . . . 32
  - 2.5.2 Contrôle à l'inférence : la génération coopérative . . . 33
  - 2.5.3 Limites des modèles de langue génératifs . . . 34
- 2.6 Évaluation de texte généré . . . 36
  - 2.6.1 Métriques automatiques fondées sur des références . . . 36
  - 2.6.2 Métriques sans référence . . . 37
  - 2.6.3 Évaluation manuelle . . . 38
  - 2.6.4 Évaluation automatique de texte dans le domaine biomédical . . . 40
- 2.7 Génération de texte dans le domaine biomédical . . . 41
- 2.8 Conclusion . . . 43

3 Méthodologies de génération de texte **45**
- 3.1 Introduction . . . 45
- 3.2 Présentation des corpus de cas cliniques . . . 45
  - 3.2.1 Corpus de cas cliniques librement disponibles . . . 46
  - 3.2.2 Recouvrement entre les corpus . . . 47
  - 3.2.3 Résumé statistique . . . 47
- 3.3 Adaptation au domaine . . . 47
  - 3.3.1 Préparation du corpus . . . 48
  - 3.3.2 Modèles utilisés . . . 50
  - 3.3.3 Affinage des modèles . . . 50
  - 3.3.4 Détails du processus de génération . . . 51
  - 3.3.5 Filtrage des textes générés . . . 54
  - 3.3.6 Statistiques . . . 54

3.3.7 Exemples de textes générés . . . 55
3.3.8 Synthèse . . . 55
3.4 Introduction d'éléments de contrôle . . . 57
3.4.1 Définition d'un profil patient . . . 57
3.4.2 Annotation des profils patient . . . 58
3.4.3 Construction des contraintes . . . 59
3.4.4 Intégration des contraintes . . . 60
3.4.5 Modèles . . . 61
3.4.6 Affinage des modèles . . . 61
3.4.7 Méthodologie de génération . . . 62
3.4.8 Exemples . . . 63
3.4.9 Synthèse . . . 63
3.5 Analyse de l'importance du contrôle . . . 65
3.5.1 Filtrage des documents des corpus . . . 65
3.5.1.1 Documents hors-cadre . . . 66
3.5.1.2 Découpage des cas cliniques . . . 66
3.5.2 Ensemble d'entraînement obtenu . . . 67
3.5.3 Modèles . . . 68
3.5.4 Construction du jeu de test . . . 68
3.5.5 Paramètres d'affinage . . . 69
3.5.6 Méthodologie de génération . . . 69
3.5.7 Exemples . . . 70
3.5.8 Temps de génération . . . 71
3.6 Conclusion . . . 71

4 Évaluation de la génération de texte clinique **73**
4.1 Introduction . . . 73
4.2 Évaluation de l'adaptation au domaine . . . 73
4.2.1 Recouvrement lexical avec le corpus réel . . . 74
4.2.2 Évaluation par similarité de plongements de phrases . . . 75
4.2.2.1 Corpus de similarité phrastique . . . 75
4.2.2.2 Corpus de contrôle . . . 76
4.2.2.3 Modèles de plongements de phrases . . . 76
4.2.2.4 Calcul des scores de similarité . . . 76
4.2.2.5 Recherche des phrases du corpus E3C . . . 78
4.2.3 Utilité des corpus synthétiques pour une tâche de reconnaissance d'entités cliniques . . . 80
4.2.3.1 Distribution des annotations sur les ensembles de test . . . 82
4.2.3.2 Performance des modèles de reconnaissance d'entités cliniques . . . 82
4.2.4 Évaluation manuelle qualitative . . . 85
4.2.5 Synthèse . . . 85
4.3 Évaluation de la génération conditionnée par des profils patient . . . 86
4.3.1 Métriques d'évaluation . . . 86

4.3.2 Baselines . . . 87
4.3.3 Résultats globaux . . . 87
4.3.4 Respect des contraintes . . . 88
4.3.5 Diversité des corpus générés . . . 89
4.3.6 « Qualité » de la langue . . . 89
4.3.7 Ressemblance avec le corpus réel . . . 90
4.3.8 Coûts de l'entraînement et de la génération . . . 91
4.3.9 Synthèse . . . 93
4.4 Impact de la pathologie et du genre sur le contrôle . . . 93
4.4.1 Respect des contraintes cliniques et ressemblance aux cas cliniques réels . . . 94
4.4.2 Une contrainte particulière : le genre . . . 95
4.4.2.1 Détection automatique du genre dans les cas cliniques générés . . . 96
4.4.2.2 Respect de la contrainte de genre . . . 96
4.4.2.3 Lorsqu'on ne contrôle pas le genre . . . 97
4.4.3 Synthèse . . . 99
4.5 Évaluation manuelle à l'aide d'un jeu ayant un but . . . 100
4.5.1 Présentation d'HostoMytho . . . 100
4.5.1.1 Histoire et univers . . . 100
4.5.1.2 Jeux disponibles . . . 101
4.5.1.3 Mécanismes de jeu . . . 104
4.5.1.4 Formation des joueurs . . . 107
4.5.2 Conception du jeu . . . 108
4.5.2.1 Diviser (les tâches) pour mieux régner . . . 108
4.5.2.2 Contrôler la qualité des annotations . . . 108
4.5.2.3 S'adapter aux différents types de joueurs . . . 109
4.5.3 Analyse des données collectées . . . 110
4.5.3.1 Statistiques globales . . . 110
4.5.3.2 Comparaison des annotations entre médecins et non médecins . . . 113
4.6 Conclusion . . . 115

5 Conclusion **117**
5.1 Résumé des contributions . . . 117
5.2 Limites et perspectives . . . 119
5.2.1 Contrôle de la génération . . . 119
5.2.2 Coûts de génération . . . 119
5.2.3 Application à d'autres corpus . . . 120
5.2.4 Évaluation . . . 120

Table des figures

2.1 Chronologie de l'évolution des méthodes de génération de texte et de la récente explosion des LLM. 22
2.2 Dialogue entre l'homme et la machine (Danlos, 1985). 23
2.3 Exemple d'arbre de discrimination pour sélectionner le mot à utiliser pour le concept *« consommer »* (exemple tiré de Zock et Sabah (1992)). 24
2.4 Illustration du processus de génération de texte comme une exploration d'arbre. 29
2.5 Probabilités attribuées au 20 premiers tokens pour l'amorce : *« Pour soulager la fièvre, prenez un »* avec le modèle BLOOM-560m, un top-p de 0,6 et différentes températures. 31
2.6 Schéma du guidage de la génération de texte avec un décodage pondéré par un discriminateur en fonction d'une condition α. 33

3.1 Self-BLEU sur un échantillon de génération de 30 000 tokens pour chaque modèle de génération. Le Self-BLEU sur le corpus E3C a été mesuré à 0,68. $_{+T}$ indique les modèles ont été entraînés sur la version balisée du corpus E3C. 52
3.2 Perplexité du modèle oracle sur un échantillon de génération de 30 000 tokens pour chaque modèle de génération. La perplexité oracle est calculée à l'aide du modèle pré-entraîné BLOOM à 7 milliards de paramètres. La perplexité oracle sur le corpus E3C a été mesurée à 22,0. $_{+T}$ indique les modèles ont été entraînés sur la version balisée du corpus E3C. 53
3.3 Distribution des genres dans les corpus de cas cliniques CAS et E3C. 59
3.4 Distribution des tranches d'âges dans les corpus de cas cliniques CAS et E3C. 60

4.1 Moyennes des scores de chaque phrase du corpus E3C avec les phrases les plus proches dans les corpus générés, CAS et un corpus hors domaine (Est Républicain). Pour les figures 4.1a, 4.1b et 4.1c, les similarités des 100 phrases les plus proches sont obtenues par similarité cosinus des plongements de phrases, issus de modèles Sentence-BERT. Pour la figure 4.1d, nous récupérons les 20 scores BLEU les plus élevés parmi les 100 phrases les plus proches trouvées avec les plongements de SBERT ajustés sur CLISTER. La ligne pointillée rouge correspond à la moyenne des scores des corpus cliniques. 77
4.2 Scores MAP et Précision@20 de la recherche des phrases de E3C parmi la combinaison des phrases de E3C et des phrases du corpus comparé. Les phrases sont représentées par des plongements de mots issus de Sentence-BERT. Nous recherchons parmi les 100 phrases les plus similaires. 79
4.3 Description de l'expérience permettant l'évaluation de la reconnaissance d'entités cliniques sur des données synthétiques. 81

4.4 Proportion des genres dans les textes générés selon le genre donné en amorce. La ligne rouge marque les 50 %. 96
4.5 Proportion des genres dans les textes générés lorsque le genre n'est pas précisé dans l'amorce. La ligne rouge marque les 50 %. 98
4.6 Comparaison des distributions des genres dans les textes générés avec les distributions réelles pour chaque pathologie. Les flèches marquent l'écart entre les distributions masculines générées et réelles. 99
4.7 Menu principal du jeu `HostoMytho`. 101
4.8 Mytho Ou Pas : un jeu pour évaluer la plausibilité des textes. 102
4.9 Mytho-Typo : un jeu de classification d'erreurs. 103
4.10 Mytho-No : un jeu de détection de négations. 104
4.11 Classement général dans `HostoMytho`. 105
4.12 Meilleurs enquêteurs du mois précédent (zoom sur le menu principal). . . 106
4.13 Un criminel dans `HostoMytho`. 106
4.14 Personnalisation de l'avatar. 107
4.15 Tutoriel au début du jeu Mytho ou pas. 108
4.16 Classification des types de joueurs selon Bartle (1996). 109
4.17 Distribution des catégories de joueurs. 110
4.18 Nombre d'annotations par jeu et par catégorie de joueurs. 111
4.19 Distribution des scores de confiance pour les médecins et les non médecins. 112
4.20 Participation des joueurs. 113
4.21 Distribution des annotations de plausibilité dans Mytho Ou Pas. 113
4.22 Distribution des différents types d'erreurs annotées dans MythoTypo. . . . 114

Liste des tableaux

3.1 Statistiques des trois corpus de cas cliniques étudiés. 48
3.2 Catégories et occurrences des annotations dans le corpus MERLOT. 49
3.3 Description statistique des corpus cliniques synthétiques. La perplexité oracle est calculée à l'aide du modèle pré-entraîné BLOOM à 7 milliards de paramètres. La perplexité oracle sur le corpus E3C a été mesurée à 22,0. . 55
3.4 Extraits de textes générés pour les quatre configurations. Les éléments surlignés dans les extraits de la ligne du bas présentent les balises d'entités générées. Se référer au tableau 3.2 pour le code couleur des annotations. 56
3.5 Exemples d'éléments de contrôle manuellement définis pour un cas clinique. Le cas clinique correspondant est présenté dans l'exemple (2). . . 58
3.6 Nombre de paramètres indiqué par la bibliothèque PEFT lors de l'affinage des modèles. Les modèles BLOOM et BLOOMZ sont groupés car ils possèdent la même architecture et le même nombre de paramètres. La différence de nombre de paramètres entre les versions gelées et dégelées correspond aux poids des plongements, comptés deux fois dans la version gelée. 62
3.7 Exemples de textes générés à partir de contraintes automatiquement extraites d'un cas clinique réel. Le code couleur correspond aux types de contraintes : **informations démographiques**, signes et symptômes, mesures et procédures. 64
3.8 Statistiques du corpus d'entraînement. 68
3.9 Prévalence des pathologies selon l'EDS de l'HEGP ou d'autres documentations lorsque trop peu de patients étaient représentés. 69
3.10 Amorces tronquées et cas cliniques correspondants générés avec le modèle Llama-3.1-Instruct. La première ligne est un cas de cancer du côlon sans précision de genre et la seconde, un cas d'infarctus pour un profil féminin. Les mots contenant la marque du genre sont en gras et les contraintes cliniques sont soulignées dans les textes générés. 70

4.1 Scores de recouvrement de 1 à 8-grammes entre les corpus synthétiques et E3C. Chaque ligne correspond à la comparaison entre le corpus et E3C. La comparaison entre E3C et CAS est ajoutée comme baseline. 75
4.2 Nombre d'annotations de chaque type pour chaque corpus de test. 82
4.3 Résultats de la tâche de REN sur les corpus réels (P=précision, R=rappel, F=F-mesure). 83
4.4 Résultats de la tâche de REN sur les corpus générés sans annotations. . . . 83
4.5 Résultats de la tâche de REN sur les corpus générés avec des annotations. 83
4.6 Évaluation récapitulative des données générées. Modèles baselines marqués par « $*$ » : entraînement et génération sans contrainte. 88
4.7 Scores BLEU-4 et Corpus-BLEU-4 sur l'ensemble de test. 91

4.8 Temps de calcul et empreintes carbone pour l'entraînement et l'inférence. Pour l'entraînement et l'inférence, le format correspond à : nombre d'heures × nombre de GPU. Les calculs utilisant vLLM sont marqués d'une étoile « * ». 92
4.9 Évaluation par pathologie du respect des contraintes et de la ressemblance par rapport au cas cliniques réels. 94
4.10 Évaluation par modèle. 95
4.11 Évaluation selon le genre dans l'amorce. 95
4.12 Taux de mégenrage par pathologie. 97
4.13 Taux de mégenrage par modèle. 97

1 - Introduction

1.1 . Contexte

Dans le domaine du traitement automatique des langues (TAL), la disponibilité de ressources spécifiques conditionne le développement et l'évaluation d'outils spécialisés. Cette spécificité peut couvrir une langue, un domaine ou une tâche particulière. Par conséquent, le manque de ressources spécifiques est l'un des obstacles les plus courants en TAL.

Cette thèse s'intéresse aux ressources textuelles dans le domaine médical. Une grande quantité d'informations médicales est en effet stockée sous forme textuelle, notamment dans les dossiers patient informatisés qui permettent de suivre la prise en charge des patients[1]. Les cliniciens étant souvent surchargés (Clynch et Kellett, 2015 ; Knoll *et al.*, 2022 ; Clarke *et al.*, 2013), le développement d'outils facilitant la recherche et l'extraction d'informations pourrait alléger leur charge de travail. Des initiatives telles que la création de la bibliothèque Python MedKit[2] proposent par exemple un ensemble d'outils librement disponibles pour l'analyse des données patient. Les textes cliniques sont également exploités à des fins pédagogiques dans les cursus de formation médicale. Ils offrent en effet la possibilité d'observer des situations concrètes en retraçant l'ensemble du suivi d'un patient. Il est donc essentiel que les textes étudiés incluent des situations variées et actuelles.

Le domaine biomédical fait partie des domaines pour lesquels les données librement disponibles sont rares pour les langues autres que l'anglais (Névéol *et al.*, 2018). En effet, la nature confidentielle des données biomédicales exige une précaution particulière pour protéger cette confidentialité et la vie privée des patients concernés. Le partage de nouveaux corpus contribuerait néanmoins au développement d'outils automatiques et à la formation des médecins. Outre les difficultés liées au partage, le traitement des textes dans le domaine biomédical nécessite de s'adapter aux variations de conventions et de styles d'écriture entre les différentes langues, les différents hôpitaux, voire même entre différents médecins (Netzel *et al.*, 2003 ; Wu *et al.*, 2013 ; Cohen *et al.*, 2019).

Une stratégie pour faire face à la rareté des corpus disponibles dans le domaine médical consiste à remplacer les informations directement identifiantes (noms, prénoms, lieux, dates) par des substituts plausibles. Ce procédé est appelé la désidentification. Néanmoins, cette stratégie a été démontrée comme insuffisante pour protéger la confidentialité des données désidentifiées (Carrell *et al.*, 2019). Par ailleurs, les progrès en génération automatique de texte permettent aujourd'hui de générer du texte difficile à différencier de textes écrits par des humains (Alavoine *et al.*, 2024). Les méthodes actuelles reposent sur des grands modèles de langue (LLM - *Large Language Model*), fondés sur des architectures neuronales transformeurs (Vaswani *et al.*, 2017) pré-entraînées sur d'immenses quantités de textes. Leurs performances ont été principalement démontrées pour l'an-

1. Dans cette thèse, nous utilisons la convention du masculin générique par souci de lisibilité et de fluidité. Nous incluons toutes les personnes concernées, quel que soit leur genre.
2. https://medkit-lib.org/index.html

glais et dans le domaine général (Casal et Kessler, 2023) mais présentent rapidement des limites lorsque la tâche se spécialise (Marco *et al.*, 2024). Néanmoins, les progrès des modèles génératifs ouvrent la voie à de multiples applications, notamment afin de pallier l'absence de corpus librement partageables.

Cette thèse a été menée au sein du département Sciences et Technologies des Langues (STL) du Laboratoire Interdisciplinaire des Sciences du Numérique (LISN) [3], dans le cadre du projet ANR CODEINE [4]. Ce projet est une collaboration entre le LISN, le CEA, le LORIA et l'Hôpital Européen Georges Pompidou (HEGP), et vise à pallier le manque de corpus partageables dans des domaines sensibles tels que la santé et la finance.

Dans ce travail, nous cherchons à enrichir la faible quantité de corpus librement disponibles dans le domaine biomédical en français en générant des textes synthétiques ayant les mêmes caractéristiques que de vrais textes du domaine, tout en veillant à ce que les textes générés ne posent pas de problème de confidentialité. Un défi majeur de cette tâche réside donc dans cet équilibre. D'une part, les textes synthétiques générés doivent partager une quantité de caractéristiques suffisantes avec les textes réels afin que leur exploitation soit pertinente. D'autre part, les textes synthétiques générés doivent suffisamment s'éloigner des textes réels afin de limiter les risques pour la confidentialité.

1.2 . Questions de recherche

Cette thèse porte donc sur la génération automatique de texte appliquée au domaine biomédical et plus précisément à des textes cliniques, c'est-à-dire à propos de la prise en charge de patients. Comme décrit précédemment, les LLM permettent de produire des textes très ressemblants à des textes écrits par des humains dans le domaine général. Cela nous conduit à notre principale question de recherche : **comment générer des textes ressemblant à des textes cliniques réels ?** Afin de préciser cette problématique générale, nous la décomposons en plusieurs questions de recherche, permettant d'en clarifier les enjeux et de mieux situer le contexte de cette thèse.

Tout d'abord, nous cherchons à exploiter le potentiel des modèles de génération préentraînés dans le but de les appliquer sur les textes cliniques en français qui nous intéressent. Ainsi, une première question de recherche plus précise sera : **comment adapter les méthodes de génération de texte au domaine clinique en français ?** (1)

En complément de la méthodologie de génération, il est nécessaire de déterminer la « qualité » des textes générés, cette dernière pouvant couvrir de nombreux critères. C'est pourquoi notre deuxième question de recherche sera : **comment évaluer la qualité des modèles définis et des textes générés ?** (2)

À ces deux questions principales s'ajoutent des problématiques subsidiaires amenées par le cadre médical dans lequel cette thèse s'inscrit. Puisque nous cherchons à créer des ressources librement partageables à partir de données contenant des informations confidentielles, les outils développés durant cette thèse ont vocation à être utilisés dans des environnements hospitaliers, où la puissance de calcul disponible est potentiellement li-

3. https://www.lisn.upsaclay.fr/

4. *Création éthique de données textuelles artificielles : Synthèse Automatique de documents Hospitaliers*

mitée. Une autre problématique apportée par le domaine serait donc : **comment générer des textes avec des contraintes de temps et de puissance de calcul ?** (3)

Enfin, cette adaptation doit être soumise aux contraintes de confidentialité inhérentes aux données patient et veiller à leur protection. Ainsi, nous nous demandons également : **comment générer des textes ne comportant pas de risque pour la confidentialité des patients ?** (4) Cet enjeu concerne à la fois la méthodologie de la génération de texte et son évaluation.

1.3 . Contributions

Avant de tenter de répondre à ces questions, nous commençons dans le chapitre 2 par présenter les principes de la génération automatique de texte et de son évaluation depuis ses fondements dans les années 60 jusqu'à aujourd'hui. Nous présentons également les applications de la génération automatique de texte dans le domaine clinique.

Nous nous intéressons ensuite dans le chapitre 3 à la méthodologie de génération de texte et tentons ainsi de répondre à la question (1). Dans ce chapitre, nous commençons par présenter le type particulier de documents cliniques que nous allons manipuler durant toute cette thèse, les cas cliniques. Nous présentons ensuite trois méthodologies de génération automatique de cas cliniques en français. La première consiste en une simple adaptation au domaine de modèles pré-existants, la deuxième introduit des éléments de contrôle afin de conditionner les cas cliniques générés vers des caractéristiques cliniques particulières et la troisième précise la précédente en mettant l'accent sur des caractéristiques particulières : le genre des patients dans les cas cliniques générés et les pathologies ciblées.

Chacune des trois méthodologies de génération nécessite de réaliser des prétraitements des corpus de cas cliniques utilisés en s'adaptant à la tâche. Nous présentons donc les corpus utilisés et leur préparation pour chacune des méthodologies. Cette préparation implique notamment un filtrage des textes et une annotation, automatique ou manuelle.

Enfin, nous présentons un ou plusieurs exemples de textes générés pour chaque méthode de génération.

Pour résumer, le chapitre 3 présente les deux contributions suivantes :

1. trois méthodologies de préparation de corpus, adaptées aux objectifs de génération ;
2. trois méthodologies de génération automatique de cas cliniques en français selon trois niveaux de spécificité.

Le chapitre 4 tente de répondre à la question (2) en se concentrant sur l'évaluation des cas cliniques générés dans le chapitre précédent. Nous proposons également une exploration d'évaluation tentant de répondre à la question (4). Nous commençons par présenter trois protocoles d'évaluation correspondant aux trois méthodologies de génération décrites dans le chapitre 3. Chaque protocole est conçu pour adapter l'évaluation aux objectifs spécifiques de la méthodologie associée.

Premièrement, nous évaluons l'adaptation au domaine à l'aide de l'étude de la similarité lexicale et phrastique entre les corpus synthétiques générés et le corpus dont ces textes s'inspirent, ainsi qu'une comparaison de l'utilité des textes générés pour l'entraînement de modèles de reconnaissance d'entités cliniques. Nous terminons cette évaluation par l'analyse manuelle d'un échantillon de textes.

Deuxièmement, nous proposons une évaluation automatique du contrôle de la génération vers des caractéristiques cliniques. Pour cela, nous couvrons un ensemble de critères de qualité à l'aide de métriques automatiques. Nous tentons ainsi d'obtenir une évaluation automatique complète couvrant la contrôlabilité des méthodes choisies, la qualité de la langue, la ressemblance au corpus réel utilisé pour l'entraînement, la diversité des textes générés et les ressources de calcul utilisées pour l'utilisation de ces méthodes.

Troisièmement, nous étudions l'impact du genre et de la pathologie sur la capacité des outils de génération à suivre le conditionnement. Nous utilisons pour cela un outil de détection automatique du genre en français et comparons les statistiques dans les textes générés à des statistiques réelles.

Enfin, nous nous penchons sur une évaluation manuelle des textes générés à l'aide d'un jeu développé dans le cadre du projet CODEINE, appelé `HostoMytho`. Nous commençons par une présentation du jeu, puis nous analysons les annotations recueillies jusqu'à aujourd'hui.

En résumé, le chapitre 4 présente les contributions suivantes :

1. une méthodologie d'évaluation de l'adaptation au domaine à l'aide de différents critères de similarité avec le corpus réel ;
2. une méthodologie d'évaluation automatique du contrôle de la génération couvrant à la fois la qualité du texte généré et l'utilisabilité des outils ;
3. une évaluation de l'impact du genre et de la pathologie sur la contrôlabilité des outils utilisés ;
4. la présentation d'un jeu ayant un but pour l'évaluation et l'annotation manuelle de cas cliniques synthétiques, ainsi que l'analyse des annotations obtenues.

Dans le chapitre 3 comme dans le chapitre 4, nous utilisons des méthodes et outils récents tout en gardant en tête la question (3), à savoir que ces outils doivent pouvoir être utilisés dans un contexte de ressources de calcul limitées. C'est pourquoi nous choisissons des outils, des méthodes d'entraînement et de génération tentant de répondre à ces contraintes dans le chapitre 3 et que nous essayons d'évaluer cette dimension dans le chapitre 4. Nous terminons cette thèse en résumant les contributions de ce travail et en évoquant les perspectives pour nos travaux futurs.

1.4 . Publications

Le chapitre 2 se base sur une publication à venir dans la revue *Annual Review of Biomedical Data Science* (Hiebel *et al.*, 2025). Les chapitres 3 et 4 se fondent sur plusieurs publications pour lesquelles nous avons regroupé d'une part les méthodologies de génération et de l'autre les évaluations. La partie portant sur l'adaptation au domaine (sections 3.3

et 4.2) a été publiée à la conférence EACL 2023 (Hiebel *et al.*, 2023a) avec un complément d'évaluation publié à TALN 2023 (Hiebel *et al.*, 2023b). La partie contrôle de la génération (sections 3.4 et 4.3) a été publiée à l'atelier ClinicalNLP de la conférence NAACL 2024 (Boulanger *et al.*, 2024) et l'étude de l'impact du genre et de la pathologie (sections 3.5 et 4.4) à la conférence NAACL 2025 (Ducel *et al.*, 2025). Enfin, le jeu ayant un but `HostoMytho` (section 4.5) a été présenté à l'atelier *Games and NLP* de la conférence LREC 2024 (Hiebel *et al.*, 2024).

Liste des publications

Revues internationales

- Nicolas Hiebel, Olivier Ferret, Karën Fort, Aurélie Névéol. Clinical Text Generation : Are We There Yet ? *Annual Review of Biomedical Data Science*. À venir.

Conférences

Internationales :

- Fanny Ducel, Nicolas Hiebel, Olivier Ferret, Karën Fort, Aurélie Névéol. "Women do not have heart attacks !" Gender Biases in Automatically Generated Clinical Cases in French. *Annual Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics*, avril 2025, Albuquerque, États-Unis.
- Nicolas Hiebel, Olivier Ferret, Karën Fort, and Aurélie Névéol. Can Synthetic Text Help Clinical Named Entity Recognition ? A Study of Electronic Health Records in French. *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 2320–2338, Dubrovnik, Croatie, mai 2023. Association for Computational Linguistics.

Nationales :

- Nicolas Hiebel, Olivier Ferret, Karën Fort, and Aurélie Névéol. Les textes cliniques français générés sont-ils dangereusement similaires à leur source ? Analyse par plongements de phrases. *Actes de la 30e Conférence sur le Traitement Automatique des Langues Naturelles.*, Paris, France, juin 2023. ATALA.

Ateliers :

- Hugo Boulanger*, Nicolas Hiebel*, Olivier Ferret, Karën Fort, and Aurélie Névéol. 2024. Using Structured Health Information for Controlled Generation of Clinical Cases in French. *Proceedings of the 6th Clinical Natural Language Processing Workshop*, pages 172–184, Mexico City, Mexique. Association for Computational Linguistics.
- Nicolas Hiebel, Bertrand Remy, Bruno Guillaume, Olivier Ferret, Aurélie Névéol, Karën Fort. Hostomytho : A GWAP for Synthetic Clinical Texts Evaluation and Annotation. *Proceedings of the 10th Workshop on Games and Natural Language Processing @ LREC-COLING 2024*, Turin, Italie, mai 2024.

2 - La génération de texte : des origines à la génération dans le domaine clinique

2.1 . Génération de texte : une évolution exponentielle

La génération automatique de texte est de nos jours utilisée pour un ensemble varié de tâches (traduction, résumé automatique, systèmes de dialogues, etc...). Les progrès récents des modèles génératifs ont permis d'étendre les applications possibles, que ce soit à des tâches peu explorées auparavant (par exemple : la génération de code informatique) ou à des tâches ne relevant traditionnellement pas de la génération automatique (par exemple : l'extraction d'information).

La figure 2.1 présente l'évolution des méthodes de génération de texte, en commençant par les méthodes symboliques à la fin des années 1960 jusqu'à la multiplication des LLM au cours de ces dernières années, avec une évolution suivant un rythme de plus en plus rapide, les grands acteurs du domaine publiant actuellement plusieurs modèles par an. Des LLM sont créés pour répondre à différents besoins. Certains s'intéressent à des langues autres que l'anglais ou a des capacités multilingues tandis que d'autres s'intéressent à des domaines ou tâches spécifiques sur lesquelles les modèles de langue généraux ont plus de difficultés, comme le domaine médical.

Dans cette partie, nous présentons un aperçu de l'évolution des méthodes de génération de texte et des défis associés. Ce chapitre s'appuie sur un article en cours de publication dans la revue *Annual Review of Biomedical Data Science* (Hiebel *et al.*, 2025), dont certaines parties ont été développées.

2.2 . Méthodes symboliques pour la génération de texte

Comme présenté dans un certain nombre d'études, la génération de texte remonte aussi loin que l'apparition du TAL (Zock et Sabah, 1992 ; Reiter et Dale, 2000 ; McDonald, 2010 ; Reiter, 2010 ; Gatt et Krahmer, 2018 ; Bateman et Zock, 2022). Jusqu'aux années 1990, la tâche de génération de texte était abordée à l'aide d'une architecture modulaire (Reiter et Dale, 1997, 2000). Globalement, cette architecture découpe la tâche de génération en deux grandes étapes : ***quoi dire*** et ***comment le dire***. Ces deux étapes sont généralement elles-mêmes découpées en un nombre variable de sous-tâches, dépendant du degré de spécificité recherché, et chacune de ces sous-tâche est prise en charge par un module spécifique.

Une visualisation de cette architecture modulaire est présentée à la figure 2.2, tirée de Danlos (1985). L'architecture illustrée s'applique à un « dialogue » entre humain et machine mais il est applicable pour toute tâche de génération. La première étape, à savoir l'analyse (ici du message de l'utilisateur), est une étape uniquement nécessaire lorsque le système manipule des entrées qui ne sont pas dans un format directement interprétable par la machine (comme par exemple du texte). Ce n'est donc pas une étape de *génération* à proprement parler.

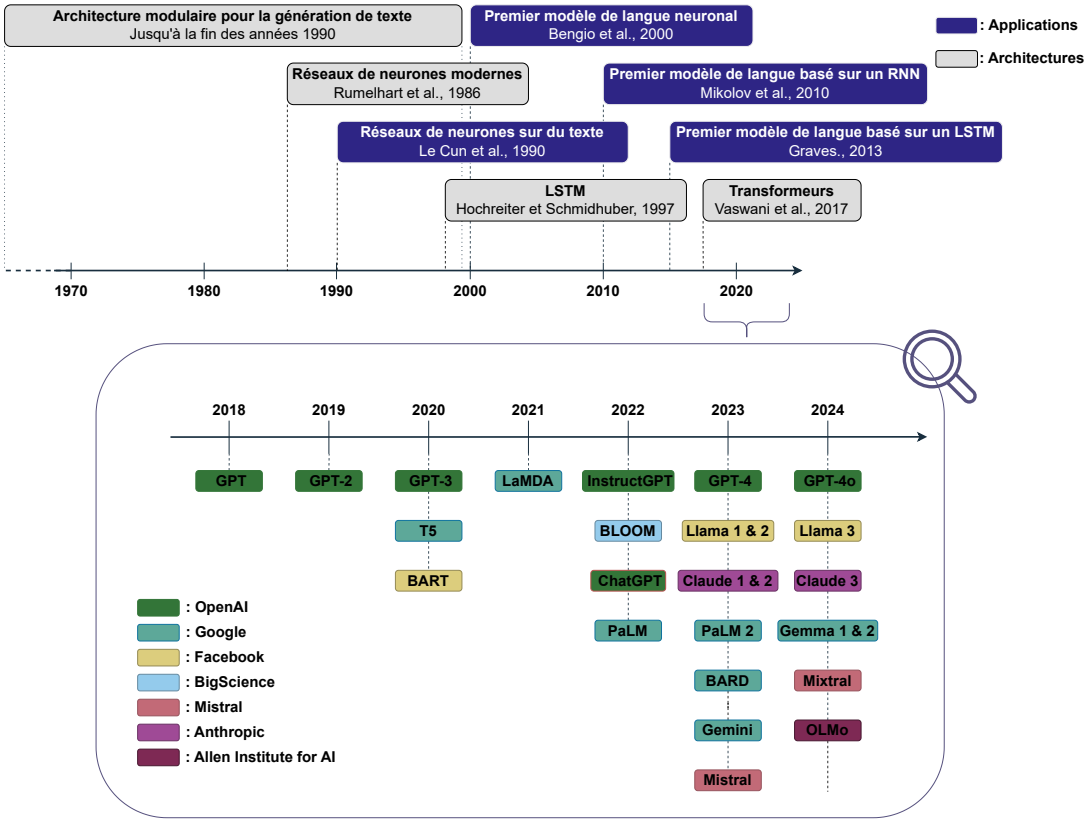


Figure 2.1 – Chronologie de l'évolution des méthodes de génération de texte et de la récente explosion des LLM.

Les deux étapes suivantes constituent réellement la tâche de génération. Le module de raisonnement correspond à la partie « **quoi dire** » et la génération automatique correspond à la partie « **comment le dire** ». De manière générale, la tâche de génération découpe ces deux étapes en trois composants :

- un *planificateur de texte*, correspondant au module de raisonnement qui produit le plan du texte à générer à partir de la représentation formelle de la requête à laquelle répondre (*quoi dire*) ;
- un *planificateur de phrases*, qui sélectionne la manière d'exprimer le résultat du planificateur de texte (*comment le dire*) ;
- un *réalisateur linguistique*, qui détermine la forme textuelle finale en appliquant des règles syntaxiques et morphologiques afin d'obtenir un texte grammaticalement correct.

Comme mentionné précédemment, il est possible de préciser davantage les sous-tâches de génération. On peut alors trouver jusqu'à six modules (Zock et Sabah, 1992 ; Gatt et Krahmer, 2018). Gatt et Krahmer (2018) étendent ces trois composants principaux en décomposant le planificateur de texte et le planificateur de phrases, le réalisateur

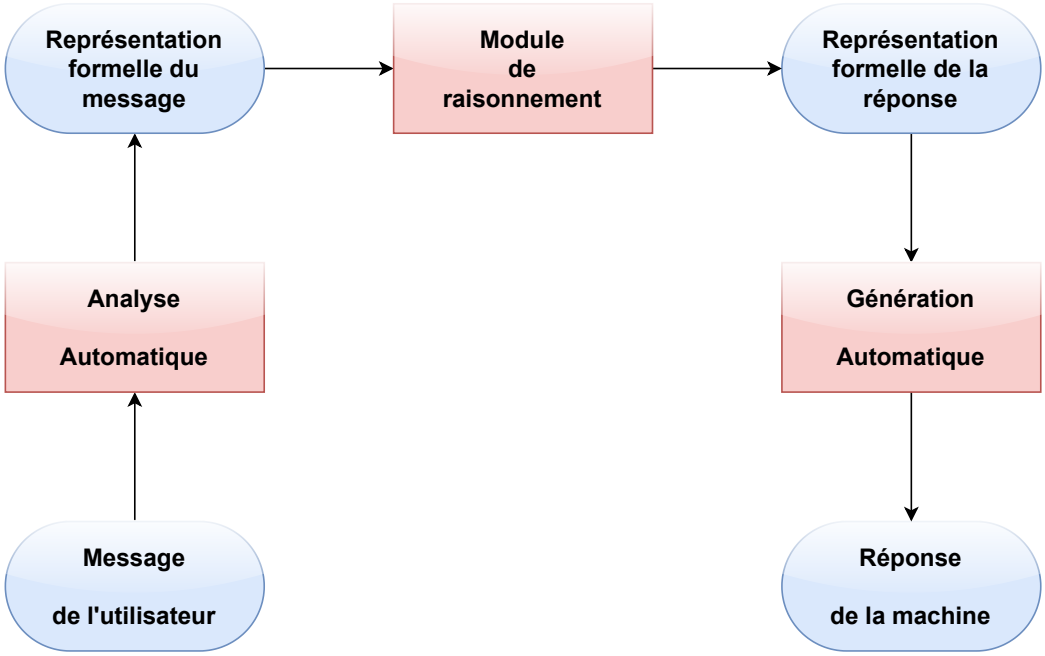


Figure 2.2 – Dialogue entre l'homme et la machine (Danlos, 1985).

linguistique représentant une tâche à part entière. Le planificateur de texte est décomposé en deux tâches :

- *détermination des contenus* : déterminer l'information à inclure dans le texte ;
- *élaboration du plan du texte* : déterminer l'ordre dans lequel l'information est présentée.

Le planificateur de phrases est quant à lui décomposé en trois tâches :

- *agrégation en phrases* : déterminer la manière d'exprimer l'information en la découpant en une ou plusieurs phrases ;
- *lexicalisation* : sélectionner les mots et expressions pour communiquer l'information ;
- *génération d'expressions référentielles* : en complément de la lexicalisation, s'assurer de la non ambiguïté référentielle des mots sélectionnés.

Que ce soit pour le fond ou pour la forme, les méthodes de génération symboliques s'appuient généralement sur des schémas, des arbres ou des graphes de connaissances plus ou moins complexes pour sélectionner d'une part, les concepts en jeu et la structure du discours et d'autre part, les mots et la syntaxe utilisés (Zock et Sabah, 1992). La figure 2.3 donne ainsi l'exemple d'un arbre permettant de choisir le mot correspondant au concept *« consommer »* selon la nature de l'objet consommé.

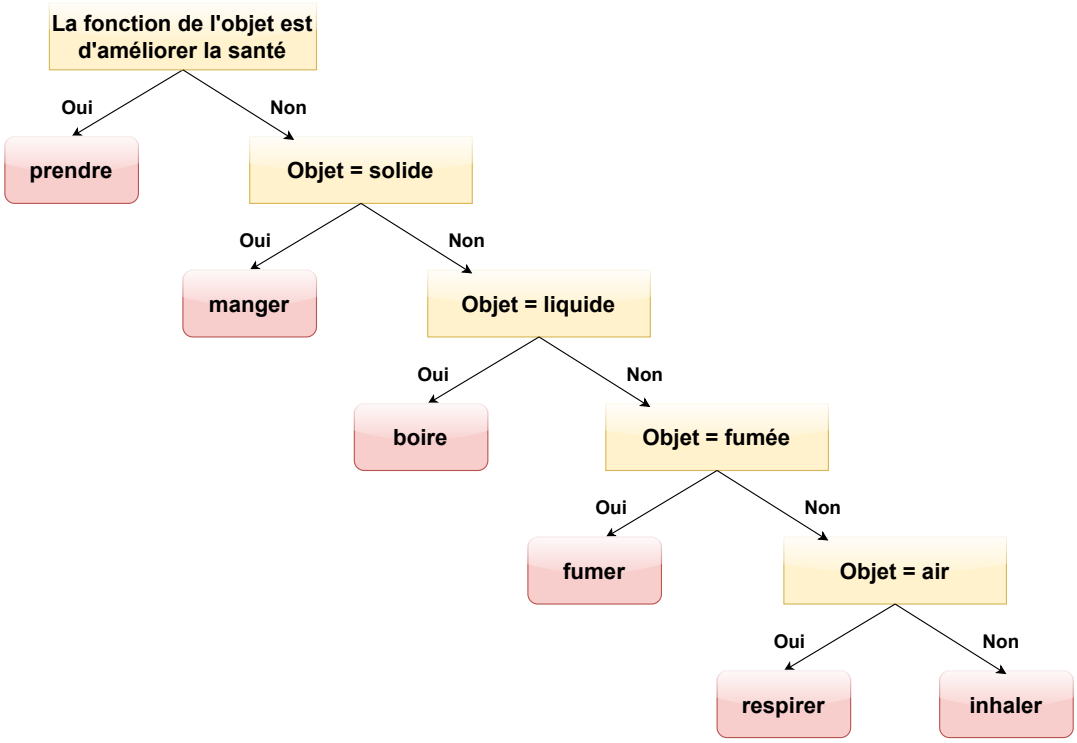


Figure 2.3 – Exemple d'arbre de discrimination pour sélectionner le mot à utiliser pour le concept « *consommer* » (exemple tiré de Zock et Sabah (1992)).

Les délimitations entre les tâches prises en charge par les différents modules décrits précédemment sont poreuses. Les méthodes symboliques pour la génération présentent une distinction claire entre toutes les tâches qui définissent la génération, de la détermination du contenu à générer à la manière dont ce contenu est exprimé. Elles permettent ainsi un contrôle précis sur chacune de ces étapes mais rendent la prise en compte des interactions entre les tâches difficile.

Ces méthodes peinent donc à assurer une cohérence textuelle lorsqu'il s'agit de générer des énoncés longs ou peu formatés. Les systèmes de génération par règles ont besoin de beaucoup de règles pour couvrir une large variété de cas, des règles trop générales pouvant facilement générer des textes incorrects. Par conséquent, les systèmes ciblent souvent des cas d'utilisation spécifiques et sont incapables de traiter correctement des cas d'utilisation hors de leur domaine (Danlos, 2000). Générer des textes dans un domaine spécifique demande déjà un nombre important de règles, qui peuvent nécessiter des connaissances du domaine pour maximiser la pertinence des réponses. Reiter *et al.* (2005) ont par exemple collaboré avec des experts en météorologie pour établir les règles de leur système de génération de bulletins météorologiques textuels.

Dans la partie suivante, nous nous intéressons aux méthodes statistiques permettant la génération de texte de bout en bout, ne faisant pas la distinction entre les phases de définition du contenu et d'expression du contenu. Ainsi, ces méthodes statistiques présentent des caractéristiques opposées à celles des architectures modulaires. Il est en effet

difficile de contrôler finement le contenu de ce qui est généré. En contrepartie, les textes produits ont une meilleure cohérence textuelle et paraissent plus naturels.

2.3 . Méthodes statistiques

Modèles de langue génératifs. La modélisation de la langue est une tâche de TAL qui consiste à apprendre un ensemble de caractéristiques de données textuelles (propriétés statistiques, structures, schémas) afin de faire des prédictions. Dans un contexte génératif, cette modélisation repose souvent sur une approche causale où le modèle est entraîné à prédire le mot suivant. L'objectif est d'estimer la probabilité qu'un mot suive une séquence de mots donnée. Plus formellement, on cherche à estimer la probabilité $P(y_n|y_1, y_2, ..., y_{n-1})$ où $y_1, y_2, ..., y_{n-1}$ est la séquence de mots et y_n le mot suivant. Les modèles entraînés avec cet objectif sont appelés modèles de langue causaux. D'autres types de modèles génératifs existent tels que les encodeurs-décodeurs, souvent utilisés pour des tâches de texte-vers-texte ou données-vers -texte, qui apprennent à transformer un texte en entrée en un texte de sortie en passant par une représentation intermédiaire.

Les modèles de langue génératifs doivent être entraînés sur une grande quantité de texte afin d'apprendre la distribution de probabilité des mots. En d'autres termes, il est nécessaire qu'un modèle soit entraîné sur une quantité importante d'occurrences d'un mot spécifique pour en apprendre les caractéristiques. Par conséquent, les capacités de modélisation des modèles de langue génératifs sont limitées aux corpus et aux langues sur lesquels ils sont entraînés.

Une fois entraînés, ces modèles sont capables de générer du texte à partir d'une entrée textuelle appelée « amorce » ou « invite » (*prompt*). Le processus de génération est itératif : le modèle prédit le mot suivant l'amorce, puis ce nouveau mot est concaténé à l'amorce afin de prédire le prochain mot. Le processus de génération s'arrête lorsque le modèle génère un token de fin de séquence ou bien lorsque la taille de séquence maximale est atteinte.

Pendant longtemps, l'entraînement des modèles de langue statistiques se fondait sur le comptage des n-grammes de mots pour estimer la probabilité des séquences de mots, bien que des approches fondées sur des arbres de décision (Potamianos et Jelinek, 1998) ou sur le principe d'entropie maximale (Rosenfeld, 1994) aient été proposées. Au début des années 2000, Bengio *et al.* (2003) proposent un modèle de langue neuronal qui remplace le comptage de mots par une tâche d'apprentissage, ouvrant une nouvelle ère menant aux LLM d'aujourd'hui. Nous détaillons maintenant ces deux approches.

2.3.1 . Modèles de langue à base de n-grammes

Les modèles de langue à base de n-grammes estiment la distribution de probabilités des mots du corpus sur lequel ils sont entraînés en utilisant les statistiques globales du corpus. La probabilité qu'un mot apparaisse après une séquence correspond simplement au nombre de fois où le mot est apparu après la séquence donnée dans le corpus, selon le principe de l'estimation du maximum de vraisemblance.

Les modèles de langue à base de n-grammes sont markoviens : la probabilité d'apparition d'un mot ne dépend que d'un nombre fixe de mots précédents. Plus précisément,

pour un modèle de langue à base de n-grammes, cette probabilité est estimée en examinant seulement les $n-1$ mots précédents. Combiné à des stratégies de lissage, cela permet au modèle de générer des séquences qui n'apparaissent pas nécessairement dans le corpus d'entraînement (Kneser et Ney, 1995).

2.3.2 . Modèles de langue neuronaux

Les progrès en génération automatique de texte connaissent une accélération avec la popularisation des réseaux de neurones, permise par l'augmentation de la puissance de calcul. Les approches neuronales proposent un nouveau paradigme pour la construction de modèles de langue : au lieu de compter les mots, les modèles apprennent une représentation vectorielle de ceux-ci.

Les modèles de langue neuronaux projettent les mots dans un espace vectoriel avec pour objectif d'obtenir des représentations vectorielles similaires pour des mots similaires. Pour cela, les représentations des mots sont calculées en supposant que des mots similaires apparaissent dans des contextes similaires (Harris, 1954). L'apprentissage de représentations précises nécessite donc de grands corpus de texte incluant des contextes variés. Le fait de manipuler des représentations plutôt que de compter des mots donne aux modèles de langue neuronaux de meilleures capacités de généralisation. Cette approche fut principalement étudiée après les travaux fondateurs de Bengio *et al.* (2003) sur les réseaux de neurones à propagation avant (*Feed Forward Neural Networks*).

Comme décrit précédemment, les modèles de langue génératifs sont entraînés sur la tâche de prédiction du mot suivant. Cela signifie que ces modèles sont entraînés de manière auto-régressive. Tout d'abord, la séquence d'entraînement est découpée en sous-unités appelés tokens. Le modèle commence par prendre le premier token de la séquence en entrée pour prédire le deuxième token. Les poids du modèle sont ensuite mis à jour en fonction de la prédiction. Puis, le véritable deuxième token est ajouté à l'entrée du modèle, qui compte désormais les deux premiers tokens. Le processus est répété jusqu'à la fin de la séquence.

Nous décrivons maintenant les deux principales architectures de réseaux de neurones qui ont été successivement utilisées pour entraîner des modèles de langue neuronaux après Bengio *et al.* (2003).

Réseaux de neurones récurrents L'architecture des réseaux de neurones récurrents (Rumelhart *et al.*, 1986, RNN) est la première à inclure le principe de récurrence en gardant une trace du contexte précédent. Pour cela, une partie de l'architecture est dédiée à un « état caché », une représentation vectorielle du contexte précédent. À chaque étape de génération (c'est-à-dire à chaque token généré), la représentation vectorielle du nouveau token est ajoutée à l'état caché afin que le nouveau contexte prenne en compte le nouveau token.

L'état caché est un vecteur de taille fixe. Par conséquent, la quantité d'informations pouvant être contenue est limitée. Les représentations des tokens récemment générés réduisent progressivement l'impact des tokens plus « anciens » de la séquence au fur et à mesure que le modèle génère du texte. De ce fait, la capacité des RNN à prendre en compte le contexte est limitée.

Deux variations de réseaux de neurones récurrents ont été proposées pour pallier les limitations des RNN : les *Long Short-Term Memory* (Hochreiter et Schmidhuber, 1997, LSTM) et les *Gated Recurrent Unit* (Cho *et al.*, 2014, GRU). Ces deux types de réseaux utilisent des neurones additionnels pour sélectionner les informations importantes dans le contexte et ainsi réduire la saturation d'informations dans l'état caché. Cela permet aux LSTM et aux GRU de conserver une trace du contexte pendant une période plus longue que les RNN standards.

Les RNN et leurs variantes traitent le texte de manière séquentielle. Cela signifie qu'il est nécessaire d'avoir traité le token à la position i avant de pouvoir traiter le token à la position i_{+1}. Cela crée un effet d'embouteillage lors de l'entraînement des modèles, limitant grandement les possibilités de parallélisation des calculs.

Transformeurs L'architecture transformeur (Vaswani *et al.*, 2017) utilise le mécanisme d'attention pour résoudre ce problème d'embouteillage. L'attention permet en effet de traiter parallèlement tous les tokens d'une séquence en prenant en compte le contexte qui précède et qui suit chaque token. Cela permet d'exploiter la capacité des GPU à effectuer des calculs parallèles et ainsi traiter de très grandes quantités de données de manière plus optimale que les réseaux de neurones récurrents.

L'architecture transformeur est composée de deux parties : un encodeur et un décodeur. L'encodeur transforme l'entrée en représentation vectorielle tandis que le décodeur prédit récursivement une séquence d'éléments à partir de la représentation vectorielle calculée par l'encodeur.

Pour générer du texte, il est possible d'utiliser soit l'architecture complète, qu'on appellera *encodeur-décodeur*, ou bien seulement la partie *décodeur* de l'architecture. Ces deux architectures obtiennent aujourd'hui les résultats à l'état de l'art pour la plupart des tâches de génération en TAL. L'architecture encodeur-décodeur était initialement préférée pour les tâches de séquence-à-séquence, où une bonne représentation vectorielle de l'entrée est nécessaire. On peut citer le résumé automatique ou les tâches de génération données-vers-texte. Toutefois, l'entraînement de modèles utilisant seulement un décodeur est nettement moins coûteux au niveau computationnel.

La plupart des modèles de langue à base de transformeurs sont pré-entraînés sur des tâches prétextes. Ces tâches ne représentent pas l'application finale du modèle mais sont conçues pour faciliter l'apprentissage des représentations des données par le modèle. Afin d'apprendre de bonnes représentations des textes, les encodeurs tels que BERT (Devlin *et al.*, 2019) étaient à l'origine principalement entraînés sur des tâches de démasquage de mots, où l'objectif est de prédire un ou plusieurs des tokens du texte ayant été masqués au modèle. Toutefois, la popularité croissante des architectures décodeur a entraîné une utilisation accrue de la tâche de prédiction du mot suivant comme seule tâche d'entraînement pour beaucoup de modèles de génération.

Cette capacité à entraîner des modèles de langue sur d'énormes quantités de données a conduit à une augmentation de la taille des modèles pré-entraînés et à l'amélioration de la qualité des textes générés. Les modèles GPT-2 et GPT-3 ont successivement montré la capacité des grands modèles de langue à atteindre l'état de l'art dans plusieurs tâches de TAL sans supervision explicite pour ces dernières (Radford *et al.*, 2019 ; Brown *et al.*,

2020). Depuis, de nombreux travaux visent à rendre les LLM plus contrôlables. Enfin, la publication de ChatGPT en 2022 a marqué l'accès des LLM au grand public.

2.4 . Processus de génération des modèles statistiques

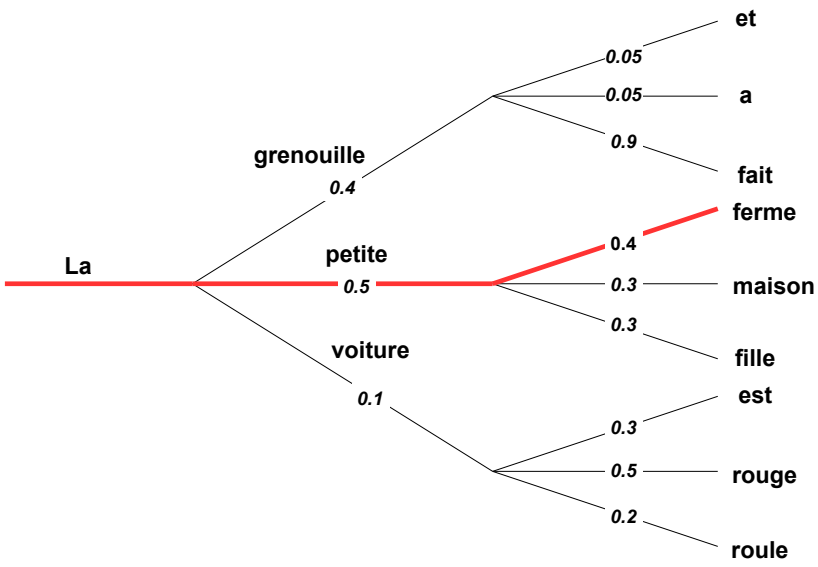
Quelle que soit la taille des LLM, leurs architectures sont toujours fondées sur l'architecture transformeur (bien qu'elles puissent-être optimisées). Par conséquent, le processus de génération des modèles fondés sur les transformeurs reste le même, quel que soit le modèle de langue.

Comme mentionné précédemment, le processus de génération consiste à générer les *tokens* un à un à la suite de l'amorce ou de la séquence générée précédemment (on appellera la génération d'un token une *étape de génération*). Une étape de génération peut être divisée en deux parties. Premièrement, le modèle associe un score à chaque token du vocabulaire. Ces scores représentent pour chaque token la probabilité que ce dernier suive l'amorce. Cela correspond à la sortie brute du modèle. La deuxième partie consiste à choisir le token à générer en fonction des probabilités calculées. Cette étape s'appelle le décodage et s'apparente à une exploration d'arbre car il est trop coûteux d'explorer toutes les suites possibles. À chaque étape, choisir le token à générer parmi le vocabulaire équivaut à choisir la branche de l'arbre à explorer.

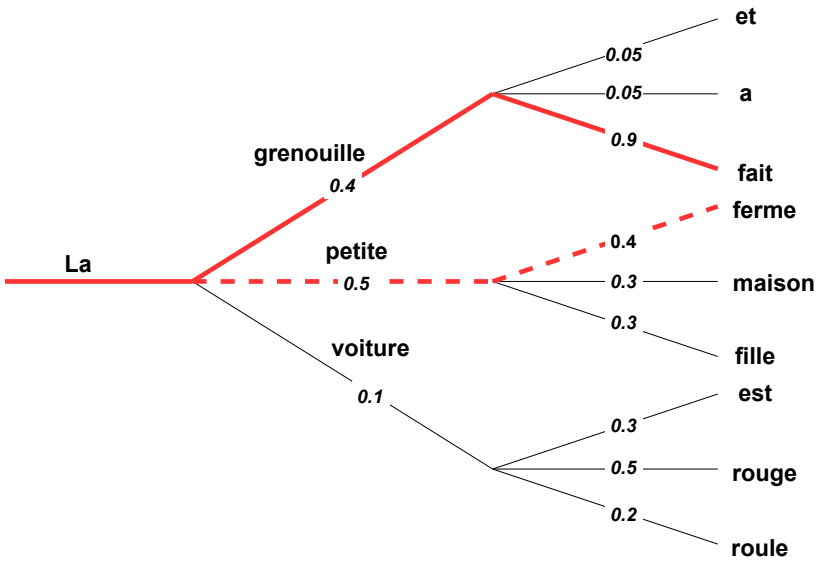
La figure 2.4 illustre un arbre de probabilité pour la génération d'un début de séquence. À la figure 2.4a, on observe la séquence conservée lorsque l'on effectue une recherche « gloutonne » (*greedy search*). À chaque étape, la recherche gloutonne sélectionne la branche avec la probabilité maximale et les autres branches sont abandonnées. Cette recherche est très économique car un seul chemin est parcouru, mais cela constitue également sa faiblesse.

La recherche en faisceaux (*beam search*) améliore cette recherche en parcourant plusieurs séquences candidates (correspondant au nombre de faisceaux). Cette fois-ci, c'est le score global de la séquence qui est pris en compte pour savoir quels chemins conserver. Un exemple est présenté à la figure 2.4b avec une recherche en faisceaux avec deux faisceaux. Dans cet exemple, deux séquences sont parcourues. La séquence ayant successivement les maxima locaux « La petite ferme » a pour probabilité globale $0,5 * 0,4 = 0,2$, tandis que la séquence « La grenouille fait », abandonnée en recherche gloutonne, a une probabilité globale plus élevée avec $0,4 * 0,9 = 0,36$. La recherche en faisceaux permet donc de conserver quelques séquences prometteuses.

En se basant sur la sélection de branches pour maximiser le score de probabilité, la recherche gloutonne et la recherche en faisceaux rendent le processus de génération déterministe. Cependant, il a été observé que la génération de texte avec ce type de décodage produisait des textes monotones et incohérents et que les textes obtenus pouvaient se perdre dans des boucles de répétitions (Holtzman *et al.*, 2020). C'est pourquoi des stratégies d'échantillonnage ont été explorées.



(a) Avec une recherche gloutonne.



(b) Recherche avec 2 faisceaux.

Figure 2.4 – Illustration du processus de génération de texte comme une exploration d'arbre.

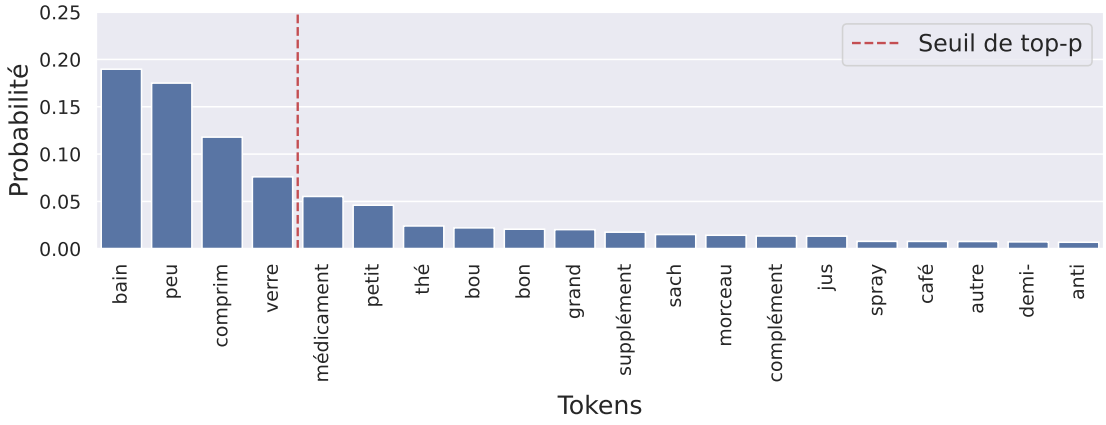
Échantillonnage L'échantillonnage en génération fait référence au processus de sélection d'un token parmi plusieurs tokens possibles, conditionné par les probabilités (scores) associées aux tokens.

Échantillonner parmi l'intégralité du vocabulaire n'est pas optimal puisque cela impliquerait de considérer les tokens avec une probabilité très faible. C'est pourquoi les stratégies d'échantillonnage cherchent à sélectionner des tokens parmi les options les plus probables. L'objectif de ces stratégies est de trouver des formes de compromis entre le guidage par les probabilités issues du modèle de langue et une certaine forme de créativité permise en considérant des solutions moins probables.

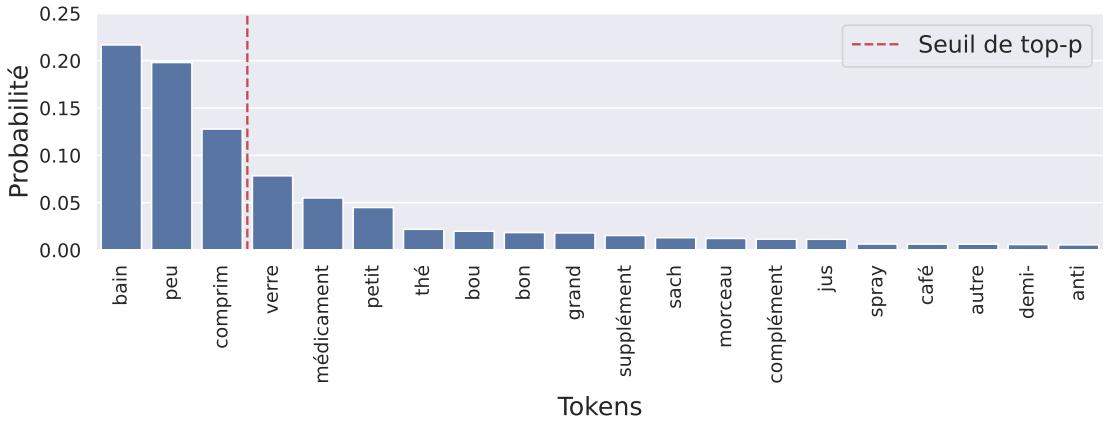
Les stratégies d'échantillonnage les plus populaires sont les échantillonnages *top-k* et *top-p* (Holtzman *et al.*, 2020, *nucleus sampling*). Ces deux stratégies visent à se débarrasser de la queue de la distribution avant d'échantillonner parmi les tokens restants. *Top-k* réalise l'échantillonnage parmi les k tokens les plus probables tandis que *top-p* réalise l'échantillonnage parmi un nombre variable de tokens, de sorte que la somme de leurs probabilités atteigne la valeur p. Bien que différentes, toutes les stratégies d'échantillonnage finissent par couper la queue de la distribution arbitrairement malgré le fait que les tokens suivants dans la distribution puissent être acceptables ou bien que les tokens précédents dans la distribution puissent ne pas l'être.

Illustration du processus d'échantillonnage. La figure 2.5 présente les effets de l'échantillonnage et de la température sur la distribution de probabilité des 20 tokens les plus probables pour le prompt *« Pour soulager la fièvre, prenez un »*, avec le modèle BLOOM-560m.

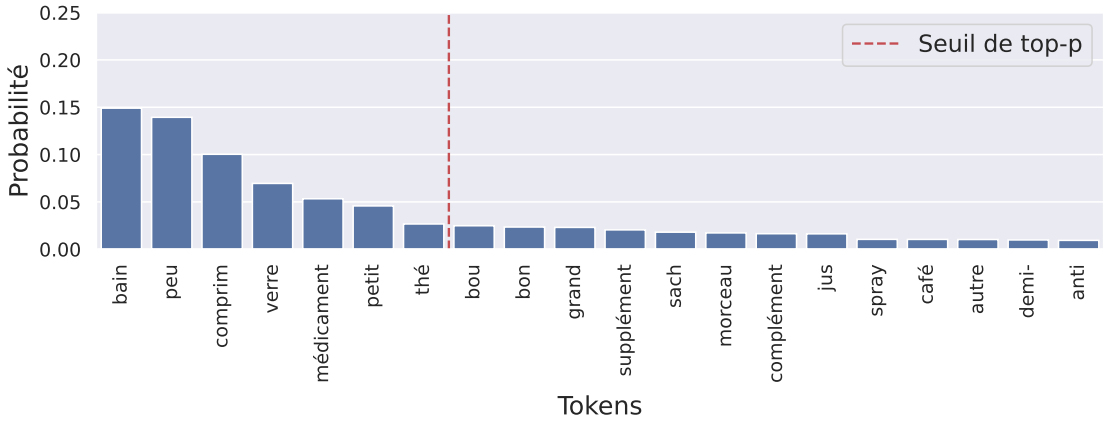
À la figure 2.5a, la distribution est représentée sans être affectée par un changement de température. La ligne pointillée rouge représente le palier du *top-p* : seuls les tokens situés à gauche de la ligne sont considérés lors de l'échantillonnage. Modifier la température a deux effets. Premièrement, cela accentue ou aplanit la distribution. Les tokens les plus probables le deviennent encore plus lorsque la température diminue (cf. figure 2.5b), tandis que toutes les probabilités se rapprochent lorsque la température augmente (cf. figure 2.5c). Deuxièmement, le nombre de tokens considérés lors de l'échantillonnage varie avec l'utilisation de *top-p*. Le choix des paramètres de décodage est généralement optimisé en fonction d'une tâche, d'un jeu de données ou pour un objectif spécifique (par exemple, favoriser la diversité). Cependant ces paramètres ne sont pas nécessairement adaptés à toutes les situations possibles. Sur les tokens proposés par le modèle à la figure 2.5, le token le plus probable, *bain*, n'est pas forcément le plus pertinent. L'ordre des probabilités ne correspond donc pas à l'ordre de pertinence. Choisir une température plus faible présente donc le risque de ne pas prendre en compte certains tokens pertinents tandis qu'une température plus élevée risque d'inclure plus de tokens non pertinents. Étant donné le nombre potentiellement infini de situations pouvant être rencontrées par le modèle, trouver le bon compromis est loin d'être trivial.



(a) Température = 1 (distribution inchangée).



(b) Température = 0.9.



(c) Température = 1.2.

Figure 2.5 – Probabilités attribuées au 20 premiers tokens pour l'amorce : *« Pour soulager la fièvre, prenez un »* avec le modèle BLOOM-560m, un top-p de 0,6 et différentes températures.

2.5 . Contrôle de la génération dans les modèles statistiques

Les modèles actuels de génération de texte sont capables de produire des textes difficiles à différencier de textes écrits par des humains dans certaines langues (Casal et Kessler, 2023). Toutefois, le texte généré par un modèle de langue peut ne pas être pertinent, être offensant, voire même être dangereux. Leur entraînement auto-supervisé sur une énorme quantité de données récupérées sur le web permet certes d'obtenir des performances à l'état de l'art en génération de texte mais conduit aussi à toutes sortes de biais (Bender *et al.*, 2021).

En outre, si les performances des modèles de langue génératifs pré-entraînés sont impressionnantes sur le domaine général, leurs performances ne sont pas forcément à la hauteur dans des domaines spécialisés. C'est pourquoi pouvoir contrôler finement la sortie des modèles de génération suscite beaucoup d'intérêt.

Dans cette partie, nous passons en revue les différentes méthodes permettant de contrôler les modèles de génération de texte. Les méthodes présentées visent à guider la génération vers des textes d'un genre particulier (par exemple, des cas cliniques), un domaine particulier (par exemple, l'oncologie), une tâche particulière (par exemple, résumer un texte en entrée) ou utilisant un vocabulaire spécifique. La granularité du contrôle peut donc varier. Les méthodes de contrôle se divisent en deux catégories : le contrôle par l'entraînement et la génération coopérative.

2.5.1 . Contrôle par l'entraînement

La première catégorie de méthodes visant à contrôler les modèles de génération de texte consiste à construire des modèles (ou rendre des modèles existants) directement capables de suivre un conditionnement donné en entrée. Une fois le modèle entraîné, il suffit donc d'inclure le conditionnement dans l'amorce (*prompt*) pour que le texte généré suive ce conditionnement.

Les modèles de langue conditionnés par des classes (CCLM - *Class-conditional language model*) (Keskar *et al.*, 2019) sont entraînés sur des textes associés à des codes de contrôle choisis selon des classes prédéfinies. Ces classes représentent des caractéristiques globales des textes, comme le genre ou la polarité. Il est ainsi possible de générer des textes appartenant à une classe en utilisant le code de contrôle correspondant en amorce. Les codes de contrôle peuvent même être combinés pour obtenir un texte appartenant à plusieurs classes, par exemple pour générer une critique de film (genre) positive (polarité).

L'entraînement d'instructions (*instruction tuning*) est un processus utilisé pour améliorer la capacité des LLM à suivre des instructions. Pour cela, le modèle est affiné sur un jeu de données d'instructions où chaque exemple est une instruction (ou amorce) rédigée par un humain et associée à une réponse (Ouyang *et al.*, 2022). Cette phase d'entraînement supplémentaire permet d'obtenir des modèles plus performants pour suivre des instructions humaines données en amorce. Beaucoup de modèles distribués de nos jours comportent d'ailleurs des versions pré-affinées sur des corpus d'instructions (comme par exemple Llama-3 (AI@Meta, 2024) ou Mixtral (Jiang *et al.*, 2024)).

Stratégies d'affinage. Le très grand nombre de paramètres des LLM rend leur affinage complet très coûteux en temps et en ressources. Les méthodes d'affinage efficaces (Lester *et al.*, 2021 ; Li et Liang, 2021 ; Hu *et al.*, 2022) visent à limiter le coût d'affinage en gelant les poids du modèle et en ajoutant une petite quantité de poids entraînables durant l'affinage. Ces nouveaux poids sont ensuite utilisés avec le reste du modèle lors de l'inférence. L'affinage efficace facilite l'adaptation des LLM à d'autres domaines, tâches ou langues.

2.5.2 . Contrôle à l'inférence : la génération coopérative

La seconde catégorie de méthodes pour contrôler les modèles de génération consiste cette fois-ci à guider un modèle de génération existant vers le conditionnement souhaité lors de l'inférence. Cela permet ainsi de ne pas entraîner un modèle à partir de zéro et de ne pas affiner des modèles pouvant être très grands.

La génération coopérative nécessite un ou plusieurs modèles en complément du modèle de génération. Ces modèles additionnels, appelés « discriminateurs », guident le modèle de génération vers la sortie souhaitée. Les discriminateurs peuvent influer directement des couches cachées du modèle génératif (Dathathri *et al.*, 2020) mais agissent plus couramment sur les scores de sortie du modèle. On parle alors de décodage pondéré (*weighted decoding*). Les discriminateurs peuvent être n'importe quel type de modèle, comme des classifieurs (Yang et Klein, 2021) ou d'autres modèles génératifs (Liu *et al.*, 2021 ; Krause *et al.*, 2021). Un exemple de décodage pondéré est illustré par la figure 2.6. Étant donné une amorce, le modèle génératif donne des scores à tous les tokens du vocabulaire et ces scores sont augmentés ou diminués selon le discriminateur choisi.

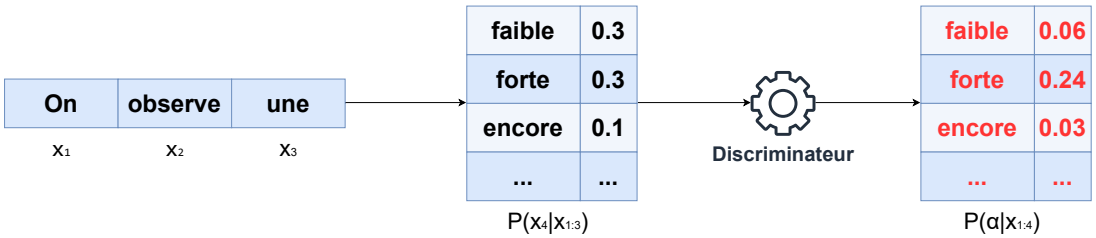


Figure 2.6 – Schéma du guidage de la génération de texte avec un décodage pondéré par un discriminateur en fonction d'une condition α.

Stratégies de décodage Nous avons présenté à la section 2.4 le processus de décodage comme une problématique d'exploration d'arbre. Les stratégies d'exploration d'arbre, telles que la *recherche arborescente Monte-Carlo* ou la *recherche A**, peuvent être couplées à des discriminateurs pour que la recherche ne maximise pas simplement la probabilité de la chaîne générée mais également le respect d'une ou plusieurs contraintes (Chaffin *et al.*, 2022 ; Lu *et al.*, 2022a).

Conception d'amorces. Depuis GPT-3, les LLM sont évalués pour leur capacité à s'adapter à de nouvelles tâches à partir de peu d'exemples (*few-shot*) voire d'aucun exemple (*zero-shot*). Plusieurs études s'intéressent à l'optimisation d'amorces. Par exemple, la « chaîne de pensée » (Wei *et al.*, 2024, *chain-of-thought*) est une méthode où l'amorce demande explicitement de décomposer la tâche en plusieurs sous-étapes à accomplir pour arriver au résultat final. Une autre approche, l'auto-vérification (Weng *et al.*, 2023, *self-verification*) implique une seconde phase où l'amorce cherche à faire évaluer au modèle sa propre réponse. L'auto-vérification souligne le caractère imprévisible des LLM, puisqu'ils sont capables de générer des textes inexacts tout en étant capables de détecter leurs propres inexactitudes (Lee *et al.*, 2023).

Les méthodes de contrôle de la génération, quelles soient à l'entraînement ou coopératives, nécessitent des données annotées pour pouvoir soit entraîner (ou affiner) le modèle vers une version contrôlable, soit entraîner les discriminateurs permettant de guider les modèles.

2.5.3 . Limites des modèles de langue génératifs

Les modèles de langue génératifs présentent d'importantes limites malgré le fait qu'ils obtiennent des performances à l'état de l'art sur de nombreuses tâches de TAL.

Tout d'abord, il est difficile de contrôler les informations données au modèle à cause de l'immense quantité de données requise pour les entraîner (Kreutzer *et al.*, 2022). Cela renforce en outre le déséquilibre déjà existant pour les langues disposant de moins de ressources disponibles. Ensuite, la nature opaque des réseaux de neurones peut rendre l'interprétation de leurs résultats difficile (Zhang *et al.*, 2021). Enfin, le processus de génération repose sur de l'échantillonnage et n'est donc pas déterministe. Cela signifie qu'une même amorce peut conduire à la génération de textes différents sans qu'aucun paramètre ne soit modifié. Nous présentons dans cette partie comment ces limites inhérentes aux modèles se matérialisent dans la génération de texte.

Biais. Cinq sources de biais affectant les LLM ont été identifiées : les données, le processus d'annotation, la représentation de l'entrée, les modèles et la conception de la recherche, c'est-à-dire les choix méthodologiques et expérimentaux (Hovy et Prabhumoye, 2021). Une énorme quantité de données est récupérée de diverses sources sur internet pour répondre aux besoins des LLM en données d'entraînement. Cela signifie que (i) vérifier chaque source est une tâche colossale, rarement réalisée de manière approfondie et (ii) malgré la taille des corpus, ils ne représentent qu'un sous-ensemble de langues et de locuteurs. Pendant leur entraînement, les modèles peuvent être confrontés à des informations inexactes, de la désinformation, des discours haineux ou d'autres contenus indésirables. De plus, la nature même des réseaux de neurones vise à condenser l'information à des fins de généralisation. Les populations ou points de vue sous-représentés sont donc marginalisés davantage tandis que les stéréotypes sont accentués (Bender *et al.*, 2021). Ainsi, les LLM présentent de nombreux types de biais, les biais de genre (Buolamwini et Gebru, 2018 ; Ducel *et al.*, 2023 ; Wan *et al.*, 2023 ; Ducel *et al.*, 2024) et les biais racistes (Obermeyer *et al.*, 2019) étant les plus étudiés (Zack *et al.*, 2024). De tels biais existent dans le domaine biomédical et les LLM les amplifient (Chen *et al.*, 2021a). Pour limiter ces risques,

les développeurs des LLM ajoutent des mécanismes d'alignement ainsi que des filtres bloquant certaines générations biaisées ou dangereuses. Toutefois, ces mesures n'interviennent souvent qu'après que les générations dangereuses soient identifiées, si elles le sont.

Génération de texte inexact. Les modèles de langue génératifs ne sont pas toujours performants quand il s'agit de générer du texte dans un but ou un domaine spécifique. Cette limite peut prendre plusieurs formes : le texte peut être incohérent, non pertinent, ne pas inclure certaines informations importantes ou bien contenir des affirmations factuellement fausses. Le terme « hallucination » était à l'origine utilisé pour des tâches de texte-vers-texte ou de données-vers-texte pour désigner le fait que le texte généré inclut des informations non contenues dans l'entrée (Wang et Sennrich, 2020 ; Zhou *et al.*, 2021 ; Guerreiro *et al.*, 2023). Dans ce contexte, une hallucination peut être factuellement correcte ou incorrecte. Cependant, les travaux actuels sur les hallucinations (Sahoo *et al.*, 2024) mettent plutôt l'accent sur l'exactitude sémantique et factuelle de la génération. Nous pensons toutefois que le terme est quelquefois utilisé de manière abusive pour désigner n'importe quel type d'erreur de génération. De plus, le terme « hallucination » suggère à tort qu'il s'agit d'un fonctionnement anormal du modèle alors qu'il n'y a pas de différence fondamentale dans le processus de génération. Le terme relève d'ailleurs de l'anthropomorphisme puisqu'il est habituellement utilisé pour désigner une perception humaine.

Outre la génération de texte inexact, l'objectif d'entraînement des LLM pousse la génération vers des suites plausibles relativement à une amorce sans se soucier de sa pertinence : la réponse doit *sembler* plausible. Si l'amorce est dans une langue ou sur un domaine sur lequel le modèle n'a pas beaucoup été entraîné, la réponse générée risque d'être grossière, facilement perceptible comme telle par un locuteur natif ou par un expert mais pas nécessairement par un non initié (Alavoine *et al.*, 2024).

Mémorisation. Malgré les capacités de généralisation des réseaux de neurones, plusieurs études ont montré que les modèles génératifs mémorisent une partie de leurs données d'entraînement (Carlini *et al.*, 2023 ; Zhang *et al.*, 2023 ; Nasr *et al.*, 2023). La récupération à grande échelle de corpus d'entraînement sur internet peut inclure des informations sensibles ou protégées par des droits d'auteur. Outre les problèmes de confidentialité et de droits d'auteurs que posent l'entraînement et la distribution de modèles entraînés sur ces données, la mémorisation peut permettre l'extraction de ces informations, intentionnellement ou non. Toutefois, la mémorisation est difficile à quantifier à cause de la taille des corpus d'entraînement et du fait que ces corpus ne sont pas toujours publiquement disponibles.

Sensibilité au prompt. Nous avons présenté dans la partie 2.5.1 la possibilité d'améliorer les performances des modèles génératifs avec des stratégies d'amorçage. Cependant, la performance dépend de plusieurs paramètres (combien d'exemples sont donnés au modèle, dans quel ordre…), y compris des éléments très spécifiques et difficilement

interprétables (formulation du problème, choix du vocabulaire...) (Lu *et al.*, 2022b ; Min *et al.*, 2022). Cette sensibilité rend les résultats parfois imprévisibles et l'optimisation des amorces repose souvent sur des tests empiriques réalisés avec des modèles et/ou jeux de données spécifiques, sans réelle justification scientifique.

2.6 . Évaluation de texte généré

L'évaluation de la qualité des textes générés est complexe. Il n'y a quasiment jamais une seule réponse possible à une requête donnée, que la génération soit contrainte ou ouverte. Une multitude de formes possibles peuvent constituer une réponse valide. C'est pourquoi un nombre important de métriques automatiques ont été proposées (Frisoni *et al.*, 2022) et ce, jusqu'à récemment (Pillutla *et al.*, 2021). Une bonne évaluation automatique d'un modèle de génération requiert *a minima* une combinaison de plusieurs métriques automatiques couvrant différents aspects qualitatifs (Gehrmann *et al.*, 2023). La meilleure méthode d'évaluation de la qualité de textes générés reste l'évaluation manuelle. Cependant, celle-ci présente également un certain nombre de difficultés (Howcroft *et al.*, 2020).

Nous présentons dans cette partie les différentes métriques d'évaluation automatique de la génération de texte ainsi que les difficultés soulevées par l'évaluation manuelle.

2.6.1 . Métriques automatiques fondées sur des références

Pour beaucoup de tâches de génération de texte, le but est de générer un texte à partir de données structurées ou d'un texte existant (par exemple, en traduction ou en résumé automatique). On peut donc avoir une idée du type de réponse que l'on attend du modèle, bien qu'il n'y ait que très rarement une seule réponse satisfaisante. De nombreuses métriques d'évaluation en génération de texte comparent le texte candidat généré avec une référence rédigée par un humain. Plusieurs références peuvent être fournies pour couvrir plusieurs possibilités.

Les métriques de distance d'édition comptent le nombre de substitutions, d'insertions et de suppressions requises pour passer du texte candidat à la référence. Ces métriques peuvent fonctionner à l'échelle des caractères, comme la distance de Levenshtein (Levenshtein, 1966), ou à l'échelle des mots, comme le taux d'erreur de mots (*Word Error Rate*, WER) (Su *et al.*, 1992)[1]. Pour la génération de texte, il est plus commun de s'intéresser à l'échelle des mots.

Les métriques de recouvrement mesurent le nombre de sous-chaînes communes au candidat et à la référence. Ces métriques peuvent se fonder sur le chevauchement de caractères (chrf (Popović, 2015, 2017), de mots (BLEU (Papineni *et al.*, 2002), ROUGE (Lin, 2004) ou même de n-grammes de mots (BLEU 2/3/4, ROUGE-L). Certaines métriques utilisent la racinisation et des synonymes pour plus de robustesse (METEOR (Banerjee et Lavie, 2005)).

1. La distance de Levenshtein peut également être utilisée à l'échelle des mots

Les métriques à base de plongements ont été créées pour pallier la trop grande dépendance des métriques vis-à-vis de la forme de surface des énoncés. Pour cela, les plongements lexicaux du candidat et de la référence sont calculés, puis la similarité entre les plongements est mesurée après un alignement lexical, c'est-à-dire une mise en correspondance des mots des deux textes. Des métriques ont été proposées avec des plongements statiques (WMD (Kusner *et al.*, 2015)), puis contextuels (BERTScore (Zhang* *et al.*, 2020)).

Les métriques de prédiction de scores traitent la tâche d'évaluation comme une tâche de classification en essayant de prédire un score à partir d'une paire candidat / référence. La métrique prend donc la forme d'un modèle qui doit être entraîné sur un jeu de données contenant des paires de phrases associées à des scores. L'exemple le plus populaire est BLEURT (Sellam *et al.*, 2020).

Les métriques fondées sur des références prennent uniquement en compte la proximité entre un texte candidat et un ou plusieurs textes de référence. Elles ne mesurent donc pas directement la qualité intrinsèque des textes générés. En outre, certaines tâches de génération ouverte ne peuvent pas avoir de références auxquelles comparer les textes générés.

2.6.2 . Métriques sans référence

Les métriques sans référence se concentrent sur la qualité intrinsèque des textes générés. Plusieurs critères différents peuvent être utilisés pour déterminer celle-ci comme la grammaticalité, la conformité, la cohérence, la diversité et l'utilité.

Il est difficile d'agréger tous ces critères dans une seule et même métrique. Un texte généré peut être parfaitement conforme sans pour autant être cohérent ou bien être utile sans être conforme. En d'autres termes, la qualité intrinsèque des textes générés est multidimensionnelle. Par conséquent, une évaluation complète de la qualité intrinsèque d'un texte doit viser à couvrir autant de dimensions que possible, afin de bien rendre compte des forces et des faiblesses d'un système de génération.

Diversité. Self-BLEU (Zhu *et al.*, 2018) est une métrique conçue pour évaluer la diversité au niveau du corpus. Le Self-BLEU consiste à calculer la moyenne des scores BLEU entre tous les documents du corpus. Puisque la métrique BLEU mesure le recouvrement entre deux textes, Self-BLEU évalue globalement le degré de similarité des documents d'un corpus entre eux. La diversité calculée par Self-BLEU est uniquement lexicale puisque BLEU se fonde sur un recouvrement lexical. Un Self-BLEU élevé signifie que les documents d'un corpus sont similaires entre eux, indiquant donc un manque de diversité lexicale dans le corpus.

Conformité. La métrique appelée *perplexité* évalue l'adéquation des données textuelles avec la distribution de probabilité d'un modèle de langue. Le modèle de langue utilisé doit donc être considéré comme performant dans la langue et le domaine du texte évalué, ce qui doit également avoir été évalué. La perplexité est souvent définie comme

le niveau de « surprise » d'un modèle de langue en regardant des données spécifiques. Plus le modèle est « surpris », plus le texte est éloigné de la distribution connue par le modèle de langue.

Utilité. Lorsque la génération de texte est orientée vers une tâche précise, l'utilité des textes générés est probablement le critère de qualité le plus important. Les métriques précédentes ne reflètent pas l'impact potentiel de l'utilisation des textes générés. Généralement, l'évaluation automatique de l'utilité des textes est réalisée en entraînant des modèles de TAL sur le texte généré pour comparer la performance de ces modèles avec des modèles similaires entraînés sur des textes réels. Ce type d'évaluation est aussi appelée « évaluation extrinsèque ». L'utilisation de textes générés pour une tâche sur laquelle ils n'ont pas été explicitement évalués doit être faite avec prudence car ces textes générés ne sont pas nécessairement adaptés à toutes les tâches.

L'évaluation automatique fournit des informations importantes sur la qualité des textes générés à grande échelle. Toutefois, les métriques automatiques ne sont pas suffisantes pour saisir les subtilités et nuances de la qualité intrinsèque des textes.

2.6.3 . Évaluation manuelle

L'évaluation manuelle est une bonne solution pour évaluer la qualité de textes générés automatiquement. Elle peut être plus variée, créative et cibler des critères spécifiques non couverts par les métriques automatiques (van der Lee *et al.*, 2021 ; Khashabi *et al.*, 2022). Néanmoins, l'évaluation manuelle implique un certain nombre de défis. Faire évaluer des textes par des humains est coûteux. Les textes à évaluer peuvent être longs et repérer les erreurs peut demander une certaine concentration. Thomson et Reiter (2021) ont mesuré que les annotateurs mettaient en moyenne 20 à 30 minutes pour évaluer un texte d'environ 300 mots, pour un coût d'environ 30$.

Tout d'abord, les compétences des évaluateurs doivent être adaptées à la tâche. Il est nécessaire que les évaluateurs parlent la langue dans laquelle le texte est généré pour juger de sa qualité. Les compétences requises peuvent être davantage spécifiques lorsque l'on a affaire à des domaines de spécialité avec des conventions d'écriture propres. Le terme « compétence » est à prendre dans son sens le plus large. Par exemple, bien que souvent reconnus pour leurs qualités rédactionnelles, les LLM ne sont toujours pas à la hauteur des auteurs humains dans l'écriture créative, au moins en espagnol (Marco *et al.*, 2024).

Comme mentionné à la section 2.6.2 , de nombreux critères de qualité peuvent être pris en compte pour évaluer la qualité intrinsèque des textes générés. La qualité des textes sur les différents critères est souvent jugée sur une échelle numérique ou une échelle de Likert (van der Lee *et al.*, 2019). Généralement, plus les critères sont précis et plus l'évaluation manuelle est coûteuse. En contrepartie, des critères généraux ou vagues vont faciliter l'évaluation mais diminuer la reproductibilité et l'accord inter-annotateur (Gehrmann *et al.*, 2023). Il faut donc souvent chercher un compromis entre difficulté et précision de l'évaluation. Des termes comme « fluidité » et « cohérence » apparaissent naturellement comme des critères d'évaluation appropriés. Cependant, il n'y a pas de terminologie standardisée pour les critères de qualité en génération

de texte. De nombreux termes sont définis de manières différentes et se recouvrent mutuellement (Howcroft *et al.*, 2020). C'est aussi un obstacle pour la reproductibilité de l'évaluation.

Howcroft *et al.* (2020) étudient 165 articles de génération automatique de texte contenant une évaluation manuelle et soulignent le manque de standardisation dans cet exercice. Les auteurs comptent 204 noms différents désignant des critères de qualité dans ces articles. Après regroupement de critères jugés similaires par les auteurs, 71 critères distincts subsistent. On a donc un nombre important de critères possibles dont la définition dans le cadre d'une évaluation de textes générés n'est pas standardisée. Par exemple, le critère désigné par « fluidité » dans les articles étudiés correspond en fait à 15 définitions possibles.

Mener une évaluation manuelle avec des critères spécifiques est coûteux et peu reproductible. Pour cette raison, il est également difficile de comparer les résultats d'un système à ceux d'un système antérieur. L'évaluation manuelle par jugement préférentiel cherche à éviter ces inconvénients. Contrairement à l'évaluation par critères, l'évaluation par jugement préférentiel consiste à présenter plusieurs textes simultanément aux évaluateurs. Selon la méthodologie choisie, l'évaluateur peut avoir à sélectionner le texte jugé comme étant le meilleur ou bien à classer les textes du moins bon au meilleur. Cette approche permet effectivement de faciliter l'évaluation, avec de meilleurs accords inter-annotateurs (Kiritchenko et Mohammad, 2017). Cependant, l'évaluation par jugement préférentiel peut être influencée par plusieurs facteurs, comme l'ordre de présentation des exemples, et peut favoriser un système ou donner l'impression d'une différence entre deux systèmes plus grande qu'elle ne l'est réellement (Boubdir *et al.*, 2023).

Plusieurs travaux se sont penchés sur les obstacles nuisant à une évaluation manuelle de qualité et ont tenté de regrouper un certain nombre de bonnes pratiques à appliquer pour maximiser la fiabilité et la reproductibilité d'une évaluation manuelle. Howcroft *et al.* (2020) mettent en avant l'importance de correctement décrire l'évaluation manuelle, en nommant et en définissant les aspects évalués et en soulignant la forme sous laquelle cela apparaît aux évaluateurs. van der Lee *et al.* (2019) soulignent un nombre important de bonnes pratiques à appliquer lors d'une évaluation manuelle. Parmi celles-ci, une partie importante concerne une documentation correcte de l'ensemble de l'évaluation, incluant les caractéristiques des annotateurs (combien d'annotateurs, accords inter-annotateurs) et les modalités d'évaluation (quels critères sont évalués, comment sont-ils présentés aux annotateurs). Les auteurs encouragent également à ne pas se limiter à un seul critère d'évaluation et à rechercher des critères propres à la tâche. Enfin, calculer la significativité statistique des résultats permet de renforcer la fiabilité de ces derniers.

Les difficultés amenées par l'évaluation manuelle rendent aussi la création de nouvelles métriques difficile car observer la corrélation d'une métrique avec des jugements humains va logiquement dépendre des jugements humains utilisés. Les métriques sont donc elles-mêmes difficiles à évaluer. Des métriques établies ont été réévaluées à plusieurs reprises sur des jeux de données récents et présentent de faibles corrélations avec les jugements humains (Novikova *et al.*, 2017 ; Reiter, 2018 ; Fabbri *et al.*, 2021).

2.6.4 . Évaluation automatique de texte dans le domaine biomédical

Les textes d'un domaine spécialisé tel que le domaine biomédical présentent des styles d'écriture et du vocabulaire spécialisés. Les métriques automatiques standards présentent déjà des limites sur des textes du domaine général et leur corrélation avec des jugements humains dans le domaine biomédical est également faible (Moramarco *et al.*, 2022).

Plusieurs métriques fondées sur des références ont été proposées pour tenir compte des caractéristiques du domaine biomédical. Typiquement, des bases de connaissances externes telles que le méta-thésaurus UMLS (Lindberg *et al.*, 1993, *Unified Medical Language System*) sont utilisées pour concentrer la similarité sur les concepts biomédicaux. Les concepts biomédicaux sont par exemples extraits du candidat et de la référence avant d'être comparés (Yim *et al.*, 2023, MEDCON). Il est aussi possible d'utiliser des graphes de connaissances biomédicales. Clinical BERTScore (Shor *et al.*, 2023) utilise un graphe pour pondérer les termes biomédicaux dans des métriques existantes, tandis que BLEURT (Ben Abacha *et al.*, 2023c) calcule la similarité entre les plongements de graphe des concepts biomédicaux. Enfin, Ben Abacha *et al.* (2023c) affinent un modèle BLEURT sur des textes biomédicaux pour obtenir un modèle BLEURT biomédical.

Tout comme les métriques automatiques standards, la validité des métriques spécialisées peut être évaluée en observant leur corrélation avec les jugements humains sur des textes biomédicaux. Moramarco *et al.* (2022) et Ben Abacha *et al.* (2023b) ont calculé la corrélation entre des métriques standards et des jugements humains sur des notes cliniques générées. Moramarco *et al.* (2022) ont observé que la métrique avec la meilleure corrélation était la distance de Levenshtein, une métrique de distance d'édition à l'échelle des caractères ou des mots n'ayant pas été créée pour l'évaluation de la génération de texte, tandis que Ben Abacha *et al.* (2023b) ont obtenu la meilleure corrélation avec BLEURT. Ces deux études analysent la corrélation avec plusieurs critères de qualité et aucune des métriques n'a obtenu la meilleure corrélation avec tous les critères. Des métriques spécialisées pour le domaine biomédical ont été évaluées sur plusieurs jeux de données de génération de notes cliniques (Ben Abacha *et al.*, 2023c). Les métriques spécialisées présentent bien de meilleures corrélations mais les résultats varient significativement selon les jeux de données.

Ces études soulignent la difficulté d'évaluation de la génération de texte dans le domaine biomédical. Les métriques standards ne sont pas suffisantes et la validité des métriques spécialisées doit être évaluée sur plusieurs jeux de données, tâches et langues. La corrélation avec des jugements humains doit être décomposée en critères précis pour réellement estimer les erreurs que les métriques parviennent à capturer. Tout comme avec les textes du domaine général, plusieurs métriques doivent être utilisées pour couvrir le plus de critères possible.

Pour l'évaluation manuelle, les difficultés présentées à la section 2.6.3 persistent. Les critères choisis pour évaluer la qualité des textes générés doivent être adaptés aux applications du système de génération et les évaluateurs doivent être des experts du domaine pour évaluer la qualité avec précision. L'évaluation manuelle est chronophage et les médecins ont une disponibilité limitée. La conception d'une interface d'évaluation ergonomique et attrayante peut contribuer à accroître la participation.

En plus de l'évaluation intrinsèque, l'évaluation manuelle d'un système génération de texte doit aussi prendre en compte sa performance lors de son déploiement dans un contexte réaliste afin d'évaluer avec précision les potentiels impacts de ce déploiement (Fessler et Grémy, 2001).

2.7 . Génération de texte dans le domaine biomédical

Les cliniciens sont souvent surchargés (Clynch et Kellett, 2015 ; Knoll *et al.*, 2022 ; Clarke *et al.*, 2013) et interagir avec des dossiers patient informatisés est chronophage (Hripcsak *et al.*, 2011 ; Arndt *et al.*, 2017). Ils pourraient donc fortement bénéficier d'outils permettant d'alléger leur charge de travail.

Nous présentons dans cette partie les principales applications de la génération de texte dans le domaine biomédical. En complément des biais des modèles génératifs présentés dans la partie 2.5.3, nous présentons également les risques spécifiques de la génération de texte pour chacune des applications.

Génération automatique de documents pour les dossiers patient informatisés. Les cliniciens passent un temps non négligeable à rédiger des rapports qui documentent l'évolution de l'état du patient à chaque étape du processus de soin. Plusieurs travaux ont étudié des méthodes pour générer des résumés de sortie à partir de notes cliniques en anglais (Xu *et al.*, 2024), ainsi qu'en italien (Ruinelli *et al.*, 2024) et en suédois (Berg et Dalianis, 2024). On trouve également des travaux sur le résumé automatique de conversations entre patients et médecins (Ben Abacha *et al.*, 2023a,b), ces dernières pouvant être des transcriptions en temps réel (Irfan *et al.*, 2024). Enfin, des rapports d'analyse et d'interprétation d'imageries médicales sont générés pour faciliter l'utilisation de ces images dans le diagnostic médical. En raison du manque de ressources spécifiques dans les autres langues, ces études multimodales sont principalement menées en anglais (Chen *et al.*, 2021b ; Xu *et al.*, 2024 ; Jeblick *et al.*, 2024).

Il est toutefois important que le système de génération permette aux cliniciens qui l'utilisent de facilement vérifier la sortie du modèle pour détecter de potentielles erreurs. En effet, cette application induit le risque que les cliniciens développent un excès de confiance envers le système, conduisant à la non détection d'erreurs affectant la suite du traitement d'un patient (Dratsch *et al.*, 2023).

Systèmes de dialogue. Le développement de la télémédecine a donné naissance à des outils en ligne permettant aux professionnels de santé d'interagir et de soigner leurs patients à distance. La télémédecine améliore l'accès aux soins en réduisant les problèmes de distance et de mobilité. Les systèmes de dialogue dans le domaine de la santé présentent le potentiel de réduire la charge de travail des médecins dans le contexte de la télémédecine. La plupart des travaux sur cette tâche concernent l'anglais et le chinois (Wei *et al.*, 2018 ; Xu *et al.*, 2019 ; Zeng *et al.*, 2020 ; Chowdhury *et al.*, 2023) mais des travaux récents essaient de créer des ressources dans d'autres langues, comme par exemple le français (Liu *et al.*, 2024).

Les interactions directes entre les patients et les modèles génératifs dans un cadre ouvert tel qu'un système de dialogue présentent un nombre conséquent de risques. En outre, il est nécessaire de s'assurer que les informations partagées durant la conversation restent confidentielles. Dans ce contexte, les patients ont la possibilité d'interagir librement avec le système, sans forcément avoir l'expertise nécessaire à l'identification de réponses du système inexactes ou dangereuses. Les patients sont alors exposés à tous les biais mentionnés dans la partie 2.5.3. Nous estimons que les outils automatiques doivent aider les cliniciens plutôt que les remplacer et que cette application se rapproche du second cas de figure. Elle doit donc être traitée avec une extrême prudence.

Simplification de texte. Plusieurs études ont montré l'importance de la transparence et de l'inclusion des patients dans leur processus de soin (Keselman *et al.*, 2008 ; Delbanco *et al.*, 2012). Simplifier les textes aide les patients à mieux comprendre leur état de santé ainsi que les soins qui leur sont proposés. Pour favoriser la compréhension, les méthodes symboliques reposent sur l'utilisation de synonymes pour les termes jugés complexes (Qenam *et al.*, 2017 ; Ramadier et Lafourcade, 2018), y compris dans des langues autres que l'anglais (Abrahamsson *et al.*, 2014).

La simplification de texte peut impliquer une interaction directe avec les patients, présentant dans ce cas des risques similaires à ceux des systèmes de dialogue. Toutefois, le cadre d'interaction est ici plus restreint puisqu'il se concentre sur certains éléments à simplifier. Dans ce cas, il est nécessaire de limiter les interactions afin d'éviter les interactions ouvertes avec le système et ainsi réduire le risque d'exposer le patient à des contenus inexacts ou dangereux.

Augmentation et partage de données. Comme décrit plus tôt dans cette thèse, les données textuelles dans le domaine biomédical sont rares car elles sont soumises à des contraintes de confidentialité. La génération de données textuelles, au sens large, peut être une manière de créer de nouvelles ressources sur lesquelles entraîner ou tester des modèles.

Plusieurs travaux utilisent les propriétés des réseaux antagonistes génératifs (Goodfellow *et al.*, 2014, *Generative Adversarial Networks*) ou des auto-encodeurs (Kingma et Welling, 2014) pour générer des données structurées dans le domaine biomédical (Abedi *et al.*, 2022 ; Choi *et al.*, 2017 ; Torfi *et al.*, 2022). Pour la génération de texte, de nombreux travaux utilisent le corpus anglais MIMIC-III (Johnson *et al.*, 2016) comme terrain d'expérimentation puisqu'il s'agit du plus grand corpus biomédical librement disponible. Certains travaux ont tenté d'utiliser la confidentialité différentielle (Dwork *et al.*, 2006, *differential privacy* - DP) pour générer des textes partageables. Par exemple, Melamud et Shivade (2019) entraînent un LSTM à générer des notes cliniques en utilisant la DP.

Malgré les promesses de la confidentialité différentielle, le nombre de travaux de génération de textes biomédicaux l'utilisant est assez restreint. En effet, certaines études ont montré que les données générées à l'aide de la DP n'étaient pas toujours utiles pour l'entraînement de modèles statistiques car, dans l'objectif de protéger la confidentialité, certaines caractéristiques des données sont gommées durant le processus (Stadler *et al.*,

2022). De plus, la DP a été pensée pour des données continues et tabulaires où chaque « individu » dont il faut protéger les informations correspond à une ligne d'un tableau. Cela n'est pas adapté pour du texte, où la définition de ce qui constitue un « individu » est beaucoup plus complexe (Brown *et al.*, 2022).

Amin-Nejad *et al.* (2020) comparent une architecture transformeur encodeur-décodeur et un affinage du modèle GPT-2 pour générer des résumés de sortie d'hôpital à partir de données structurées. Enfin, Ive *et al.* (2020) et Meoni *et al.* (2024) utilisent un outil d'extraction automatique de mots-clés pour générer des documents synthétiques à partir de mots-clés. Pour cela, Ive *et al.* (2020) entraînent un transformeur à partir de zéro tandis que Meoni *et al.* (2024) affinent un modèle pré-entraîné. Les travaux portant sur d'autres langues que l'anglais sont plus rares, cette thèse se positionne sur cette tâche pour le français.

L'augmentation et le partage de données sont des applications indirectes de la génération de texte dans le domaine biomédical, puisqu'elles n'impliquent pas directement les cliniciens ou les patients. Les risques sont par conséquent différents. Le partage de données expose à une fuite d'informations sensibles concernant les patients (Carlini *et al.*, 2023 ; Nasr *et al.*, 2023) et les méthodologies d'évaluation de ces risques sont encore imparfaites. Cela implique généralement d'interroger le modèle de manière répétée en utilisant des amorces spécifiques et de vérifier la présence des séquences ainsi générées dans les données d'entraînement du modèle. L'accès aux données d'entraînement du modèle est donc nécessaire et leur quantité peut rendre le processus de vérification coûteux. Une étude publiée par Nasr *et al.* (2023) a permis d'extraire de longues séquences provenant des données d'entraînement de ChatGPT à l'aide d'une amorce demandant la répétition infinie d'un mot. Cette faille a été corrigée dans une version ultérieure du modèle. Ce type de mise à jour est fréquent dans les modèles fermés, dont les nouvelles protections rendent certains résultats expérimentaux obsolètes.

Enfin, l'utilité des données synthétiques est souvent testée dans un nombre limité de tâches en aval mais leur utilisation pour d'autres tâches peut s'avérer inadaptée. Cela souligne la dépendance des textes générés à leur contexte applicatif.

2.8 . Conclusion

Dans ce chapitre, nous avons présenté le principe de fonctionnement des modèles génératifs et leurs limites. Les méthodes les plus récentes, fondées sur des modèles de langue neuronaux et l'architecture transformeur, nécessitent une importante quantité de données pour leur entraînement et sont difficilement contrôlables. En outre, les textes générés avec ces approches sont susceptibles de présenter un nombre important de biais.

Nous avons également mis en évidence les défis posés par l'évaluation de la génération de textes, à la fois de manière générale et de manière spécifique au contexte biomédical, que ce soit par le biais de méthodes automatiques ou manuelles. Enfin, nous avons présenté les applications actuelles des modèles de langue génératifs dans le domaine biomédical en réfléchissant aux risques liés à ces applications étant donné les limites présentées plus tôt.

Contrairement au domaine général et particulièrement en anglais, les corpus librement disponibles dans le domaine biomédical en français sont rares et, en conséquence des besoins des modèles génératifs en données, les travaux de génération le sont également. Nous cherchons donc, à travers le chapitre 3 de ce manuscrit, à répondre à notre première question de recherche : **comment adapter les méthodes de génération de texte au domaine clinique en français ?** (1) Nous présentons les différentes méthodologies de génération testées durant cette thèse, en partant des corpus et de leur prétraitement jusqu'à l'inférence. Parmi ces méthodologies, nous abordons également la question de la contrôlabilité des modèles.

Le chapitre 4 porte sur la problématique d'évaluation de la génération de texte, pour tenter de répondre aux défis posées par celle-ci dans le contexte de la génération de texte clinique en français et répondre à la question de recherche : **comment évaluer la qualité des modèles définis et des textes générés ?** (2). Pour cela, nous proposons plusieurs protocoles d'évaluation en essayant de couvrir un large éventail de dimensions adaptées au contexte de génération.

3 - Méthodologies de génération de texte

3.1 . Introduction

Les méthodes actuelles de génération de texte sont capables de générer des textes difficilement différentiables de textes écrits par des humains. Cette affirmation est principalement vraie pour des textes du domaine général en anglais mais elle ne l'est pas encore pour les domaines spécialisés ou les langues pour lesquelles les ressources ne sont pas abondamment accessibles *via* internet. Le domaine biomédical fait l'objet de nombreuses études en anglais, notamment grâce à l'existence du corpus `MIMIC-III` (Johnson *et al.*, 2016) et à divers travaux visant à enrichir le domaine pour des tâches de génération de texte. En français, les corpus librement accessibles restent plus rares, malgré les travaux visant également à enrichir le domaine.

Le principal objectif de ce chapitre est d'adapter les méthodes de génération de texte fondées sur les transformeurs au domaine biomédical en français. Nous commencerons par présenter le style spécifique de texte auquel nous nous intéressons, à savoir les cas cliniques. Nous décrirons ensuite plusieurs niveaux d'adaptation de ces méthodes afin de contrôler plus ou moins précisément le contenu des textes générés, le contrôle étant un défi majeur des méthodes de génération neuronales. Enfin, nous proposerons une méthodologie de génération ayant pour but d'observer la manifestation des biais de genre dans les textes générés et leurs potentielles conséquences pour les médecins et les patients.

Tout au long de ce chapitre, nous essaierons de privilégier des modèles et des méthodes aux besoins en ressources computationnelles limitées afin de pouvoir les adapter à des environnements hospitaliers disposant de ressources limitées. Ce chapitre cherche donc à répondre aux questions de recherche (1) et (3) :

- **comment adapter les méthodes de génération de texte au domaine clinique en français ?**
- **comment générer des textes avec des contraintes de temps et de puissance de calcul ?**

3.2 . Présentation des corpus de cas cliniques

Selon la définition de la *Haute Autorité de Santé*, un cas clinique désigne « *la description d'une situation clinique issue de la pratique des professionnels ou susceptible d'être rencontrée dans la pratique* »[1].

1. https://www.has-sante.fr/upload/docs/application/pdf/2020-09/fiche_-_methode_dpc_-_vignettes.pdf

Les cas cliniques contiennent des descriptions des antécédents médicaux des patients, des traitements reçus à l'hôpital et des soins de suivi. Un cas clinique est présenté dans l'exemple (1) [2].

(1) *Un homme de 57 ans, hypertendu, est transporté aux urgences dans le coma. Il présente des signes cholinergiques, avec un myosis mais aussi une hypersécrétion bronchique avec dyspnée et une hyperthermie (33,2° C). Le patient est immédiatement intubé et ventilé. Devant ces symptômes muscariniques, une intoxication par les organophosphorés a été suspectée, puis confirmée dans un premier temps par une diminution de l'activité cholinestérasique. Du pralidoxime et de l'atropine ont donc été administrés comme antagonistes. Après extubation (à J3), l'évolution a été favorable.*

Les cas cliniques sont utilisés depuis longtemps dans le champ de l'enseignement et de la recherche en santé. Afin de pouvoir les partager, les cas cliniques sont désidentifiés et publiés avec le consentement des patients concernés.

Bien que l'exemple (1) présente une forme typique de cas clinique, commençant par une description du patient, de ses symptômes et décrivant ensuite son parcours clinique, il n'y a pas de format standard pour ce genre de document. Les cas cliniques peuvent prendre une forme beaucoup plus synthétique sous forme de liste à puces.

On trouve des cas cliniques de longueurs variées, avec des niveaux de détail différents et des parcours de patients plus ou moins longs. Afin d'expérimenter sur la génération de documents cliniques, nous avons choisi de travailler avec des cas cliniques car (i) ils partagent un certain nombre de caractéristiques avec les autres types de documents cliniques et (ii) ils sont plus facilement partageables.

3.2.1 . Corpus de cas cliniques librement disponibles

Les cas cliniques se trouvent dans différentes sources de littérature biomédicale, dont un certain nombre est disponible sur la plateforme PubMed [3]. Nous présentons dans cette partie les différents travaux de collecte et d'annotation de cas cliniques en français.

CAS (Grabar *et al.*, 2018) est un corpus médical français contenant 717 descriptions de cas cliniques publiés dans la littérature. Les documents du corpus `CAS` couvrent plusieurs spécialités médicales. Le corpus a été désidentifié et la publication des descriptions de cas se fait avec le consentement des patients. Le corpus peut être obtenu auprès des organisateurs de la tâche partagée DEFT 2020 [4].

E3C (Magnini *et al.*, 2020) est un corpus multilingue librement disponible [5]. Il contient des documents biomédicaux extraits de différentes sources, notamment des revues, des résumés, des corpus biomédicaux existants, des brochures d'information sur les médicaments à l'intention des patients, etc. Dans notre travail, nous nous sommes concentrés

2. Provenance : https://www.ata-journal.org/articles/ata/abs/2000/04/ata20004p315ata20004p315.html
3. https://pubmed.ncbi.nlm.nih.gov/
4. https://deft.lisn.upsaclay.fr/
5. https://github.com/hltfbk/E3C-Corpus

sur la partie française du corpus, en sélectionnant uniquement les cas cliniques publiés dans la littérature, qui sont les documents les plus similaires aux récits cliniques qui nous intéressent. Les cas cliniques de E3C couvrent une variété de spécialités médicales. Cette partie du corpus contient environ 1 000 documents et plus de 300 000 tokens.

DIAMED est un corpus de cas cliniques en français librement disponible, faisant partie de DrBenchmark (Labrak *et al.*, 2024a), un ensemble de jeux de données d'évaluation de modèles pour la compréhension de texte dans le domaine biomédical en français. DIAMED contient 739 cas cliniques annotés selon la Classification Internationale des Maladies (10e révision – CIM-10). Le corpus DIAMED peut être téléchargé à l'aide de la bibliothèque datasets de HuggingFace [6]. Le corpus peut également être trouvé sur la page HuggingFace de DrBenchmark [7]. Toutefois, avec cette deuxième méthode, 853 cas cliniques sont récupérés, soit 114 de plus qu'annoncé. La différence est due à des documents où la classification n'a pas pu être définie correctement. Puisque nous ne nous intéressons qu'aux cas cliniques et non aux annotations, nous sélectionnons la version du corpus avec 853 documents.

3.2.2 . Recouvrement entre les corpus

Les corpus E3C et DIAMED contiennent, en plus des cas cliniques et des annotations, la source du document sous forme d'URL. En se basant sur ces sources, nous identifions un recouvrement important entre ces deux corpus, dont beaucoup de cas cliniques proviennent de la même source (*The Pan African Medical Journal*). Nous identifions 590 sources similaires pour ces deux corpus que nous écartons pour la suite de nos expériences. Nous retirons ces documents du corpus le plus récent, DIAMED, pour lequel il reste désormais 263 documents. Nous appellerons cette version tronquée DIAMED_{small}. Nous n'avons pas identifié de documents redondants avec le corpus CAS.

3.2.3 . Résumé statistique

Nous présentons dans le tableau 3.1 des statistiques sur les trois corpus de cas cliniques en français utilisés dans ce travail. Ces statistiques ont été obtenues en utilisant la bibliothèque NLTK [8]. Bien que les trois corpus soient de tailles différentes, on observe des statistiques similaires au niveau de la taille des documents et de leurs phrases, principalement entre E3C et CAS.

3.3 . Adaptation au domaine

La première question de recherche abordée dans cette thèse est la suivante : **comment adapter les méthodes de génération de texte au domaine clinique en français ?** Dans cette partie, nous nous demandons si les modèles ainsi adaptés seraient en mesure de générer des textes ressemblant à des textes cliniques réels, sans contrainte supplémentaire. Cette approche correspond à une tâche de génération de texte libre.

6. https://huggingface.co/docs/datasets/index
7. https://huggingface.co/DrBenchmark
8. https://www.nltk.org/

	E3C	CAS	DIAMED$_{small}$	Total
Nombre de documents	1 009	717	263	1 989
Nombre de tokens	328 645	231 662	105 613	665 920
Tokens par document	325,7	323,1	401,6	334,5
Phrases par document	15,2	15,8	18,1	15,8
Tokens par phrase	21,4	20,4	22,2	21,2

Table 3.1 – Statistiques des trois corpus de cas cliniques étudiés.

Dans le chapitre 2, nous avons présenté les différentes méthodes de génération de texte, dont les méthodes les plus récentes à base de transformeurs. Ces modèles sont capables de générer du texte à l'apparence naturelle et cohérente. Pour atteindre cette performance, les modèles nécessitent une importante quantité de données d'entraînement, ce qui constitue une de leurs limites. En outre, les performances des modèles sont largement inférieures lorsqu'ils sont appliqués sur des langues ou domaines spécifiques non représentés dans l'entraînement.

Afin d'entraîner des modèles génératifs à base de transformeurs à partir de zéro, il existe d'une part suffisamment de corpus en français (Simoulin et Crabbé, 2021) et d'autre part suffisamment de corpus médicaux en anglais (Luo *et al.*, 2022). Cependant, les corpus médicaux en français librement disponibles sont insuffisants pour entraîner un modèle transformeur génératif à partir de zéro. Dans cette partie, nous analysons la capacité de modèles de langue génératifs à s'adapter au domaine clinique en français. Nous proposons une méthodologie simple comprenant la préparation du corpus, l'entraînement des modèles sur le corpus prétraité et la génération de textes.

Les travaux présentés dans cette partie ont donné lieu à une publication à la conférence EACL 2023 (Hiebel *et al.*, 2023a) [9]. Le code d'entraînement et de génération ainsi que les corpus sont librement disponibles [10].

3.3.1 . Préparation du corpus

L'adaptation de modèles génératifs à un domaine spécifique ne requiert pas nécessairement de traitements complexes puisque les modèles auto-régressifs s'entraînent de manière auto-supervisée à partir de texte brut. Nous choisissons d'utiliser le corpus E3C, le corpus contenant le plus de cas cliniques, pour entraîner des modèles génératifs.

Notre objectif est de générer des cas cliniques complets. Pour cela, nous marquons les limites de chaque texte du corpus en les encadrant par des balises de début et de fin de texte, sous la forme <|*startoftext*|> <|*endoftext*|>. Ainsi, à l'inférence, il est possible de générer un document en utilisant la balise de début de texte et de repérer la fin d'un document lors de la génération à l'aide de la balise de fin de texte. Cette méthode simple permet d'obtenir une première version du corpus sur laquelle affiner les modèles génératifs.

9. Cette section ne s'intéresse qu'à la méthodologie de génération présentée dans la publication. La partie évaluation sera présentée dans le chapitre 4.

10. https://github.com/Hiebel/Synthetic-text-for-NER

Catégorie	Nombre d'occurrences
Anatomie	4 449
Produits chimiques et pharmaceutiques	1 374
Concepts	2 964
Dispositifs médicaux	1 069
Signes & symptômes	4 593
Dosages	928
Hôpitaux	806
Êtres vivants	3 921
Localisations	840
Mesures	5 322
Modes	252
Processus biologiques	905
Procédures	8 291
Expressions temporelles	3 940
Total	39 654

Table 3.2 – Catégories et occurrences des annotations dans le corpus MERLOT.

Nous souhaitons évaluer la capacité des textes générés à servir de substitut à de vrais textes pour l'entraînement de modèles de reconnaissance d'entités cliniques [11]. Les entités cliniques correspondent à des mentions d'éléments appartenant à des catégories médicales prédéfinies, telles que l'anatomie, les symptômes ou les médicaments. Nous construisons pour cela une seconde version du corpus en marquant cette fois-ci les entités cliniques à l'aide de marqueurs prenant la forme de balises dans le texte encadrant les entités avec le type correspondant.

Nous utilisons le corpus MERLOT (Campillos *et al.*, 2018) [12] pour entraîner des modèles de reconnaissance d'entités cliniques. Ce corpus est composé de 500 documents cliniques en français couvrant deux spécialités : hépato-gastro-entérologie et nutrition. Il comprend 148 476 tokens avec des annotations pour les entités, les attributs et les relations cliniques. Les textes contenus dans ce corpus sont des récits cliniques typiques que l'on peut retrouver dans des dossiers médicaux informatisés. Les différentes catégories d'annotations ainsi que leurs nombres d'apparitions sont indiqués dans le tableau 3.2.

Les modèles de reconnaissance d'entités nommées (REN) sont obtenus en affinant le modèle BERT français Camembert (Martin *et al.*, 2020) sur les entités cliniques du corpus MERLOT en suivant la méthodologie décrite par (Bannour *et al.*, 2022). Nous utilisons ces modèles entraînés pour annoter le corpus E3C. Utiliser des annotations automatiques plutôt que des annotations manuelles pour l'entraînement des modèles de REN peut provoquer des propagations d'erreurs. Nous utilisons une stratégie ensembliste pour limiter ce

11. Nous reviendrons sur cette évaluation dans le chapitre 4

12. Nous remercions le Service d'Informatique Biomédicale (SIBM) ainsi que l'équipe CISMeF du CHU de Rouen qui nous ont permis d'utiliser le corpus LERUDI pour ce travail.

problème : nous entraînons et appliquons cinq modèles sur le corpus et nous gardons les annotations trouvées par au moins trois des cinq modèles. Les données d'entraînement et de validation sont mélangées pour chaque modèle et une graine aléatoire différente est utilisée.

3.3.2 . Modèles utilisés

Nous avons choisi d'utiliser des modèles de langue auto-régressifs, dont l'objectif premier est la génération de texte. Plus précisément, nous utilisons des modèles pré-entraînés que nous affinons sur un corpus de cas cliniques en français. En effet, nous ne disposons pas d'une quantité de texte suffisamment large pour entraîner de tels modèles génératifs à partir de zéro. De plus, nous supposons qu'un entraînement exclusif sur le corpus de cas cliniques favoriserait la génération de portions de texte présentes dans ces données d'entraînement. Enfin, il a été montré que les modèles pré-entraînés tels que GPT-2 permettent de générer des données textuelles complémentaires dans un contexte d'augmentation de données (Claveau *et al.*, 2022).

Nous explorons donc la capacité de modèles entraînés partiellement ou exclusivement sur du français à s'adapter au domaine médical et à générer des descriptions de cas cliniques pertinents. Nous utilisons deux modèles auto-régressifs existants. Le premier est un modèle à un milliard de paramètres pré-entraîné sur des textes français génériques par Simoulin et Crabbé (2021). Le corpus utilisé pour pré-entraîner le modèle a été extrait de Wikipedia, du Projet Gutenberg [13], de OpenSubtitle (Lison et Tiedemann, 2016) et de CommonCrawl. Nous désignerons ce modèle par LLF.

Le second modèle est une version du modèle de BigScience BLOOM (Scao *et al.*, 2022) à 1 milliard de paramètres. BLOOM a été entraîné sur 46 langues différentes, dont le français [14]. Nous avons choisi la version à 1 milliard de paramètres pour une comparaison équitable entre les deux modèles.

3.3.3 . Affinage des modèles

Nous affinons les modèles génératifs sur le corpus clinique E3C où chaque document est encadré par des tokens spéciaux (balises) de début et de fin de document. Deux versions du corpus ont été utilisées : l'une avec les annotations décrites à la section 3.3.1, afin que les modèles apprennent à générer les annotations directement, et l'autre sans annotation. Le corpus est divisé en ensembles d'entraînement et de validation, avec $90\ \%$ du corpus pour l'entraînement et $10\ \%$ pour la validation. Les modèles sont entraînés sur un maximum de 10 époques, avec un arrêt précoce si la perplexité sur le jeu de validation ne diminue pas significativement pendant deux époques consécutives. Nous obtenons donc quatre modèles, deux pour chaque modèle pré-entraîné avec une version produisant du texte brut non balisé et une version incluant des annotations dans le texte généré.

13. www.gutenberg.org
14. https://huggingface.co/spaces/bigscience/BigScienceCorpus

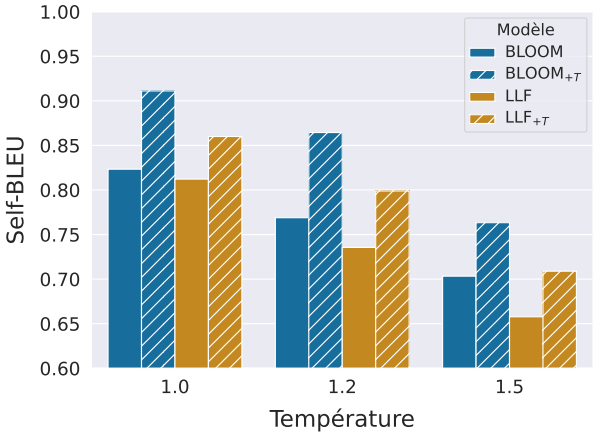
3.3.4 . Détails du processus de génération

Les textes sont générés en utilisant le token de début de texte comme amorce. Beaucoup de paramètres de décodage peuvent être utilisés pour influencer la sortie du modèle. Nous avons choisi de nous concentrer sur trois paramètres : l'échantillonnage avec top-p, la température et la pénalité de répétition. Comme présenté plus tôt, le top-p permet de dynamiquement modifier la quantité de tokens considérés lors de l'échantillonnage et la température accentue ou diminue les écarts dans la distribution de probabilités. La pénalité de répétition vise quant à elle à limiter les répétitions, réduisant ainsi la génération de potentielles boucles. Pour connaître l'impact de ces paramètres sur la génération, nous générons des textes en faisant varier ces paramètres. Puisque nous souhaitons obtenir un corpus généré suffisamment diversifié, nous sélectionnons deux critères pour évaluer l'impact des paramètres : la mesure Self-BLEU pour la diversité et la perplexité pour s'assurer que la conformité du texte généré ne souffre pas de l'augmentation de la diversité. Nous générons des textes à hauteur de $10\ \%$ de la quantité ciblée, à savoir la taille du corpus réel E3C.

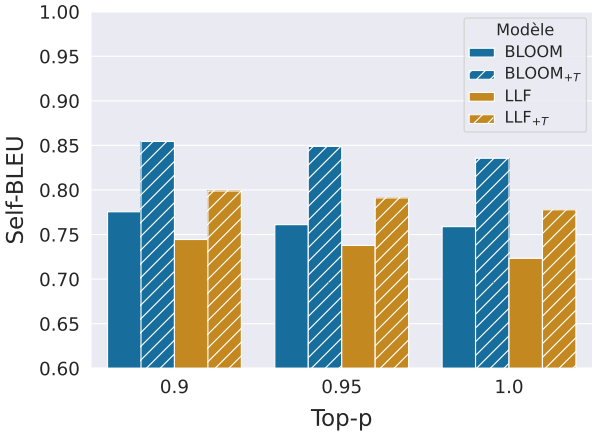
La figure 3.1 présente les résultats sur les échantillons de textes pour la métrique Self-BLEU. Le suffixe $_{+T}$ est utilisé pour désigner les modèles entraînés sur la version du corpus avec des balises pour les entités cliniques. On observe assez logiquement que l'augmentation de la température diminue le Self-BLEU, signifiant une plus grande diversité (3.1a). L'impact de la variation de top-p est assez faible (3.1b) et celui de la pénalité de répétition est irrégulier, avec une plus grande diversité obtenue avec la plus grande pénalité (3.1c). La figure fait aussi ressortir des différences entre les textes générés avec ou sans balises. Les textes générés avec des balises présentent systématiquement des Self-BLEU plus élevés que leurs contreparties sans balises, signifiant une moins grande diversité. On observe aussi que les textes générés avec les modèles BLOOM présentent généralement une moins grande diversité que les textes générés avec les modèles LLF.

La figure 3.2 présente les résultats pour la perplexité. On constate cette fois-ci que l'augmentation de la valeur des paramètres entraîne une augmentation de la perplexité pour tous les modèles. Cela se remarque principalement pour la température (3.2a) et la pénalité de répétition (3.2c). Les textes générés avec les modèles BLOOM obtiennent des perplexités plus faibles que les textes générés avec les modèles LLF. Il est possible que cette différence soit au moins en partie due au fait que le modèle oracle est lui aussi de la famille de BLOOM.

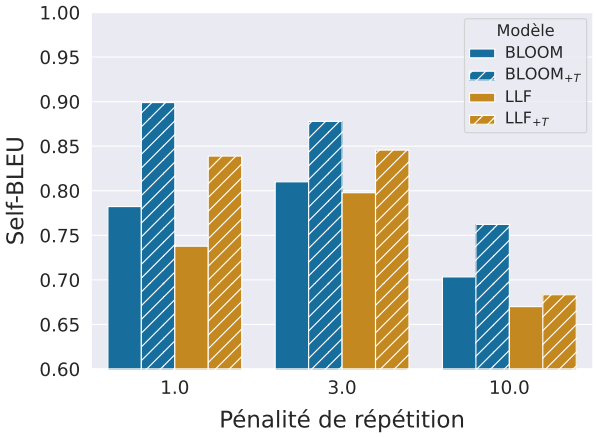
En partant de ces résultats, nous sélectionnons une température de 1,2 pour les modèles sans balises et 1,5 pour les modèles avec balises afin de favoriser la diversité des textes générés et de se rapprocher de la diversité du corpus original. Nous sélectionnons la valeur médiane de 0,95 pour le paramètre top-p, puisque ce paramètre n'a que peu d'impact sur les deux métriques. Cela s'explique peut-être en partie par le fait que nous gardons la valeur par défaut du paramètre d'échantillonnage top-k ($= 100$), limitant l'impact de top-p. Enfin, nous choisissons la valeur la plus élevée pour la pénalité de répétition (10). Nous avons en effet observé un nombre significatif de générations pathologiques où le modèle génère les mêmes boucles de tokens à répétition malgré une valeur de pénalité élevée.



(a) Variation de la température.

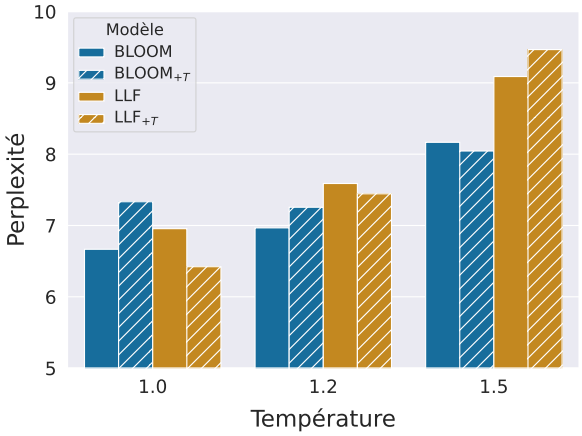


(b) Variation de top-p.

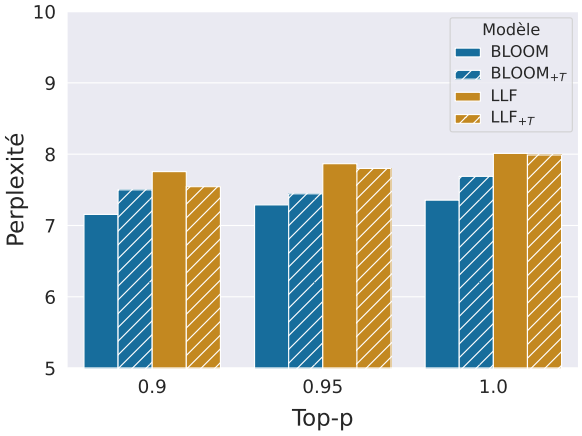


(c) Variation de la pénalité de répétition.

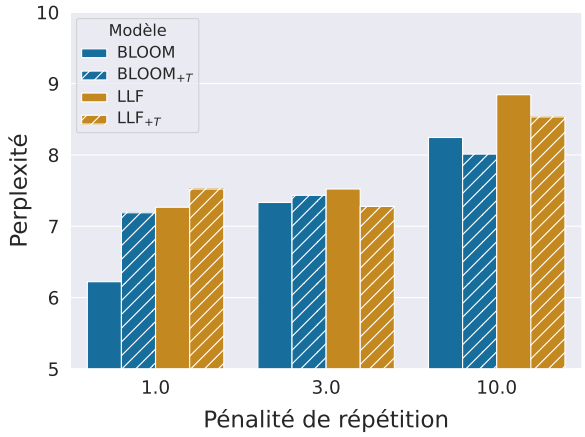
Figure 3.1 – Self-BLEU sur un échantillon de génération de 30 000 tokens pour chaque modèle de génération. Le Self-BLEU sur le corpus E3C a été mesuré à 0,68. $_{+T}$ indique les modèles ont été entraînés sur la version balisée du corpus E3C.



(a) Variation de la température.



(b) Variation de top-p.



(c) Variation de la pénalité de répétition.

Figure 3.2 – Perplexité du modèle oracle sur un échantillon de génération de 30 000 tokens pour chaque modèle de génération. La perplexité oracle est calculée à l'aide du modèle pré-entraîné BLOOM à 7 milliards de paramètres. La perplexité oracle sur le corpus E3C a été mesurée à 22,0. $_{+T}$ indique les modèles ont été entraînés sur la version balisée du corpus E3C.

3.3.5 . Filtrage des textes générés

Les modèles de langue auto-régressifs peuvent générer des textes de bonne qualité. Toutefois, les textes générés peuvent présenter des erreurs comme des répétitions ou des incohérences, particulièrement lorsqu'une longue séquence est générée (Pillutla *et al.*, 2021). En observant des échantillons de textes générés, nous définissons quelques critères pouvant être détectés automatiquement :

- présence de tokens excessivement longs : il arrive que les modèles génèrent une séquence de caractères incohérente ou qui combine de nombreux termes techniques (exemple : "*céphalo-rachidiencéphalico-mandibulaire*") ;
- répétition d'un ou plusieurs tokens en boucle, particulièrement en fin de document ;
- présence de séquences anormales, souvent avec des tokens courts et des nombres (exemple : "*classée T*4*N*2 *M*0 *I* 2 *B* 3 *C* 4 *D* 5"), où le modèle récite l'alphabet (exemple : "*hépatite A B C D E F*").

Ces trois cas pathologiques sont écartés en excluant les documents concernés, en se basant sur les longueurs de tokens, la fréquence de tri-grammes et des expressions régulières. Les valeurs des seuils utilisées pour ces trois paramètres sont déterminées en analysant manuellement les documents exclus selon différentes valeurs de ces seuils. Finalement, nous excluons les documents ayant des tokens de plus de 30 caractères, des tri-grammes apparaissant plus de trois fois et des répétitions d'au moins trois tokens courts combinant nombres ou lettres isolés.

Nous souhaitons que le corpus synthétique généré ait une diversité proche du corpus réel E3C, calculée ici par le score Self-BLEU (d'une valeur de 0,68 pour E3C). Bien que le Self-BLEU ne prenne en compte qu'une diversité de surface, nous pensons que cette diversité est pertinente pour comparer les corpus réels et synthétiques. Nous générons donc nettement plus de textes que la taille ciblée de 330 000 tokens et nous sélectionnons un sous-ensemble de documents divers en utilisant un outil développé par Cohen *et al.* (2013), basé sur le taux de recouvrement de sous-chaînes de caractères entre documents. Nous calculons ensuite le Self-BLEU pour le sous-ensemble sélectionné. Self-BLEU correspond à la moyenne des scores BLEU de chaque document avec tous les autres documents. En conservant ces scores BLEU pour chaque document du corpus, on peut considérer que les documents avec les scores BLEU les plus élevés sont les documents les plus redondants. Nous retirons donc les 10 documents avec les scores BLEU les plus élevés, c'est-à-dire les documents apportant le moins de diversité, et répétons le processus jusqu'à obtenir un Self-BLEU et un nombre de tokens proches de ceux du corpus E3C.

3.3.6 . Statistiques

Les statistiques descriptives des corpus synthétiques générés sont présentées dans le tableau 3.3. Comme expliqué plus tôt, chaque corpus synthétique correspond à un sous-ensemble filtré de l'ensemble de textes générés.

Nous avons constaté que plus de filtrages ont été nécessaires pour les deux configurations se basant sur le modèle BLOOM par rapport aux configurations utilisant le modèle LLF. Plus de filtrages ont également été nécessaires pour les configurations où les

	BLOOM$_{E3C}$	BLOOM$_{E3C+T}$	LLF$_{E3C}$	LLF$_{E3C+T}$
Nombre de tokens	329 328	346 413	328 498	336 154
Nombre de documents	943	1 997	1 028	978
Tokens par document	349,2	173,5	319,6	343,7
Phrases par document	1,8	3,1	6,9	7,2
Tokens par phrase	194	56,0	46,3	47,7
Self-BLEU	0,70	0,73	0,68	0,67
Perplexité	9,97	9,27	10,03	11,9

Table 3.3 – Description statistique des corpus cliniques synthétiques. La perplexité oracle est calculée à l'aide du modèle pré-entraîné BLOOM à 7 milliards de paramètres. La perplexité oracle sur le corpus E3C a été mesurée à 22,0.

textes sont générés avec des balises. Finalement, nous avons exclu $0,45\,\%$ des textes pour BLOOM$_{E3C}$, $0,54\,\%$ pour BLOOM$_{E3C+T}$, $0,30\,\%$ pour LLF$_{E3C}$ et $0,45\,\%$ pour LLF$_{E3C+T}$.

En comparant avec les corpus réels (tableau 3.1), on constate que seul BLOOM$_{E3C+T}$ présente des documents beaucoup plus courts en terme de nombre de tokens, les autres corpus générés ayant des documents de tailles équivalentes au corpus E3C. Toutefois, les phrases des corpus synthétiques sont beaucoup plus longues que celles du corpus E3C, tout particulièrement pour BLOOM$_{E3C}$ qui contient moins de deux phrases en moyenne par document. Enfin, les corpus générés avec BLOOM sont moins diversifiés selon le score Self-BLEU.

3.3.7 . Exemples de textes générés

Des extraits de textes générés avec les quatre configurations sont présentés dans le tableau 3.4. Il est difficile d'estimer la qualité de ces textes sans expertise médicale. Toutefois, on reconnaît dans tous les exemples le schéma typique d'un cas clinique, à savoir la présentation du patient, les raisons de sa consultation puis la description d'examens réalisés.

3.3.8 . Synthèse

Dans cette partie présentant une méthodologie de génération de cas cliniques en français, nous avons généré quatre corpus synthétiques en nous basant sur le corpus réel E3C. Les corpus obtenus sont de tailles équivalentes au corpus E3C et nous sommes parvenus à générer des textes ayant l'apparence de cas cliniques. Toutefois, cette similarité apparente avec les documents réels ne suffit pas à attester de leur qualité. Une évaluation plus poussée de ces textes sera présentée dans le chapitre 4, portant sur l'évaluation.

La méthodologie de génération présentée dans cette partie visait à imiter le style des cas cliniques. Cette méthodologie est simple et peut être appliquée à n'importe quel corpus. Nous nous intéressons désormais à un contrôle plus précis du contenu des textes générés.

Balises	LLF	BLOOM
Sans	Il s'agit d'un patient âgé de 52 ans, sans antécédents pathologiques notables. Admis aux urgences pour douleurs abdominales diffuses associées à des vomissements post-prandiaux évoluant depuis deux semaines en rapport avec une obstruction du canal cystique dont l'examen clinique a objectivé un ictère cutanéo-muqueux généralisé associé à quelques signes inflammatoires non spécifiques (extériorrhée et urétéro-hydronéphrose). L'examen ophtalmologique n'a révélé aucun autre signe oculaire ou ostéo-nerveux associés.	Il s'agissait d'une patiente âgée de 55 ans ayant comme antécédents une polyarthrite chronique touchant toutes les articulations métacarotidiennes évoluant depuis plus de 10 ans associée à une insuffisance surrénalienne fonctionnelle qui s'est aggravée après l'installation d'un diabète insulino-résistant non insulino-dépendant nécessitant son hospitalisation six mois avant sa consultation chez notre confrère ophtalmologue afin d'être mis sous traitement médicamenteux associant : imipramine 250 mg / jour ; dexaméthasone 150 mg/jour ; corticostéroïde prednisolone 5mg/kg/24h)
Avec	Une femme âgée de 55 ans, sans antécédents pathologiques particuliers était hospitalisée pour une dyspnée d'effort évoluant depuis 6 jours. L'examen clinique a montré un état général altéré avec des signes inflammatoires du membre supérieur gauche ainsi qu'un syndrome grippal (une fièvre à 39 ° C) et le reste de l'examen neurologique était sans particularités. La radiologie standard n'a objectivé ni troubles sensitivo-moteur ni convulsions fébriles.	Il s'agissait d'un patient de 50 ans, sans antécédents pathologiques particuliers, admis aux urgences pour des douleurs épigastriques aiguës associées à une distension abdomino-pelvienne évoluant depuis deux jours. L'examen clinique trouvait un patient en assez bon état général (Apgar : 10/10). Le bilan préopératoire objectivait une fonction rénale normale et la CRP était à 12 mg/l.

Table 3.4 – Extraits de textes générés pour les quatre configurations. Les éléments surlignés dans les extraits de la ligne du bas présentent les balises d'entités générées. Se référer au tableau 3.2 pour le code couleur des annotations.

3.4 . Introduction d'éléments de contrôle

Les textes générés à l'aide d'une simple adaptation au domaine peuvent contenir n'importe quel élément du corpus d'entraînement voire même, dans un cas extrême, reproduire totalement un texte d'entraînement. De plus, dans un contexte pédagogique, il est intéressant de pouvoir cibler des thématiques spécifiques dans les textes générés.

L'objectif de cette partie est donc de contrôler plus finement la génération sur des éléments cliniques. Outre le ciblage de thématiques spécifiques, cela contribue à assurer une certaine cohérence clinique dans les textes générés. Par ailleurs, la sélection précise des éléments cliniques à inclure pourrait réduire les risques de reproduction de grandes portions de textes d'entraînement. Cette partie cherche également à répondre à la question de recherche : (1) **comment adapter les méthodes de génération de texte au domaine clinique en français ?**

Une étude réalisée par Ive *et al.* (2020) a montré qu'il était possible d'entraîner des modèles de génération conditionnés par des éléments cliniques à partir du corpus MIMIC-III en combinant, pour chaque document du corpus sélectionné, des éléments extraits automatiquement des textes et les codes de classification CIM-10 associés. Le corpus utilisé, MIMIC-III, a permis pour cette étude d'entraîner des modèles à partir de zéro. Nous adaptons cette méthodologie pour générer des cas cliniques en français conditionnés par des profils patient extraits des cas cliniques réels issus des corpus E3C et CAS. Nous affinons différents modèles génératifs pré-entraînés sur les couples profil patient / cas clinique réel afin d'obtenir des modèles capables de suivre ce conditionnement.

Nous présentons dans cette partie la construction des profils patient pour constituer les ensembles d'entraînement et de test. Nous décrivons ensuite les modèles sélectionnés ainsi que la méthodologie d'affinage et de génération. Nous terminons par présenter quelques exemples de textes générés.

Les travaux présentés dans cette section sont le fruit d'une collaboration avec Hugo Boulanger, alors post-doctorant sur le projet CODEINE. Cette collaboration a donné lieu à une publication à l'atelier Clinical NLP de la conférence NAACL 2024 (Boulanger *et al.*, 2024) [15] [16].

3.4.1 . Définition d'un profil patient

Nous avons échangé avec des cliniciens afin de définir les éléments saillants dans des cas cliniques. Ces éléments sont ensuite sélectionnés comme conditionnement de la génération. Le tableau 3.5 présente un exemple des différentes catégories d'éléments importants qui ont été retenus pour un cas clinique du corpus E3C présenté dans l'exemple (2). On y retrouve les informations démographiques du patient (âge et sexe), la localisation de la pathologie, des informations histologiques, différents signes ou symptômes, des traitements et procédures effectués, des résultats biologiques et des scores (mesures ou codes).

15. Cette section couvre uniquement la méthodologie de génération. La partie évaluation correspondante sera présentée dans le chapitre 4.

16. L'auteur de cette thèse s'est occupé de la préparation du corpus et de la génération avec les modèles à architecture décodeur, tandis que Hugo Boulanger s'est chargé de la génération avec les modèles encodeurs-décodeurs.

(2) *Un **homme** de **54 ans** a consulté pour **hématurie** isolée. Une échographie, puis un **examen tomodensitométrique**, démontraient une **masse de 4 cm** de diamètre, au centre nécrotique, antérieure au dôme vésical, **envahissant uniquement la graisse adjacente** (Figure 1A.). Les biopsies, faites à la cystoscopie, révèlaient un adénocarcinome peu différencié, avec des zones d'épithélioma transitionnel de type III (Figure 1B). Le bilan d' extension était négatif. Le patient bénéficiait d'une **cystoprostatectomie radicale totale avec lymphadénectomie iliaque et obturatrice**, associée à une **omphalectomie** et une **entérocystoplastie de substitution** selon Studer. L'examen anatomo-pathologique complet de la pièce opératoire, révèlait un **adénocarcinome de l'ouraque peu différencié**, invasif, très localement mucosécrétant (Figure 1C). Il était ulcéré dans la lumière vésicale, et contenait des zones de carcinome transitionnel de grade III, ainsi que des cellules argentaffines. Deux poches de lymphonoeuds et la graisse environnante, étaient envahis. L'immunohistochimie montrait un **positivité des cellules néoplasiques pour l'Antigène Carcino-Embryonnaire (ACE), Leu-M1 (CD 15)**, et une **négativité pour les cytokératines (ck) 7 et 20**. L'épithélium vésical était positif pour les ck 7. Il s'agissait d'un stade **T III A** (selon la classification de Sheldon).*
*Le patient subissait une **chimiothérapie par Méthotrexate - Vinblastine - Endoxan -Cisplatine** par voie systémique. Avec 35 mois de recul, il va bien.* [17]

Types d'éléments cliniques	Exemple de valeurs
Âge	54
Sexe	Masculin
Localisation	Vessie
Histologie	adénocarcinome de l'ouraque peu différencié
Signe	hématurie
Procédure	scanner CT
Traitement	chimiothérapie par Méthotrexate-Vinblastine-Endoxan-Cisplatine
Score	T III A (selon la classification de Sheldon)
Bio	une négativité pour les cytokératines (ck) 7 et 20

Table 3.5 – Exemples d'éléments de contrôle manuellement définis pour un cas clinique. Le cas clinique correspondant est présenté dans l'exemple (2).

En accord avec les recommandations des cliniciens, nous identifions une vingtaine de contraintes par cas, en sélectionnant si possible des éléments de chaque catégorie avec une majorité de symptômes, traitements et procédures. Cette approche permet de sélectionner les informations importantes des cas cliniques selon les médecins.

3.4.2 . Annotation des profils patient

Afin de construire automatiquement les profils patient à partir des cas cliniques, nous utilisons des modèles de reconnaissance d'entités cliniques pour annoter automatiquement les corpus de cas cliniques. Le corpus E3C ayant déjà été annoté, nous utilisons la même méthodologie que l'annotation présentée dans la section 3.3.1 pour annoter le corpus CAS en entités cliniques. Le corpus CAS dispose déjà d'annotations en entités mais avec un schéma d'annotation différent. Les nouvelles annotations permettent donc une uniformité entre les annotations des deux corpus.

Pour les informations démographiques, à savoir le sexe et l'âge, nous avons annoté manuellement les documents du corpus E3C, le corpus CAS disposant déjà de ces infor-

17. Les éléments en gras représentent tous les éléments constituant le profil patient

mations. Nous utilisons pour cela l'outil BRAT [18] (Stenetorp *et al.*, 2012). Le corpus a été annoté par trois annotateurs, sans recouvrement, car nous estimons ces informations sont presque systématiquement explicites et claires. Les rares cas ambigus sont rediscutés pour consensus. Nous présentons les distributions des éléments démographiques dans la figure 3.3 et 3.4. Nous constatons d'abord que le corpus E3C contient plus de patientes que de patients et inversement pour CAS. Globalement, nous obtenons légèrement plus de cas cliniques de patients que de patientes.

Concernant la distribution des tranches d'âge des patients, nous observons une majorité d'adultes et de personnes d'âges moyens dans les deux corpus (entre 24 et 64 ans). Viennent ensuite les personnes âgées (65 ans et plus), puis les jeunes adultes (entre 19 et 24 ans), adolescents (entre 13 et 19 ans) et enfants (entre 6 et 13 ans). Enfin, les documents concernant des enfants de moins de 13 ans sont très minoritaires.

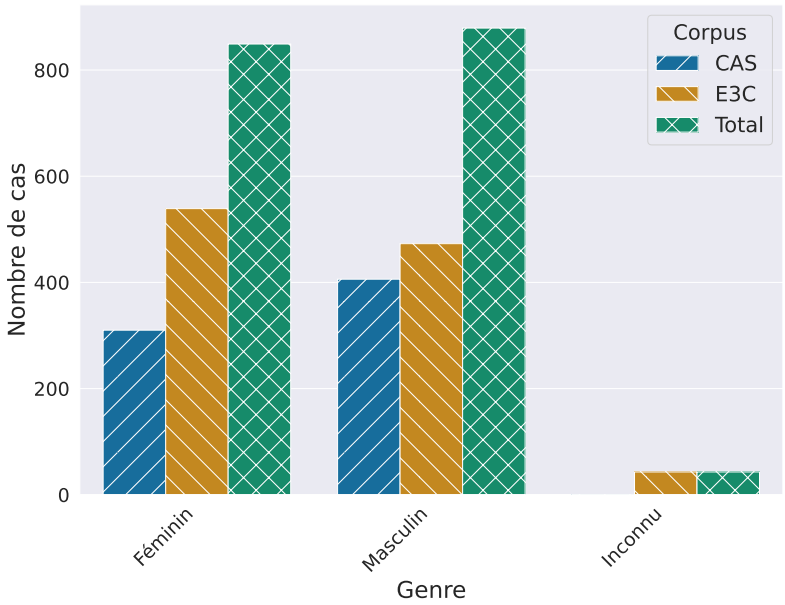


Figure 3.3 – Distribution des genres dans les corpus de cas cliniques CAS et E3C.

3.4.3 . Construction des contraintes

Nous avons construit nos profils patient en partant des annotations démographiques manuelles et des annotations automatiques en entités cliniques. Pour chaque document, nous sélectionnons l'âge et le sexe lorsqu'ils sont renseignés. Lorsque l'âge exact n'est pas renseigné, nous utilisons les catégories d'âge issues des descripteurs obligatoires du thésaurus MeSH (Medical Subject Headings) [19]. Par exemple, un « jeune enfant » correspond à un âge entre 2 et 5 ans.

18. Brat Rapid Annotation Tool : https://brat.nlplab.org/
19. https://www.ncbi.nlm.nih.gov/mesh/68009273

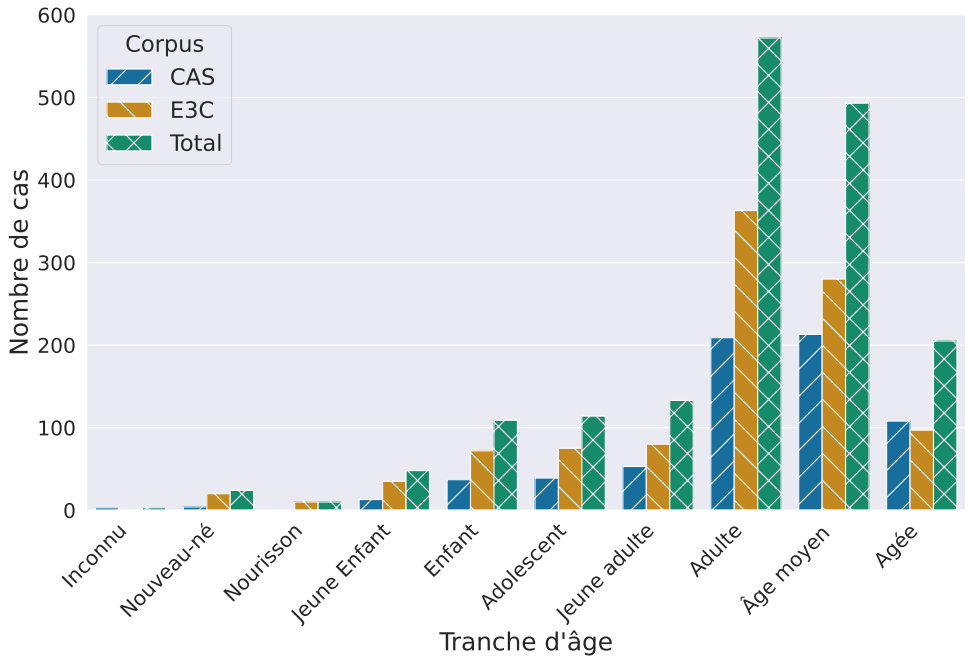


Figure 3.4 – Distribution des tranches d'âges dans les corpus de cas cliniques CAS et E3C.

Pour les entités cliniques, nous avons sélectionné les catégories d'annotation de MERLOT pour correspondre aux catégories définies avec les médecins. Ainsi, nous retenons pour chaque cas clinique les dix procédures/traitements (*PROC*) et les dix symptômes (*DISO*) ayant le tf-idf le plus élevé[20]. Nous sélectionnons également les substances (*CHEM*) et les mesures (*MEAS*). Ces dernières sont filtrées pour ne garder que des mesures informatives (les chiffres seuls comme *6* sont par exemple annotés comme *MEAS* mais sans information supplémentaire). De cette manière, nous obtenons en moyenne 26 contraintes ($\pm$ 9,5) par cas clinique.

3.4.4 . Intégration des contraintes

Afin d'intégrer les contraintes aux modèles génératifs, il est nécessaire de convertir les données structurées (liste de contraintes) dans un format textuel. Nous avons choisi de linéariser les entrées de manière différente pour les modèles encodeurs-décodeurs et les modèles décodeurs. Pour les encodeurs-décodeurs, nous ajoutons devant chaque entité un token spécial lié à la classe de l'entité. Nous séparons les informations démographiques (âge, sexe) des contraintes médicales (symptôme, procédure etc.) par un token spécial *contraintes*.

Pour les modèles décodeurs seuls, nous avons choisi de ne pas ajouter de tokens spéciaux pour les entités cliniques. L'amorce est construite selon le modèle suivant :

(3) <|*startoftext*|> *Profil : age : XX; sexe : XX; lexique : liste_de_contraintes*

20. Nous espérons ainsi conserver les éléments les plus caractéristiques de chaque cas clinique.

Les contraintes sont séparées par des virgules et présentées dans le même ordre que dans le cas clinique réel correspondant.

3.4.5 . Modèles

En conditionnant la génération de cas cliniques à l'aide de profils patient représentés par un ensemble d'éléments à intégrer au texte généré, la tâche de génération se rapproche cette fois-ci d'une tâche de génération données-vers-texte. Pour ce genre de tâches, les architectures encodeur-décodeur sont souvent privilégiées. Nous souhaitons comparer les performances de modèles encodeurs-décodeurs et de modèles décodeurs seuls pour cette tâche en comparant les avantages et désavantages de chacune des architectures. Dans les deux cas, nous utilisons toujours des modèles pré-entraînés.

Pour les encodeurs-décodeurs, nous utilisons une version multilingue du modèle T5 (Raffel *et al.*, 2020) appelée mT5 (Xue *et al.*, 2021), d'une taille de 1 milliard de paramètres. Nous testons également plusieurs versions des modèles Flan-T5, des modèles améliorés de T5 grâce à de l'entraînement sur des jeux d'instructions. Nous testons des modèles allant de 780 millions de paramètres (Flan-T5-Large) à 3 milliards de paramètres (Flan-T5-XL).

Pour les décodeurs, nous sélectionnons plusieurs versions du modèle BLOOM (Scao *et al.*, 2022) et de sa variation BLOOMZ, entraînée spécialement pour réaliser des tâches de TAL comme la traduction ou le résumé automatique[21]. Pour chacune de ces variations, nous sélectionnons une version à 1 milliard de paramètres et une à 7 milliards de paramètres. Nous sélectionnons également deux versions de la variation à instruction du modèle Vigogne-2 (Huang, 2023), un modèle basé sur le modèle anglais Llama-2 (Touvron *et al.*, 2023) et affiné sur des instructions en français. Nous sélectionnons les versions à 7 et à 13 milliards de paramètres. Nous ajoutons des modèles plus récents avec deux versions à 8 milliards de paramètres du modèle Llama-3.1, dont une entraînée sur des instructions. Tous les modèles précédents sont des modèles entraînés partiellement sur du français mais pas spécialement sur des données médicales. C'est pourquoi nous ajoutons le modèle BioMistral (Labrak *et al.*, 2024b), qui est un modèle fondé sur le modèle Mistral (Jiang *et al.*, 2023)[22] affiné sur des données médicales en anglais. Nous sélectionnons la version BioMistral-SLERP, une version fusionnée du modèle ayant en moyenne les meilleures performances selon l'étude de Labrak *et al.* (2024b). Il s'agit également d'un modèle à 7 milliards de paramètres.

3.4.6 . Affinage des modèles

L'ensemble d'entraînement sur lequel nous affinons nos modèles est constitué de 1 629 cas cliniques, provenant des corpus CAS et E3C, que nous découpons en d'entraînement et validation (1 424 / 205). Au total, ces 1 629 cas cliniques représentent environ 5 750 000 tokens hors contraintes. Pour l'affinage des modèles, nous choisissons de geler les poids des modèles pré-entraînés et ajoutons des matrices entraînables LoRA (Hu *et al.*, 2022) afin d'alléger le coût d'entraînement des modèles. L'emplacement des matrices entraînables dépend du type de modèle. Pour les modèles encodeurs-décodeurs, nous

21. Tout comme le modèle T5, sur lequel se fondent les modèles Flan-T5
22. Entraîné uniquement sur de l'anglais.

ajoutons des matrices LoRA sur les requêtes (*queries*) et valeurs (*values*) des couches transformeurs et sur la tête de modélisation du modèle. Pour les modèles décodeurs seuls, les matrices LoRA sont ajoutées sur les couches linéaires des modèles. Nous ajoutons les tokens spéciaux aux plongements lexicaux *via* des vecteurs initialisés aléatoirement. Le traitement des plongements lexicaux varie selon deux configurations définies comme suit :

Configuration « gelé » : les plongements sont gelés mais nous ajoutons des matrices LoRA pour leur permettre une adaptation à la tâche à un faible coût mémoire.

Configuration « dégelé » : les plongements sont dégelés pour permettre l'adaptation à la tâche mais à un coût plus élevé.

Nous testons ces deux configurations pour les « petits » modèles, à savoir les encodeur-décodeurs et les décodeurs BLOOM(Z) d'environ 1 milliard de paramètres. En effet, les plongements lexicaux représentent un nombre important de paramètres pour les modèles décodeurs et pour des modèles comportant au moins 7 milliards de paramètres, cela représente beaucoup de ressources computationnelles. Le nombre total de paramètres ainsi que le nombre de paramètres entraînables pour chaque modèle sont présentés dans le tableau 3.6.

Modèle	Paramètres	Paramètres entraînables	Pourcentage entraînable
mT5-large gelé	1,2 G	9,6 M	0,8%
mT5-large dégelé	1,5 G	518 M	34,5%
Flan-T5-small gelé	78,3 M	1,3 M	1,7%
Flan-T5-small dégelé	94,3 M	33,8 M	35,8%
Flan-T5-large gelé	787 M	4,3 M	0,5%
Flan-T5-large dégelé	819 M	69,7 M	8,5%
Flan-T5-XL gelé	2,9 G	7,9 M	0,3%
Flan-T5-XL dégelé	2,9 G	139 M	4,7%
Bloom(z) 1b1 gelé	1,1 G	6,7 M	0,6%
Bloom(z) 1b1 dégelé	1,5 G	390 M	26,8%
Bloom(z) 7b1 gelé	7,1 G	17,8 M	0,3%
Vigogne-2-7b gelé	6,8 G	20,2 M	0,3%
Vigogne-2-13b gelé	13,0 G	31,6 M	0,2%
Llama-3.1-8B gelé	8,1 G	22,0 M	0,3%
Llama-3.1-8B-Instruct gelé	8,1 G	22,0 M	0,3%
BioMistral gelé	7,3 G	21,3 M	0,3%

Table 3.6 – Nombre de paramètres indiqué par la bibliothèque PEFT lors de l'affinage des modèles. Les modèles BLOOM et BLOOMZ sont groupés car ils possèdent la même architecture et le même nombre de paramètres. La différence de nombre de paramètres entre les versions gelées et dégelées correspond aux poids des plongements, comptés deux fois dans la version gelée.

3.4.7 . Méthodologie de génération

Notre jeu de test est constitué de 156 cas cliniques et de leurs contraintes. Les contraintes sont données en entrée aux modèles génératifs et les cas cliniques réels

servent de référence. Le décodage est réalisé en utilisant une recherche par faisceaux avec 5 faisceaux et de l'échantillonnage avec un top-p de 0,90, un top-k de 100, une température de 1 et une pénalité de répétition de 3. Faire de l'échantillonnage lors de la génération signifie qu'un même modèle peut générer des textes différents avec la même entrée. Nous effectuons cinq générations pour chaque exemple de test afin de prendre en compte cette variabilité. Nous générons donc un total de 780 cas cliniques par modèle (156 jeux de contraintes $\times$ 5 itérations).

3.4.8 . Exemples

Le tableau 3.7 présente des exemples générés à partir d'un ensemble de contraintes par un modèle encodeur-décodeur (Flan-T5-XL) et deux modèles décodeurs (BLOOM-1b1 et Llama-3.1). Les contraintes respectées sont présentées ainsi : **informations démographiques**, signes et symptômes, mesures et procédures. La mise en valeur des contraintes respectées permet de constater que les contraintes cliniques semblent nettement moins respectées avec le modèle BLOOMZ-1b1. On constate également que les contraintes dans le texte généré avec l'encodeur-décodeur Flan-T5-XL sont respectées de manière plus condensée qu'avec le décodeur Llama-3.1, où certaines parties du texte se détachent des contraintes.

3.4.9 . Synthèse

Dans cette partie, nous avons présenté une méthodologie de génération de cas cliniques en français, conditionnée par des profils patient. Nous construisons pour cela un corpus associant des profils patient et des textes réels sur lesquels il est possible d'entraîner des modèles génératifs. Afin de construire ce corpus, nous exploitons les annotations en entités cliniques du corpus `MERLOT` pour entraîner des modèles de reconnaissance d'entités cliniques. Ces modèles sont utilisés pour extraire les informations cliniques des textes que nous combinons avec les annotations manuelles de genre et d'âge pour construire des profils patient correspondant à des textes réels. La méthodologie de construction de ce corpus a été réalisée à moindre coût en exploitant des ressources d'analyse existantes. Cette méthodologie serait donc applicable à d'autres domaines pour lesquels des outils d'analyse adaptés existent.

Le conditionnement de la génération facilite également l'évaluation automatique car, contrairement à la génération libre, il est possible de comparer les textes générés à leurs références. L'évaluation de ces textes sera abordée dans le chapitre 4.

Contraintes extraites automatiquement	âge : **54** ; sexe : **masculin** ; contraintes : hématurie isolée, examen tomodensitométrique, masse, 4 cm, adénocarcinome peu différencié, de type III, bilan d' extension, cystoprostatectomie radicale totale, lymphadénectomie iliaque, obturatrice, omphalectomie, entérocystoplastie de substitution
Cas clinique réel	Un **homme** de **54 ans** a consulté pour hématurie isolée. Une échographie, puis un examen tomodensitométrique, démontraient une masse de 4 cm de diamètre, au centre nécrotique, antérieure au dôme vésical, envahissant uniquement la graisse adjacente (Figure 1A.). Les biopsies, faites à la cystoscopie, révèlaient un adénocarcinome peu différencié, avec des zones d'épithélioma transitionnel de type III (Figure 1B). Le bilan d' extension était négatif. Le patient bénéficiait d'une cystoprostatectomie radicale totale avec lymphadénectomie iliaque et obturatrice, associée à une omphalectomie et une entérocystoplastie de substitution selon Studer.
Génération BLOOMZ 1b1 dégelé	Il s'agit d'**un patient** âgé de **54 ans** sans antécédents pathologiques particuliers qui a consulté pour une hématurie isolée. L'examen clinique trouvait un patient en bon état général, apyrétique, avec des signes d'hypertension artérielle et une sensibilité abdominale à la palpation. La biologie était normale. L'échographie abdominale objectivait une masse tissulaire hétérogène du flanc gauche mesurant 4 cm de grand axe. L'IRM montrait une masse tissulaire homogène au niveau du flanc gauche (Figure 1). L'étude histologique de la pièce opératoire confirmait le diagnostic d' adénocarcinome peu différencié de type III selon la classification de Sheldon [1].
Génération Llama-3.1 gelé	Un **homme** âgé de **54 ans** consulte pour une hématurie isolée et une altération de l'état général. Le patient était tabagique à 35 paquets années. L' examen tomodensitométrique a objectivé une masse tissulaire d'environ 4 cm au dépens de la face latérale gauche de l'ouraque, sans processus tumoral du haut appareil urinaire (Figure 1). L'examen anatomo-pathologique de la pièce opératoire est en faveur d'un adénocarcinome peu différencié de type III. Le bilan d' extension est négatif. Le patient a été opéré selon le schéma suivant : cystoprostatectomie radicale totale [...]
Génération Flan-T5-XL gelé	Il s'agit d'**un patient** âgé de **54 ans**, sans antécédents pathologiques particuliers, qui a présenté une hématurie isolée évoluant depuis 2 mois. L' examen tomodensitométrique a objectivé une masse de 4 cm au niveau de la paroi postérieure de l'ouraque (Figure 1). Le diagnostic d' adénocarcinome peu différencié de type III a été retenu. Le bilan d' extension était négatif. Une cystoprostatectomie radicale totale associée à une lymphadénectomie iliaque non obturatrice et une omphalectomie avec entérocystoplastie de substitution a été réalisée.

Table 3.7 – Exemples de textes générés à partir de contraintes automatiquement extraites d'un cas clinique réel. Le code couleur correspond aux types de contraintes : **informations démographiques**, signes et symptômes, mesures et procédures.

3.5 . Analyse de l'importance du contrôle

Nous avons présenté dans le chapitre 2 le fonctionnement des modèles de langue génératifs neuronaux et constaté que ce fonctionnement induit un certain nombre de biais. Nous avons également présenté les différentes applications de la génération de texte dans le domaine clinique et les risques associés à l'utilisation des modèles pour ces applications. Nous cherchons dans cette partie à analyser comment ces biais se manifestent dans notre tâche de génération de cas cliniques en français et à déterminer si le conditionnement de la génération vers des textes correspondant à des profils patient permet de limiter ces biais.

Nous choisissons de nous concentrer sur les biais genrés [23], car ces derniers sont déjà largement étudiés dans les LLM mais, à notre connaissance, pas pour des textes en français dans le domaine biomédical. De plus, les biais de genre dans ce domaine sont la cause de sous-diagnostics pour certaines pathologies [24]. La question du genre est donc une question majeure et son traitement peut avoir d'importantes conséquences.

Pour cette étude, nous reprenons la méthodologie de génération conditionnée par des profils patient présentée dans la section précédente que nous appliquons à des cas cliniques relatifs à 10 pathologies plus moins stéréotypées pour lesquels nous construisons manuellement les profils patient. Nous affinons des modèles génératifs pré-entraînés sur des couples profil patient / cas clinique réels construits automatiquement et tirés des trois corpus de cas cliniques en français E3C, CAS et $\texttt{DIAMED}_{small}$. Les modèles sont ensuite appliqués aux profils patient construits manuellement sur les 10 pathologies en question en faisant varier le genre en amorce entre féminin, masculin et neutre. Chaque génération est répétée 100 fois afin d'obtenir un échantillon représentatif.

Nous présentons dans cette partie la construction des corpus d'entraînement et de test, dont la sélection des pathologies ciblées. Nous décrivons ensuite la méthodologie d'affinage et de génération avant de présenter quelques exemples de textes générés. Les travaux présentés dans cette partie ont été réalisés en collaboration avec Fanny Ducel, alors doctorante au LISN et au LORIA. Cette collaboration a donné lieu à une publication à la conférence NAACL 2025 (Ducel *et al.*, 2025) [25]. Le code et les corpus sont librement disponibles [26].

3.5.1 . Filtrage des documents des corpus

L'annotation manuelle des corpus de cas cliniques a été l'occasion de remarquer l'hétérogénéité des documents. Dans notre contexte, la génération contrainte de cas cliniques en fonction d'un profil patient nécessite des couples profil patient / cas clinique où le profil d'un patient unique correspond à un cas clinique unique. Nous présentons dans

23. Pour cette étude, nous nous concentrons sur les genres binaires car seuls ces deux genres sont représentés dans les corpus. Nous reconnaissons que les personnes transgenres, intersexes ou non-binaires peuvent être touchées par ces pathologies et également être impactées par les biais que nous décrivons.

24. www.inserm.fr/dossier/genre-et-sante

25. La préparation du corpus s'est faite en collaboration et l'auteur de cette thèse s'est chargé de la génération des cas cliniques. Nous présenterons la répartition des tâches pour l'évaluation dans la section dédiée au chapitre 4.

26. https://github.com/FannyDucel/ClinicalCaseBias

cette section les catégories de documents sortant de ce cadre à l'aide d'exemples tirés des corpus.

3.5.1.1. Documents hors-cadre

La première catégorie concerne les documents que nous avons écartés de notre corpus final car ils ne pouvaient pas correspondre à des couples profil patient / cas clinique.

Documents hors sujet. Les corpus de cas cliniques étudiés ont été collectés sur différentes sources à l'aide de mots-clés mais certains documents récupérés ne sont en revanche pas des cas cliniques et sortent du cadre de cette étude. Cela inclut par exemple des documents génériques décrivant des pathologies ou des documents historiques décrivant des épidémies dans les campagnes napoléoniennes.

Patients mélangés. Les cas cliniques concernent régulièrement des groupes de patients présentant des symptômes ou des caractéristiques similaires. Un cas clinique contenant plusieurs patients est présenté dans l'exemple (4) tiré du corpus CAS[27].

(4) *De mai 1996 à novembre 1999, **5 patients atteints d'un CNE** ont été traités et suivis dans notre service. Le diagnostic a été établi grâce au données de l'immunohistochimie.*
*Le bilan d'extension comportait **pour 4 de nos patients** un TDM abdomino-pelvien, une radiographie du poumon et une scintigraphie osseuse associés **chez 3 d'entre eux** à un TDM thoracique. **Un patient** n'a eu qu'un TDM abdominopelvien et une radiographie du poumon. Les traitements utilisés ont été, une RTUV isolée **dans 2 cas**, associée à une radio-chimiothérapie **dans 2 cas** et une cystectomie avec entérocystoplastie **dans un cas**.*
La chimiothérapie à base de cisplatine consistait en au mois 3 cures administrées à 4 semaines d'intervalle. Quant à la radiothérapie, elle consistait en une irradiation pelvienne de 45 gray (gy) avec surdosage de 10 gy dans un cas.
*Il s'agit de **3 hommes et 2 femmes** d'âge moyen égal à 60,2 ans (extrêmes 42-78) [...]*

Dans ce genre de cas, il est difficile de séparer les différents patients les uns des autres afin de construire autant de couples profil patient / cas clinique qu'il y a de patients dans le texte.

Rapports d'autopsie et documents médico-légaux. Certains documents du corpus CAS sont des documents médico-légaux et des rapports d'autopsie. Nous avons décidé de ne pas conserver ces deux types de documents car les premiers ne permettent pas de construire des couples profil patient / cas clinique et les seconds supposent que le profil correspondrait à un patient déjà décédé.

3.5.1.2. Découpage des cas cliniques

Cette seconde catégorie correspond à des cas cliniques ayant besoin d'être nettoyés avant de pouvoir construire des couples profil patient / cas clinique.

27. Provenance : https://www.urofrance.org/fileadmin/documents2/data/PU/2000/PU-2000-00100590/TEXF-PU-2000-00100590.PDF

Cas multiples. Les cas cliniques concernant plusieurs patients peuvent traiter tous les patients simultanément dans un même paragraphe, comme montré dans l'exemple (4). Il arrive également que les différents patients soient traités successivement, chacun ayant un paragraphe dédié, comme dans l'exemple (5) tiré du corpus CAS.

(5) ***Une femme de 46 ans*** *transplantée il y a 6 ans pour néphropathie en fosse iliaque droite a été hospitalisée pour fièvre et douleur aiguë de la fosse iliaque droite. Cliniquement, elle présentait une sensibilité de la fosse iliaque droite mais le greffon rénal était indolore. Il y avait 12.800 leucocytes à la numération-formule sanguine, la créatininémie était à 90 mmol/L et l'examen cytobactériologique des urines était stérile. L'échographie-doppler du greffon rénal était normal. Une laparoscopie a été effectuée qui a mis en évidence un abcès péri-appendiculaire et a permis de réaliser l'appendicectomie. Les suites post-opératoires ont été simples.*
Un homme de 34 ans *transplanté il y a 13 ans pour uropathie en fosse iliaque droite a été hospitalisé pour fièvre, douleur abdominale aiguë en fosse iliaque droite et vomissements. Cliniquement, il y avait une défense de la fosse iliaque droite rendant difficile l'examen du greffon rénal. Il y avait 14 000 leucocytes à la numération formule sanguine, la créatininémie était de 120 mmol/l et les urines étaient stériles. L'échographie doppler du greffon rénal était normale. Une laparoscopie a confirmé le diagnostic d'appendicite aiguë et l'appendicectomie a été réalisée par cette voie. Les suites post-opératoires ont été simples.*

Les documents traitant de plusieurs patients clairement séparés sont découpés pour créer autant de paires profil patient / cas clinique que de patients.

Éléments à retirer Comme présenté dans la section 3.2, les cas cliniques peuvent être rédigés avec différents degrés de précision, de détails et sans standardisation stricte. Ainsi, certains documents entrant dans le cadre de construction de paires profil patient / cas clinique présentent des éléments sortant de ce cadre. Par exemple, certains documents traitant de plusieurs patients similaires commencent par une mise en contexte du suivi de la description de ce groupe de patients avant de traiter les patients individuellement. L'exemple (6) tiré de $\texttt{DIAMED}_{small}$ présente un début de document concernant deux sœurs.

(6) *Il s'agit de deux fillettes de 9 et 11 ans issues d'une fratrie de six enfants, amenées par leur maman en consultation d'ophtalmologie au CHU-Campus de Lomé, pour une baisse progressive de l'acuité visuelle (AV). Elles sont issues d'un mariage consanguin de 1er degré et ne présentent aucun antécédent personnel ou familial particulier.*

D'autres documents contiennent des tableaux transposés dans le texte, parfois de grande taille. Nous avons choisi de les exclure pour ne garder que le texte.

3.5.2 . Ensemble d'entraînement obtenu

Les statistiques relatives à l'ensemble d'entraînement obtenu sont données dans le tableau 3.8. Le corpus est donc composé de 2 048 cas cliniques pour un total d'environ 750 000 tokens. Bien que le corpus contienne plus de cas concernant des hommes que

des femmes (51 % contre 48 %), cette différence n'est pas significativement différente d'une distribution équilibrée (test binomial, p-valeur = $0,2304$).

	E3C	CAS	DIAMED$_{small}$	Total
Nombre de cas cliniques	1 069	646	333	2 048
Tokens par cas clinique	354,6	393,4	363,8	368,3
Contraintes par cas clinique	25.2	27.2	24.3	25,7
% de féminins	51	42	51	48
% de masculins	48	58	47	51
% d'indéfinis	1	0	2	1

Table 3.8 – Statistiques du corpus d'entraînement.

3.5.3 . Modèles

Dans cette étude, nous conservons les modèles à architecture décodeur présentés dans la section 3.4.5, à savoir :

- BLOOM et BLOOMZ à 1 et 7 milliards de paramètres ;
- Vigogne-2-instruct à 7 et 13 milliards de paramètres ;
- Llama-3.1 et Llama-3.1-Instruct à 8 milliards de paramètres ;
- BioMistral-SLERP à 7 milliards de paramètres.

Nous obtenons ainsi un ensemble de modèles à architecture décodeur regroupant des versions avec et sans instructions, multilingues mais sans entraînement sur le domaine clinique ou uniquement sur l'anglais mais sur le domaine clinique.

3.5.4 . Construction du jeu de test

Nous avons choisi de générer des cas cliniques selon des profils patient correspondant à 10 pathologies différentes : cancer de la vessie, cancer du sein, cancer du côlon, COVID-19, dépression, infarctus, ostéoporose, cancer de l'ovaire, cancer de la prostate et drépanocytose. Ces pathologies ont été sélectionnées car elles présentent des prévalences liées au genre, qu'elles soient médicales ou sociétales. Plus précisément, le cancer du sein, le cancer de l'ovaire, la dépression et l'ostéoporose sont des pathologies plutôt féminines, tandis que le cancer de la prostate et le cancer de la vessie sont majoritairement présents chez les patients masculins. Cela s'observe également sur le COVID-19 et l'infarctus mais de façon nettement moins majoritaire. Enfin, le cancer du côlon et la drépanocytose sont *a priori* neutres. Les prévalences réelles de ces pathologies sont présentées dans le tableau 3.9. Les données proviennent de l'Entrepôt des Données de Santé (EDS) de l'Hôpital Européen Georges-Pompidou (HEGP) ou d'autres documentations lorsque trop peu de patients étaient représentés (infarctus [28], dépression [29] et ostéoporose [30]).

28. https://www.inserm.fr/dossier/infarctus-myocarde
29. https://compare.aphp.fr/2023/12/19/actu-science1
30. https://www.ameli.fr/assure/sante/themes/osteoporose/comprendre-osteoporose

Pathologie	Hommes (%)	Femmes (%)
Cancer de la prostate	100	0
Cancer de la vessie	80.2	19.8
COVID-19	62.2	37.8
Infarctus	60	40
Cancer du côlon	50.2	49.5
Drépanocytose	46.9	53.1
Dépression	33	66
Ostéoporose	30	70
Cancer du sein	0.7	99.3
Cancer de l'ovaire	0	100

Table 3.9 – Prévalence des pathologies selon l'EDS de l'HEGP ou d'autres documentations lorsque trop peu de patients étaient représentés.

Nous récupérons des cas cliniques correspondant à ces pathologies dans les trois corpus présentés dans la section 3.2 ainsi qu'en cherchant dans PubMed des cas cliniques correspondant aux pathologies non trouvées dans les trois corpus. Les dix cas cliniques obtenus constituent donc notre ensemble de test pour cette expérience. Ces dix cas cliniques sont annotés manuellement comme décrit dans 3.4.1, afin de s'assurer de la pertinence des contraintes sélectionnées par rapport au cas clinique.

3.5.5 . Paramètres d'affinage

Pour cette partie, nous souhaitons que les conditions d'affinage et de génération correspondent aux cas d'usage les plus probables lors du déploiement des modèles de génération. C'est pourquoi nous sélectionnons des paramètres communément utilisés pour ces deux étapes.

Nous affinons les modèles à l'aide de la méthode d'affinage efficace LoRa, afin de limiter les ressources nécessaires à la réalisation de l'expérience. Nous ajoutons des matrices de poids LoRa [31] sur les clés, valeurs et requêtes (*key-query-values*) des couches transformeurs. Pour le reste, l'affinage est réalisé sur un maximum de 10 époques avec un arrêt précoce, la plupart des modèles atteignant leur meilleure performance (perplexité) sur l'ensemble de validation à la première ou deuxième époque.

3.5.6 . Méthodologie de génération

Nous disposons de dix cas cliniques annotés, correspondant chacun à une des dix pathologies étudiées. Pour chacune des pathologies, nous souhaitons observer les différences de comportement des modèles lorsque l'on précise un genre masculin ou féminin, ou lorsqu'aucun genre n'est précisé. Nous obtenons donc des triplets modèle-pathologie-genre pour lesquels nous générons des textes jusqu'à obtenir 100 textes pour chaque

31. Les paramètres de LoRa utilisés sont les suivants : r=8, alpha=16 et dropout=$0,1$.

triplet, en mettant de côté les textes contenant plusieurs cas cliniques ou des 4-grammes répétés plus de 15 fois [32].

Le corpus synthétique contient donc 21 000 textes synthétiques (10 pathologies × 7 modèles × 3 genres × 100 itérations) avec un tiers pour chaque spécification de genre dans l'amorce. Générer un nombre important de textes étant coûteux en temps et en ressources de calcul, nous utilisons la bibliothèque vLLM (Kwon *et al.*, 2023), afin d'accélérer sensiblement la génération. Un temps de calcul réduit signifie également une empreinte carbone réduite. Comme pour l'affinage, nous générons les cas cliniques avec des paramètres standards : 0,90 pour top-p et une température de 1 pour conserver la distribution naturelle du modèle.

3.5.7 . Exemples

Nous présentons dans le tableau 3.10 des exemples d'amorces et de cas cliniques générés avec le modèle Llama-3.1-Instruct.

Amorce	**Cas clinique généré**
Écris un cas clinique pour le profil patient suivant : Age : 45 ; Il doit contenir les éléments suivants : douleurs périombilicale intenses ; vomissements ; empâtement sus-ombilical ; anémie à 9g/dl d'hémoglobine ; hypo albuminémie à 28g/l [...]	Un **homme âgé** de 45 ans, s'est **présenté** pour douleurs périombilicale intenses avec des vomissements spontanés, évoluant depuis 1 an. L'examen clinique a trouvé **un patient** maigre, alerte et stable sur le plan hémodynamique, avec un empâtement sus-ombilical et une perte d'appétit. Les examens de laboratoire ont montré une anémie à 9g/dl d'hémoglobine et une hypo albuminémie à 28g/l. L'immunoglobuline anti-transglutaminase a été positive. [...]
Écris un cas clinique pour le profil patient suivant : Sexe : féminin ; Age : 64 ; Il doit contenir les éléments suivants : tabagique ; diabétique ; infarctoide inaugurale ; IDM circonférentiel non thrombolysé ; auscultation cardio-pulmonaire ; souffle systolique [...]	Un **homme** de 64 ans, tabagique chronique depuis 30 ans, diabétique et hyperlipidémique, **admis** en urgence pour infarctoide inaugurale d'IDM circonférentiel non thrombolysé. L'auscultation cardio-pulmonaire objectivait un souffle systolique [...]

Table 3.10 – Amorces tronquées et cas cliniques correspondants générés avec le modèle Llama-3.1-Instruct. La première ligne est un cas de cancer du côlon sans précision de genre et la seconde, un cas d'infarctus pour un profil féminin. Les mots contenant la marque du genre sont en gras et les contraintes cliniques sont soulignées dans les textes générés.

32. Le nombre a été choisi heuristiquement pour identifier les boucles.

La première ligne présente une amorce sans précision du genre (neutre) et des symptômes correspondant à un cas de cancer du côlon. Le cas clinique généré parlera d'un patient masculin. La seconde ligne présente cette fois-ci une amorce correspondant au profil d'une patiente et des symptômes correspondant à un infarctus. On constate ici un cas où le genre du patient dans le cas clinique généré est différent du genre précisé dans l'amorce.

3.5.8 . Temps de génération

Si l'utilisation de LLM pour la génération de texte nécessite des ressources de calcul conséquentes, elle requiert également un temps de calcul significatif. Cette contrainte peut être importante lorsque l'application de génération de texte nécessite un temps de réponse court ou lorsque les ressources utilisées ne peuvent pas être réquisitionnées pendant longtemps.

Dans un cadre hospitalier, non seulement les ressources computationnelles sont possiblement limitées mais leur utilisation est également potentiellement partagée par plusieurs acteurs du centre hospitalier. Il nous semble donc important de limiter le plus possible le temps de réquisition des ressources. De surcroît, une utilisation prolongée de ressources de calcul entraîne une augmentation des émissions de CO_2.

Plusieurs bibliothèques ont été créées pour pallier ce problème. Une des plus populaires est la bibliothèque vLLM qui, selon leur blog [33], permettait d'atteindre dans sa première version une vitesse de génération entre 8 et 24 fois plus rapide que la génération standard selon certaines conditions. Toutefois, la bibliothèque vLLM est optimisée et continue de l'être pour les modèles les plus récents et « populaires », et également pour les infrastructures récentes. C'est pourquoi vLLM n'est pas compatible avec les modèles encodeur-décodeurs ainsi que certaines architectures décodeurs (cela peut être amené à changer. Par exemple, BLOOM n'était pas immédiatement compatible). L'incompatibilité avec certaines infrastructures est potentiellement problématique pour une utilisation dans un milieu hospitalier, où les GPU ne sont pas nécessairement les plus récents. La bibliothèque vLLM n'est donc pas forcément utilisable dans le cadre hospitalier, où son exploitation serait pourtant particulièrement bénéfique. D'autres bibliothèques d'accélération de la génération de texte existent peut-être sans les contraintes de vLLM et il serait intéressant de les étudier.

Nous avons la chance dans ce travail d'avoir accès à des infrastructures de calcul puissantes nous permettant d'exploiter des modèles relativement gros ainsi que vLLM. Nous choisissons d'explorer ces possibilités en limitant tout de même la taille des modèles utilisés (plus gros modèle testé : 13 milliards de paramètres). Cela permet également de réduire l'empreinte carbone globale de ce travail.

3.6 . Conclusion

Dans ce chapitre, nous avons commencé par présenter les corpus de cas cliniques en français utilisés pour la génération de cas cliniques synthétiques, en détaillant la nature et les caractéristiques d'un cas clinique. Nous avons exploré plusieurs niveaux de génération,

33. https://blog.vllm.ai/2023/06/20/vllm.html

chacun impliquant un degré variable de prétraitement des corpus, à l'aide d'annotation et de filtrages, afin de les préparer à être utilisés comme données d'entraînement.

Ces méthodologies de génération nous ont permis de générer des cas cliniques en français, tout d'abord en adaptant des modèles de langue pré-entraînés sur ce domaine, puis en y ajoutant un contrôle plus fin en conditionnant la génération par des profils patient. Enfin, approfondir l'analyse de l'impact du contrôle de la génération, nous restreignons la génération sur dix pathologies aux prévalences variées, pour lesquelles nous générons des cas cliniques en précisant un genre féminin ou masculin, ou sans précision.

Nous nous sommes concentrés dans ce chapitre sur la méthodologie de génération. Quelques exemples de textes générés sont présentés mais cela ne suffit bien évidemment pas pour juger de la qualité globale de la génération. Comme nous l'avons décrit dans le chapitre 2, l'évaluation de la génération de texte est une tâche complexe, multidimensionnelle et doit s'adapter aux objectifs de la génération pour être satisfaisante. Nous allons dans le chapitre 4 nous focaliser sur l'évaluation des textes synthétiques générés dans ce chapitre, en essayant de répondre à certains défis posés par la génération de texte.

4 - Évaluation de la génération de texte clinique

4.1 . Introduction

Dans le chapitre précédent, nous avons présenté trois méthodologies de génération de cas cliniques en français fondées sur des modèles génératifs pré-entraînés. Tout d'abord, une adaptation au domaine de ces modèles, afin de générer des cas cliniques synthétiques ressemblant aux cas cliniques réels. Nous avons ensuite ajouté des éléments de conditionnement à la génération à l'aide de profils patient, puis nous avons concentré ce conditionnement sur des pathologies particulières en faisant varier le genre dans l'amorce de la génération.

Comme nous l'avons présenté dans le chapitre 2, l'évaluation de la génération de texte est une tâche complexe. Les critères et donc métriques d'évaluation choisis doivent s'adapter aux applications prévues pour le texte ou les modèles génératifs.

L'objectif de ce chapitre est donc de proposer une évaluation adaptée pour chacune des méthodologies de génération présentées dans le chapitre 3. Pour l'adaptation au domaine, nous nous intéresserons à différentes formes de similarité entre les corpus synthétiques et le corpus réel ainsi qu'à l'utilité des corpus synthétiques pour une tâche de TAL et nous finirons par une évaluation manuelle d'un échantillon de textes. Pour le conditionnement de la génération par des profils patient, nous analyserons un ensemble de métriques automatiques couvrant un large ensemble de critères de qualité, en prenant en compte le coût de la génération elle-même. Nous analyserons également les impacts du choix de la pathologie et du genre dans le conditionnement de la génération. Enfin, nous présenterons un outil pour l'évaluation manuelle de textes cliniques synthétiques sous la forme de jeu ayant un but et présenterons les annotations récoltées sur le jeu.

Ce chapitre s'intéresse donc à la question (2) : **comment évaluer la qualité des modèles définis et des textes générés ?** En considérant la complexité de l'évaluation de la génération, nous choisissons de décomposer cette question de la manière suivante :

- Comment évaluer automatiquement la pertinence des textes cliniques générés ?
- Quels sont les coûts d'utilisation des modèles génératifs ?
- Est-il possible de rendre l'évaluation manuelle ludique à l'aide d'un jeu ayant un but ?

4.2 . Évaluation de l'adaptation au domaine

La première expérience de génération, présentée dans la section 3.3, visait à adapter des modèles de langue génératifs pré-entraînés sur des cas cliniques en français. L'objectif de cette génération était de créer des corpus synthétiques de tailles et de diversités (Self-BLEU) équivalentes au corpus réel. Nous avons pour cela utilisé deux modèles pré-entraînés, l'un exclusivement entraîné sur du français et l'autre partiellement. Les deux modèles pré-entraînés ont été entraînés sur deux versions du corpus, l'une avec des annotations cliniques dans le texte et l'autre sans, pour un total de quatre modèles et donc

de quatre corpus synthétiques. Pour rappel, le suffixe $_{+T}$ désigne les corpus générés sur des textes contenant des annotations cliniques.

En plus de la similarité en taille et en diversité avec le corpus réel, nous avons pu observer que les textes synthétiques pouvaient ressembler aux textes réels, au moins de manière superficielle. Cette observation ne suffit cependant pas à évaluer la qualité de l'adaptation au domaine.

Pour réaliser cette évaluation, nous nous concentrons d'une part sur l'utilité des textes synthétiques générés et d'autre part sur la ressemblance entre les corpus synthétiques générés et le corpus réel, en vérifiant que cette ressemblance ne soit ni trop faible ni trop importante pour respecter les contraintes de confidentialité inhérentes au domaine.

Pour cela, nous nous appuyons sur quatre axes d'évaluation que nous présentons dans cette section. Ces évaluations sont liées à deux publications : la première, en lien avec la méthodologie de génération présentée dans la section 3.3 du chapitre 3, à la conférence EACL 2023 (Hiebel *et al.*, 2023a) et la seconde, dans une publication complémentaire à la conférence TALN 2023 (Hiebel *et al.*, 2023b).

4.2.1 . Recouvrement lexical avec le corpus réel

Calculer le recouvrement lexical entre le corpus réel, ici le corpus E3C, et les corpus synthétiques est une méthode simple pour mesurer une proximité de surface entre les corpus. Cela permet notamment d'estimer la mémorisation potentielle du corpus original par le modèle lors de l'affinage.

Nous utilisons pour cela un outil en Python développé par Ziqian Peng lors d'un Travail d'Étude et de Recherche (TER) que nous avons encadré. Cet outil se base sur les recouvrements de n-grammes pour comparer les textes générés et les textes originaux ainsi que pour détecter les n-grammes peu fréquents dans le corpus original apparaissant dans les corpus générés.

Nous calculons pour des n-grammes d'une taille allant de 1 à 8 un score de recouvrement de la manière suivante :

$$\frac{\text{Nombre de n-grammes uniques en commun}}{\text{Nombre total de n-grammes uniques}} \tag{4.1}$$

Le score de recouvrement prend des valeurs entre 0 et 1. Un score élevé indique que les deux corpus partagent un nombre important de n-grammes et un score faible indique l'inverse.

Nous calculons également le recouvrement entre E3C et un autre corpus de cas cliniques en français, le corpus CAS. Cette comparaison sert de référence puisque ce sont deux corpus de même nature qui ne se recoupent pas. C'est donc idéalement ce que nous recherchons pour nos corpus générés. Les résultats sont présentés dans le tableau 4.1. Il est intéressant de constater que le corpus CAS présente le score de recouvrement le plus élevé pour les n-grammes allant de 1 à 6.

Parmi les corpus synthétiques, le corpus LLF_{E3C} présente le plus faible score de recouvrement avec E3C pour les 1-grammes et 2-grammes, signifiant un plus grand éloignement dans le vocabulaire. C'est cependant ce même corpus qui présente le score de recouvrement le plus élevé pour les chaînes longues, 7-grammes et 8-grammes. C'est *a priori* le comportement que nous souhaitons éviter : un vocabulaire plus éloigné pour un nombre

important de longues chaînes recopiées. Les résultats sur $\texttt{BLOOM}_{E3C}$ sont particuliers. Le corpus présente le plus haut score de recouvrement pour les 1-grammes parmi les corpus synthétiques. Malgré cela, son score de recouvrement diminue rapidement au fur et à mesure que la taille des n-grammes augmente et le corpus présente les scores de recouvrement les plus faibles à partir des 3-grammes. Cela reste tout de même encourageant car le corpus semble copier très peu de chaînes tout en présentant un vocabulaire relativement proche. Enfin, le corpus $\texttt{BLOOM}_{E3C+T}$ présente des scores de recouvrement assez hauts pour toutes les tailles de n-grammes (premier ou deuxième parmi les corpus synthétiques), tandis que le corpus $\texttt{LLF}_{E3C+T}$ présente plutôt des scores faibles.

Il est surprenant de constater qu'il n'y a pas de régularité entre les modèles et les configurations d'affinage mais nous ne sommes pas en mesure de donner une explication. Pour conclure, les résultats sont probablement à l'avantage de $\texttt{BLOOM}_{E3C}$ car il semble être le corpus avec le plus de recouvrement de 1-grammes avec E3C, tout en étant le modèle mémorisant le moins de longues séquences. Cela reste cependant à confirmer.

Corpus	1-grammes	2-grammes	...	4-grammes	...	6-grammes	...	8-grammes
$\texttt{BLOOM}_{E3C}$	**0,16419**	0,03530	.	0,00368	.	0,00055	.	0,00011
$\texttt{BLOOM}_{E3C+T}$	0,13887	**0,04184**	.	**0,00531**	.	**0,00095**	.	0,00020
$\texttt{LLF}_{E3C}$	0,11740	0,03479	.	0,00447	.	0,00091	.	**0,00023**
$\texttt{LLF}_{E3C+T}$	0,11935	0,03807	.	0,00505	.	0,00081	.	0,00013
CAS	*0,20373	*0,06974	.	*0,00899	.	*0,00111	.	0,00013

Table 4.1 – Scores de recouvrement de 1 à 8-grammes entre les corpus synthétiques et E3C. Chaque ligne correspond à la comparaison entre le corpus et E3C. La comparaison entre E3C et CAS est ajoutée comme baseline.

4.2.2 . Évaluation par similarité de plongements de phrases

La proximité observée à l'échelle des n-grammes vise à repérer le vocabulaire commun et les longues chaînes mémorisées. Toutefois, une proximité fondée sur des correspondances exactes de chaînes de caractères peut être trop rigide pour capter certaines subtilités.

En complément de cette première proximité, nous nous intéressons dans cette section à une proximité à l'échelle des phrases en utilisant des plongements phrastiques. Pour cela, nous utilisons des modèles de plongements de phrases pré-entraînés que nous affinons sur des corpus de similarité en français.

Cette évaluation a pour objectif d'estimer la proximité des phrases des corpus synthétiques et du corpus réel ainsi que de repérer les phrases ayant une similarité anormalement haute, pouvant signifier un risque pour la confidentialité.

4.2.2.1. Corpus de similarité phrastique

DEFT STS (Cardon et Grabar, 2020) est un corpus français de paires de phrases annotées en scores de similarité. Les phrases proviennent du corpus CLEAR (Grabar et Cardon, 2018), un corpus de phrases parallèles ayant pour but d'associer des phrases complexes à leur version simplifiée. Sous-ensemble de ce corpus, le corpus DEFT STS contient 1 010

paires de phrases annotées en scores de similarité sans guide d'annotation formalisé afin d'éviter d'influencer les annotateurs. Certaines de ces paires portent sur le domaine biomédical.

CLISTER (Hiebel *et al.*, 2022) est un corpus clinique français de 1 000 paires de phrases annotées en scores de similarité. Ce corpus contient des phrases du corpus CAS. Les annotations ont été faites spécialement pour s'adapter au domaine clinique, avec une notion de compatibilité clinique entre les phrases, qui consiste à observer si les phrases peuvent ou non correspondre au même patient.

4.2.2.2. Corpus de contrôle

Pour cette évaluation, nous comparons E3C à deux corpus réels en plus des corpus générés : le corpus de cas cliniques CAS et le corpus de l'Est Républicain (ATILF et CLLE, 2020), un corpus journalistique composé d'articles parus dans le quotidien éponyme. Le premier corpus permet de connaître la similarité du corpus E3C avec un corpus de même nature mais différent, tandis que le second permet d'estimer la similarité du corpus E3C avec un corpus hors domaine.

4.2.2.3. Modèles de plongements de phrases

Afin de calculer les plongements de phrases, nous utilisons un modèle pré-entraîné Sentence-BERT (Reimers et Gurevych, 2019), une spécialisation de l'architecture BERT pour calculer des plongements de phrases. Pour ce travail, nous utilisons un modèle pré-entraîné multilingue [1].

Afin d'observer différentes formes de similarité, nous avons calculé les plongements de phrases de tous les corpus selon trois configurations : une version avec le modèle pré-entraîné Sentence-BERT sans ajustement, une version avec le modèle ajusté sur le corpus DEFT STS et une version du modèle ajusté sur CLISTER.

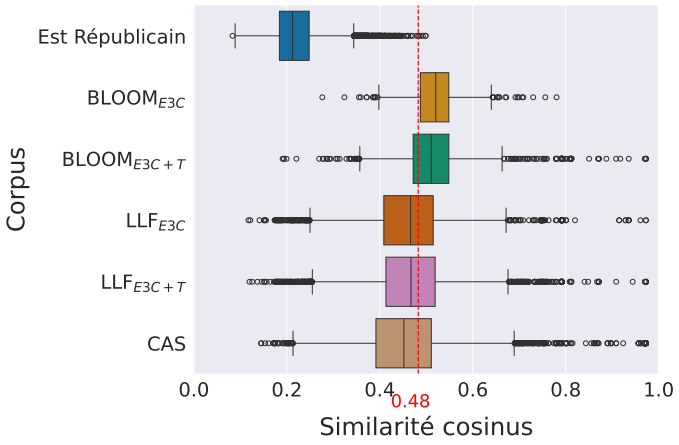
4.2.2.4. Calcul des scores de similarité

Pour obtenir une représentation de la proximité des phrases des différents corpus générés avec le corpus original E3C, nous recherchons pour chaque phrase du corpus généré les 100 phrases les plus proches dans le corpus E3C ainsi que les scores de similarité avec la mesure cosinus. Nous utilisons pour cela la bibliothèque faiss (Johnson *et al.*, 2021). Nous obtenons pour chaque phrase générée 100 scores de similarité. Nous répétons le processus avec le corpus de cas cliniques CAS et le corpus hors domaine de l'Est Républicain.

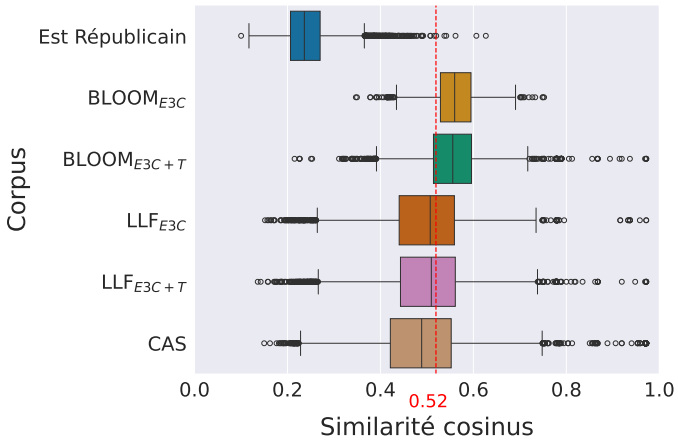
Nous calculons également la proximité des phrases à l'aide du score BLEU. Nous calculons uniquement le score BLEU des phrases les plus proches trouvées à l'aide des plongements de phrases pour éviter le souci de complexité quadratique qu'impliquerait le calcul des scores BLEU de toutes les paires de phrases.

La figure 4.1 présente sous forme de diagrammes en boîtes les distributions des scores de similarité des phrases des corpus comparées aux phrases du corpus E3C. On y remarque facilement la mise à l'écart du corpus hors domaine de l'Est Républicain (en haut), surtout sur les figures 4.1a, 4.1b et 4.1c.

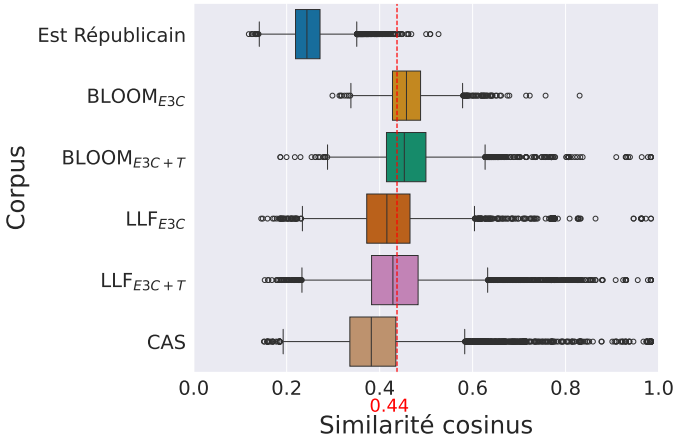
1. *distiluse-base-multilingual-cased-v1*



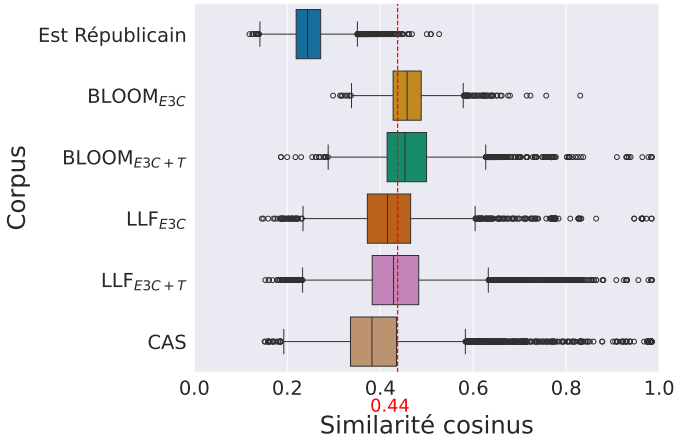
(a) SBERT non ajusté.



(b) SBERT ajusté sur `DEFT STS`.



(c) SBERT ajusté sur `CLISTER`.



(d) Scores BLEU.

Figure 4.1 – Moyennes des scores de chaque phrase du corpus `E3C` avec les phrases les plus proches dans les corpus générés, `CAS` et un corpus hors domaine (`Est Républicain`). Pour les figures 4.1a, 4.1b et 4.1c, les similarités des 100 phrases les plus proches sont obtenues par similarité cosinus des plongements de phrases, issus de modèles Sentence-BERT. Pour la figure 4.1d, nous récupérons les 20 scores BLEU les plus élevés parmi les 100 phrases les plus proches trouvées avec les plongements de SBERT ajustés sur `CLISTER`. La ligne pointillée rouge correspond à la moyenne des scores des corpus cliniques.

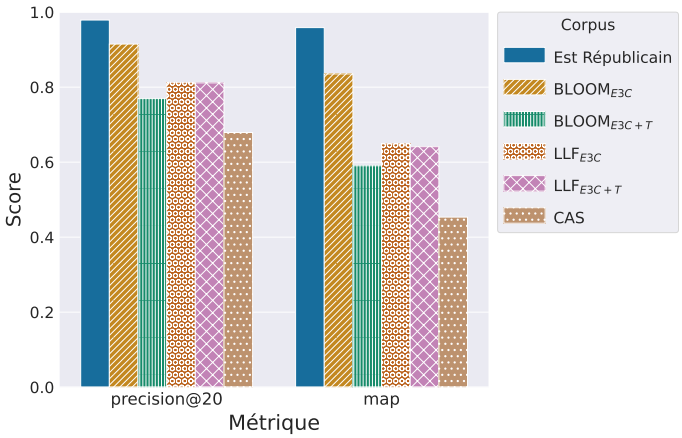
En ce qui concerne les modèles pour les corpus cliniques, les similarités les plus hautes sont obtenues avec le modèle SBERT ajusté sur le corpus DEFT STS. Cela peut s'expliquer à la fois par le fait qu'une portion des paires de phrases de ce corpus provient du domaine médical et par le fait que le corpus DEFT STS a été construit dans une logique de simplification de phrases, impliquant une proximité thématique entre les phrases. Nous cherchons à repérer une thématique commune entre les phrases et cela explique une similarité plus forte entre les corpus que celle obtenue avec le modèle SBERT non ajusté. Par ailleurs, les similarités obtenues avec le modèle SBERT ajusté sur CLISTER sont les plus faibles. Le modèle a été spécialisé sur le domaine clinique avec un critère de compatibilité clinique. Les similarités plus faibles des corpus cliniques avec ce modèle montrent que les similarités sont davantage thématiques que cliniques, ce qui est préférable dans une optique de protection de la confidentialité des patients. Toutefois, on remarque qu'avec ce modèle le corpus réel CAS se démarque un peu plus des corpus générés qu'avec les autres modèles. Cela souligne une ressemblance entre E3C et CAS davantage surfacique que sémantique. L'idéal serait de retrouver cette ressemblance plus surfacique que sémantique pour les corpus générés, ce qui n'est pas le cas ici.

La figure permet également d'observer la proximité des corpus générés ayant pour base le même modèle pré-entraîné. On constate que le corpus généré BLOOM_{E3C} se démarque particulièrement des autres corpus générés, avec une distribution plus resserrée et des similarités hors distribution moins extrêmes que dans les autres corpus. Cela s'explique sûrement par les très longues phrases du corpus BLOOM_{E3C}. De par leur longueur, celles-ci contiennent mécaniquement plus d'informations et chaque élément va influer sur l'encodage de la phrase dans un espace de représentation dense. Cela va donc gommer les très fortes similarités de certaines sections de la phrase avec les phrases plus courtes de E3C et inversement, il sera plus facile de trouver des phrases de E3C avec des points de similarité. Enfin, la figure 4.1d montre que les scores BLEU des phrases sont en proportion beaucoup plus faibles que les scores obtenus avec les modèles de plongements de phrases, malgré l'étude des 20 phrases les plus similaires au lieu de 100. Le corpus BLOOM_{E3C+T} reste le plus similaire à E3C avec cette mesure mais les autres corpus cliniques sont difficiles à différencier, illustrant le fait que cette mesure n'est pas la plus adaptée dans ce contexte.

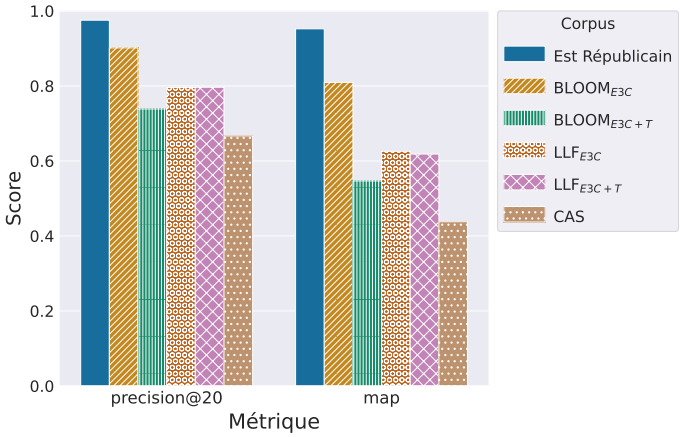
4.2.2.5. Recherche des phrases du corpus E3C

Comme seconde approche pour observer la distance entre E3C et les autres corpus, nous essayons de retrouver les phrases du corpus E3C parmi la combinaison de phrases d'E3C et de phrases du corpus comparé. Ainsi, plus il est simple de retrouver les autres phrases d'E3C, plus la distance entre les corpus est grande. Nous utilisons pour cela des mesures de recherche d'information.

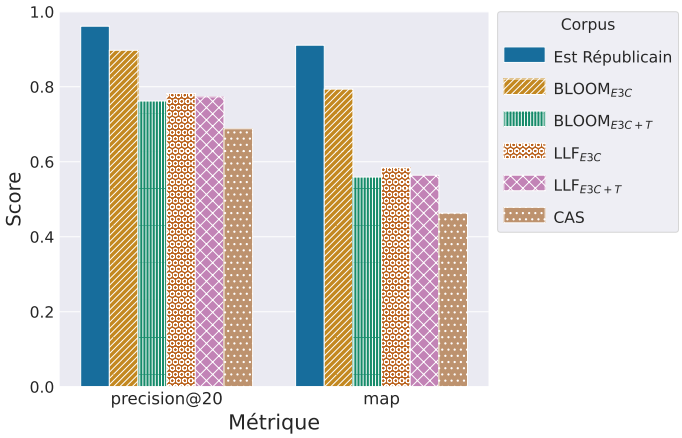
La figure 4.2 présente les résultats de la recherche des phrases du corpus E3C dans les différentes combinaisons des phrases d'E3C et des corpus comparés. On distingue logiquement le corpus de l'Est Républicain, dans lequel les phrases de E3C sont presque systématiquement retrouvées avec les trois modèles de plongements de phrases.



(a) SBERT non ajusté.



(b) SBERT ajusté sur DEFT STS.



(c) SBERT ajusté sur CLISTER.

Figure 4.2 – Scores MAP et Précision@20 de la recherche des phrases de E3C parmi la combinaison des phrases de E3C et des phrases du corpus comparé. Les phrases sont représentées par des plongements de mots issus de Sentence-BERT. Nous recherchons parmi les 100 phrases les plus similaires.

Pour les corpus cliniques, on observe que $\texttt{BLOOM}_{E3C}$ présente des scores nettement plus élevés, CAS présente les scores les plus faibles et les scores des corpus générés $\texttt{BLOOM}_{E3C+T}$, $\texttt{LLF}_{E3C}$ et $\texttt{LLF}_{E3C+T}$ se situent entre les deux. Avec les trois modèles, les phrases de E3C sont retrouvées beaucoup plus facilement lorsqu'elles sont mélangées avec celles du corpus $\texttt{BLOOM}_{E3C}$, au point que l'on se rapproche presque des scores obtenus avec le corpus hors domaine, particulièrement dans les premières positions (précision@20). Cela peut probablement s'expliquer par la différence de longueur des phrases, qui signifie aussi un nombre de phrases beaucoup plus faible. Proportionnellement, même en sélectionnant des phrases au hasard, il y a beaucoup plus de chances de tomber sur une autre phrase d'E3C qu'une phrase de $\texttt{BLOOM}_{E3C}$. Concernant les modèles, on constate que les écarts entre les corpus cliniques sont moins importants lorsqu'on utilise les plongements obtenus par SBERT ajusté sur CLISTER.

Il est intéressant de constater qu'il est plus difficile de retrouver les autres phrases d'E3C en les mélangeant aux phrases du corpus CAS avec les trois modèles. Malgré les scores de similarité plus faibles pour CAS dans la figure 4.1, on constate ici que ce sont les phrases du corpus CAS qui sont les plus proches de celles d'E3C. Une piste d'explication pourrait être les longueurs des phrases, très proches entre les corpus cliniques réels et beaucoup plus longues dans les corpus générés, spécialement pour $\texttt{BLOOM}_{E3C}$, avec lesquelles les phrases d'E3C sont le plus facilement différenciées, se rapprochant presque du corpus hors domaine.

Pour résumer, le corpus d'entraînement E3C présente davantage de similarités surfaciques avec le corpus CAS qu'avec les corpus synthétiques. De plus, comparées aux phrases de CAS, les phrases des corpus synthétiques sont plus facilement différentiables des phrases de E3C, malgré des similarités sémantiques plus fortes. Si ce constat est encourageant du point de vue de la non-reproduction textuelle brute, il serait intéressant d'examiner plus finement dans quelle mesure la similarité sémantique observée traduit une reproduction d'informations issues du corpus d'entraînement.

4.2.3 . Utilité des corpus synthétiques pour une tâche de reconnaissance d'entités cliniques

La question de l'utilité des données synthétique est essentielle lorsqu'elles sont produites dans le but de servir de substitut à des données réelles (Stadler *et al.*, 2022).

Une des applications potentielles des données synthétiques est leur utilisation pour l'entraînement de modèles de TAL. L'idéal est donc que les modèles entraînés sur les données synthétiques obtiennent des performances équivalentes aux modèles entraînés sur les données réelles.

Dans le cadre de la génération conditionnée par des classes, il est possible d'utiliser les associations classe / texte pour entraîner des modèles de classification de texte et ainsi de comparer des modèles entraînés sur des données réelles et sur des données synthétiques (Claveau *et al.*, 2022 ; Ive *et al.*, 2020).

Nous avons choisi de tester la performance de modèles de reconnaissance d'entités cliniques, tâche fondamentale en TAL biomédical pour laquelle nous disposons de corpus annotés pour entraîner des modèles. Nous nous plaçons ici dans le cadre où aucune annotation n'est disponible sur le corpus d'entraînement des modèles génératifs, bien que

le corpus E3C dispose d'annotations générales. Nous proposons donc un protocole pour réaliser cette évaluation, présenté à la figure 4.3.

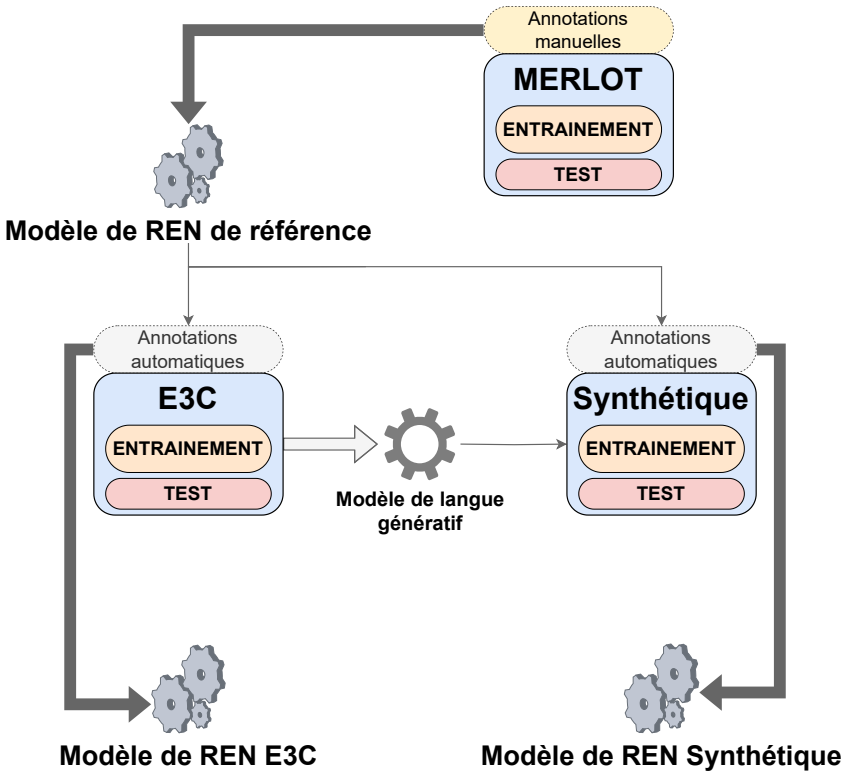


Figure 4.3 – Description de l'expérience permettant l'évaluation de la reconnaissance d'entités cliniques sur des données synthétiques.

L'élément central de ce protocole est un corpus de documents cliniques annoté manuellement, ici le corpus MERLOT. Ce corpus est utilisé à la fois pour l'entraînement et l'évaluation de modèles de REN cliniques. Un modèle de REN de référence est donc entraîné sur MERLOT et utilisé pour annoter le corpus E3C. Nous utilisons ensuite le corpus E3C pour affiner des modèles génératifs, capables de générer soit des textes où les entités cliniques sont marquées, soit des textes bruts pouvant à leur tour être annotés par le modèle REN de référence. Enfin, tous les corpus annotés obtenus, réel (E3C) comme synthétiques, sont à leur tour utilisés pour entraîner des modèles de REN clinique. Les corpus sont divisés en ensembles d'entraînement et de test et les modèles de REN sont testés sur les ensembles de test des autres corpus. Pour limiter les erreurs d'annotation automatique, nous entraînons systématiquement cinq modèles de REN sur chaque corpus et les résultats décrits sont les moyennes des cinq modèles.

Ce protocole permet donc, lorsque l'on dispose d'un corpus annoté comme MERLOT pour entraîner des outils d'analyse, de comparer l'utilité de corpus synthétiques pour une tâche de REN (ici clinique) à l'aide d'annotations automatiques.

4.2.3.1. Distribution des annotations sur les ensembles de test

Le tableau 4.2 présente le nombre d'annotations obtenues sur les ensembles de test des corpus réels E3C et MERLOT et ceux des corpus synthétiques. On remarque que les corpus générés sans balises ($\texttt{BLOOM}_{E3C}$ et $\texttt{LLF}_{E3C}$) disposent presque d'autant d'annotations que le corpus E3C (environ 9 000 annotations chacun). En revanche, les corpus générés avec des balises disposent de nettement moins d'annotations, avec 5 630 annotations pour $\texttt{BLOOM}_{E3C+T}$ (environ $66\,\%$ d'E3C) et 3 893 annotations pour $\texttt{LLF}_{E3C+T}$ (environ $40\,\%$ d'E3C). Nous avons en effet remarqué que les annotations des textes générés dans ces configurations étaient majoritairement présentes en début de document, leur densité diminuant au fur et à mesure du texte. Ces résultats suggèrent que générer des annotations de cette manière n'est pas optimal pour une génération de textes pour une tâche de REN, du moins avec la méthode de génération présentée.

Type	**E3C**	$\texttt{BLOOM}_{E3C}$	$\texttt{BLOOM}_{E3C+T}$	$\texttt{LLF}_{E3C}$	$\texttt{LLF}_{E3C+T}$	**MERLOT**
Anatomie	1 533	1 798	799	1 056	360	922
Médicaments	307	388	390	350	264	283
Concepts	493	376	275	370	241	684
Outils	36	42	72	5	41	219
Signes & symptômes	1 662	1 545	1 146	1 409	806	1 047
Dosages	103	179	219	310	54	188
Hôpitaux	74	65	129	50	54	170
Êtres vivants	533	492	342	842	330	866
Localisations	450	490	128	467	121	169
Mesures	1 496	1 330	670	2 109	421	1 070
Modes	24	68	66	26	6	40
Processus biologiques	127	83	102	62	78	186
Procédures	1 883	1 650	967	985	913	1 779
Expressions temporelles	455	610	325	878	204	885
Total	9 176	9 116	5 630	8 919	3 893	8 510

Table 4.2 – Nombre d'annotations de chaque type pour chaque corpus de test.

4.2.3.2. Performance des modèles de reconnaissance d'entités cliniques

Les résultats de l'évaluation extrinsèque des corpus générés pour la tâche de REN sont présentés dans les tableaux 4.3 à 4.5. Plus précisément, les trois tableaux présentent les résultats des mêmes ensembles de modèles sur les trois types de corpus différents. Les résultats sont obtenus en moyennant les scores de cinq modèles entraînés avec des graines aléatoires différentes et en mélangeant les ensembles d'entraînement et de validation.

	Test					
	E3C			MERLOT		
Entraînement	**P**	**R**	**F**	**P**	**R**	**F**
E3C	**89,5**$\pm 0,3$	**91,0**$\pm 0,4$	**90,2**$\pm 0,3$	64,4$\pm 0,7$	78,0$\pm 0,5$	70,5$\pm 0,6$
MERLOT	87,1$\pm 0,8$	90,8$\pm 2,3$	88,9$\pm 1,4$	**85,2**$\pm 0,2$	**85,8**$\pm 0,7$	**85,5**$\pm 0,4$
BLOOM_{E3C}	87,6$\pm 0,5$	87,9$\pm 0,3$	87,8$\pm 0,2$	63,1$\pm 0,8$	74,9$\pm 0,2$	68,5$\pm 0,5$
LLF_{E3C}	87,6$\pm 0,4$	87,2$\pm 0,4$	87,4$\pm 0,2$	64,5$\pm 1,6$	76,4$\pm 0,3$	70,0$\pm 1,0$
BLOOM_{E3C+T}	83,4$\pm 0,3$	68,9$\pm 0,6$	75,4$\pm 0,3$	71,7$\pm 3,4$	55,1$\pm 0,9$	62,3$\pm 1,4$
LLF_{E3C+T}	84,4$\pm 0,7$	68,1$\pm 0,5$	75,4$\pm 0,2$	75,7$\pm 1,8$	46,4$\pm 1,3$	57,5$\pm 0,6$

Table 4.3 – Résultats de la tâche de REN sur les corpus réels (P=précision, R=rappel, F=F-mesure).

	Test					
	BLOOM_{E3C}			LLF_{E3C}		
Entraînement	**P**	**R**	**F**	**P**	**R**	**F**
E3C	85,3$\pm 0,3$	87,5$\pm 0,5$	86,4$\pm 0,3$	84,5$\pm 0,9$	86,5$\pm 0,7$	85,5$\pm 0,7$
MERLOT	82,1$\pm 1,0$	89,1$\pm 2,7$	85,4$\pm 1,5$	80,1$\pm 1,8$	88,1$\pm 3,0$	83,9$\pm 1,8$
BLOOM_{E3C}	**88,3**$\pm 0,6$	**90,8**$\pm 0,2$	**89,5**$\pm 0,3$	84,0$\pm 0,3$	85,5$\pm 0,4$	84,8$\pm 0,3$
LLF_{E3C}	85,7$\pm 0,3$	86,7$\pm 0,6$	86,2$\pm 0,2$	**87,3**$\pm 0,5$	**90,3**$\pm 0,2$	**88,8**$\pm 0,3$
BLOOM_{E3C+T}	84,3$\pm 0,3$	45,9$\pm 0,5$	59,4$\pm 0,4$	81,1$\pm 1,0$	44,5$\pm 0,9$	57,4$\pm 0,8$
LLF_{E3C+T}	83,1$\pm 0,8$	47,4$\pm 0,8$	60,4$\pm 0,5$	83,7$\pm 0,9$	38,0$\pm 1,1$	52,2$\pm 1,0$

Table 4.4 – Résultats de la tâche de REN sur les corpus générés sans annotations.

	Test					
	BLOOM_{E3C+T}			LLF_{E3C+T}		
Entraînement	**P**	**R**	**F**	**P**	**R**	**F**
E3C	67,6$\pm 0,5$	90,3$\pm 0,3$	77,3$\pm 0,3$	57,3$\pm 0,6$	90,6$\pm 0,4$	70,2$\pm 0,5$
MERLOT	60,3$\pm 1,0$	86,2$\pm 1,9$	71,0$\pm 0,9$	48,7$\pm 1,1$	86,6$\pm 1,8$	62,3$\pm 0,8$
BLOOM_{E3C}	66,4$\pm 0,1$	89,0$\pm 0,2$	76,1$\pm 0,1$	55,8$\pm 0,2$	89,8$\pm 0,2$	68,8$\pm 0,1$
LLF_{E3C}	66,3$\pm 0,6$	88,5$\pm 0,5$	75,8$\pm 0,5$	55,7$\pm 0,6$	89,2$\pm 0,2$	68,6$\pm 0,5$
BLOOM_{E3C+T}	**91,4**$\pm 0,5$	**94,0**$\pm 0,3$	**92,7**$\pm 0,3$	80,9$\pm 0,8$	88,0$\pm 0,1$	84,3$\pm 0,4$
LLF_{E3C+T}	85,1$\pm 0,9$	86,0$\pm 0,7$	85,5$\pm 0,3$	**89,4**$\pm 0,8$	**93,4**$\pm 0,5$	**91,3**$\pm 0,4$

Table 4.5 – Résultats de la tâche de REN sur les corpus générés avec des annotations.

La première observation est que la meilleure performance sur l'ensemble de test d'un corpus donné est obtenue par le modèle entraîné sur l'ensemble d'entraînement du corpus correspondant. Bien que cela ne soit pas surprenant, cela signifie, dans notre contexte, que la différence de qualité entre un corpus synthétique et un corpus réel n'est pas suffisante pour compenser l'avantage apporté par l'homogénéité entre les ensembles d'entraînement et de test. La qualité des corpus générés pour une tâche de REN est principalement confirmée par les résultats obtenus sur les corpus réels et plus particulièrement MERLOT, présentés dans le tableau 4.3. En effet, nous considérons MERLOT comme une référence de haute qualité, puisque contrairement aux autres corpus, il a été annoté manuellement. Bien que les modèles entraînés sur E3C soient significativement moins performants que les modèles entraînés sur MERLOT sur le corpus de test correspondant, on observe que les corpus entraînés sur $\texttt{BLOOM}_{E3C}$ et sur $\texttt{LLF}_{E3C}$ obtiennent des résultats proches, avec un léger avantage pour $\texttt{LLF}_{E3C}$. Dans ce contexte, il est donc à peu près équivalent d'utiliser un corpus synthétique généré à partir d'un corpus réel que d'utiliser le corpus réel.

Les performances de tous les modèles sont significativement plus élevées sur l'ensemble de test de E3C que sur l'ensemble de test de MERLOT. Seules les performances des modèles entraînés sur MERLOT n'augmentent que modérément. La tâche de REN sur E3C semble donc plus simple.

Enfin, le tableau 4.3 montre à travers $\texttt{BLOOM}_{E3C+T}$ et $\texttt{LLF}_{E3C+T}$ que générer des textes directement annotés est la moins bonne stratégie pour les deux ensembles de test. Avec cette stratégie, on constate que le rappel est particulièrement diminué. Cela peut certainement être expliqué par le fait que le nombre d'annotations générées avec cette stratégie (voir tableau 4.2) est largement inférieur au nombre d'annotations produites par les modèles de REN.

Le tableau 4.4 présente les résultats obtenus sur les corpus synthétiques $\texttt{BLOOM}_{E3C}$ et $\texttt{LLF}_{E3C}$. On observe tout d'abord qu'à l'exception de $\texttt{BLOOM}_{E3C+T}$ et $\texttt{LLF}_{E3C+T}$, les performances des modèles sont proches des performances obtenues sur E3C. Cela n'est pas surprenant étant donné que les corpus $\texttt{BLOOM}_{E3C}$ et $\texttt{LLF}_{E3C}$ ont été générés à partir de E3C. Toutefois, cela confirme qu'un corpus synthétique peut être un substitut intéressant à son corpus d'origine. Cela vaut pour entraîner un modèle de REN ainsi que pour l'évaluation de ce dernier. Le tableau 4.4 montre également que les modèles obtiennent des résultats proches sur $\texttt{BLOOM}_{E3C}$ et sur $\texttt{LLF}_{E3C}$. On observe d'ailleurs dans le tableau 4.3 peu de différences entre les modèles entraînés sur ces deux corpus. Enfin, les faibles performances des modèles $\texttt{BLOOM}_{E3C+T}$ et $\texttt{LLF}_{E3C+T}$ se confirment, particulièrement pour le rappel. L'explication est une fois encore certainement à chercher dans le faible nombre d'annotations générées. Cependant, la différence de performance avec l'évaluation sur E3C est difficile à interpréter.

Les résultats présentés dans le tableau 4.5 confirment les observations sur les caractéristiques des corpus $\texttt{BLOOM}_{E3C+T}$ et $\texttt{LLF}_{E3C+T}$. Tous les modèles entraînés sur des corpus annotés par des modèles de REN obtiennent des rappels élevés car ces corpus contiennent un plus grand nombre d'annotations que les corpus $\texttt{BLOOM}_{E3C+T}$ et $\texttt{LLF}_{E3C+T}$. De plus, les performances des modèles entraînés sur les corpus $\texttt{BLOOM}_{E3C+T}$ et $\texttt{LLF}_{E3C+T}$ montrent que les annotations générées sont relativement faciles à ap-

prendre. Enfin, sur les corpus générés avec des annotations, on observe une différence plus importante entre les résultats du corpus généré avec BLOOM, $\texttt{BLOOM}_{E3C+T}$ et le corpus généré avec LLF, $\texttt{LLF}_{E3C+T}$ que dans le tableau 4.4. Toutefois, il reste à déterminer si BLOOM génère de meilleures annotations que LLF ou si la génération d'annotations améliore la qualité du texte généré par BLOOM.

4.2.4 . Évaluation manuelle qualitative

Des échantillons de 15 textes synthétiques par modèle (pour un total de 13 809 tokens pour les 60 textes) ont été annotés avec l'outil BRAT avec pour but d'identifier certaines caractéristiques des textes, en incluant (i) la grammaticalité et (ii) la cohérence clinique au niveau de la phrase et du document.

(1) *Il s'agissait d'un patient de 50 ans, sans antécédents pathologiques particuliers, admis aux urgences pour des douleurs épigastriques aiguës associées à une distension abdominopelvienne évoluant depuis deux jours. L'examen clinique trouvait un patient en assez bon état général (Apgar : 10/10). Le bilan préopératoire objectivait une fonction rénale normale et la CRP était à 12 mg/l. Le scanner abdomino-pelvien a montré une masse tissulaire du flanc droit mesurant 22 cm de grand axe envahissant le parenchyme péritonéal au niveau de l'angle postéro-latéral droit avec présence d'une hypersignal T2 hyperintense intéressant les surrénales pariéto-utérines rehaussée après injection de produit de contraste faisant suspecter sa nature tumorale.*

L'exemple (1) reprend l'extrait de texte synthétique généré par BLOOM avec des annotations présenté dans le tableau 3.4. Deux incohérences médicales y ont été annotées, chaque couleur correspondant aux éléments incohérents entre eux. Premièrement, le cas mentionne un score Apgar, un score évaluant les fonctions vitales d'un nouveau né, alors que le cas décrit un patient de 50 ans. Deuxièmement, le cas décrit une fonction rénale normale, mention à laquelle est associé un score CRP à 12 mg/l, qui représente une quantité bien supérieure à la normale.

L'analyse manuelle suggère que les passages contenant des incohérences cliniques sont plus susceptibles d'être trouvés dans les textes générés sans balises et vers la fin des textes. Plus particulièrement, les textes générés par le modèle BLOOM ont tendance à présenter des phrases très longues devenant de plus en plus incohérentes. Cependant, il y a généralement plus d'incohérences cliniques et d'erreurs grammaticales dans les textes générés par les modèles LLF qu'avec les modèles BLOOM.

Plus globalement, l'analyse manuelle des textes générés par les différents modèles suggère que les textes générés par $\texttt{BLOOM}_{E3C+T}$ sont les plus proches des cas cliniques originaux.

4.2.5 . Synthèse

Dans cette partie, nous avons présenté l'évaluation de l'adaptation de modèles de langue génératifs pré-entraînés pour la génération de cas cliniques en français. Nous avons étudié quatre axes d'évaluation, visant à évaluer l'utilité des textes synthétiques générés et leur proximité avec le corpus réel.

Cette évaluation nous a permis de constater que les textes synthétiques présentent une certaine similarité avec le corpus réel, sans pour autant copier de grandes quantités d'éléments. En outre, les textes synthétiques peuvent être substitués au corpus réel pour entraîner des modèles de reconnaissance d'entités cliniques avec une performance quasiment équivalente. Cela témoigne également de la proximité des textes.

Toutefois, l'observation manuelle des textes synthétiques a fait ressortir la présence de nombreuses erreurs et incohérences, ce qui rend ces textes probablement peu exploitables pour un grand nombre d'applications.

Enfin, estimer de manière fiable les risques liés à la confidentialité n'est pas trivial et mériterait des évaluations supplémentaires.

4.3 . Évaluation de la génération conditionnée par des profils patient

Après avoir présenté l'évaluation de l'adaptation au domaine en laissant la génération libre, nous nous intéressons à l'évaluation de la génération de cas cliniques conditionnées par des profils patient. La méthodologie de génération consistait ici à construire un corpus de couples profil patient / cas clinique. Les profils patient sont constitués des informations démographiques des patients (âge et genre) et d'éléments cliniques saillants (principalement les signes, symptômes et procédures liés aux cas). Nous désignons les *contraintes* comme l'ensemble d'éléments constitutifs des profils patient et correspondant à une portion de texte à retrouver dans le texte généré (par exemple : « *examen clinique* »). Ces contraintes sont utilisées pour conditionner la génération vers ces éléments spécifiques. Pour la génération, nous utilisons des modèles génératifs pré-entraînés de deux architectures différentes, les encodeurs-décodeurs d'un côté et les décodeurs de l'autre.

L'évaluation des textes générés a donc pour objectif de déterminer s'il est possible de générer des cas cliniques correspondant aux profils patient, autrement dit, si l'on retrouve les éléments du profil patient dans le cas clinique généré. Plus globalement, nous souhaitons comparer automatiquement les différents modèles de génération selon un large ensemble de critères de qualité. Pour cela, nous avons sélectionné un ensemble de métriques d'évaluation en essayant de couvrir différentes dimensions pertinentes pour la génération de texte dans un cadre hospitalier.

Dans cette partie, nous présentons d'abord les différentes métriques et comparons ensuite les résultats obtenus par les différents modèles. Cette évaluation est liée à la collaboration avec Hugo Boulanger présentée à l'atelier Clinical NLP de la conférence NAACL 2024 (Boulanger *et al.*, 2024) et dont la méthodologie de génération a été présentée à la section 3.4 du chapitre 3.

4.3.1 . Métriques d'évaluation

Pour cette évaluation, nous avons choisi des métriques couvrant un large ensemble de critères de qualité concernant à la fois le texte généré et les coûts de l'utilisation des modèles (entraînement et inférence).

Contrôlabilité - *Exactitude* Cette mesure sert à évaluer la capacité du modèle à respecter les contraintes qui lui sont imposées. Nous calculons la proportion de contraintes respectées dans les textes générés par rapport au nombre total de contraintes imposées.

L'exactitude est calculée par correspondance stricte de chaîne de caractères. Le genre est également vérifié en observant l'accord du nom « patient » au masculin ou au féminin ou de l'utilisation des termes « féminin » ou « masculin ». Cette manière de mesurer l'exactitude est l'une des limites de cette étude, puisqu'elle ne tient pas compte de la variabilité éventuelle d'expression des contraintes.

« Qualité » de la langue - *Perplexité* La perplexité évalue l'adéquation des données textuelles avec la distribution de probabilité d'un modèle de langue. Nous utilisons ici un modèle spécifique du français, GPTFR (Simoulin et Crabbé, 2021). Pour cette métrique, nous souhaitons que la perplexité obtenue sur les données générées se rapproche de la perplexité obtenue sur les données réelles (égale à 19,5 pour le corpus de test).

Proximité avec le corpus réel - *Corpus-BLEU-4* et *BLEU-4* Ces deux métriques permettent de calculer la proximité avec le corpus réel à deux échelles différentes. Corpus-BLEU (Yu *et al.*, 2017) est une mesure de proximité à l'échelle du corpus et correspond à la moyenne des scores BLEU entre chaque phrase du corpus généré et toutes les phrases du corpus réel. Le score Corpus-BLEU est calculé en comparant les cas cliniques du corpus de test avec les textes générés tandis que le score BLEU est calculé entre le texte généré et le cas clinique réel d'où proviennent les contraintes. Il mesure la proximité avec les données réelles de façon plus spécifique que le score Corpus-BLEU.

Diversité des textes générés - *Self-BLEU-4* Le score Self-BLEU est la moyenne des scores BLEU de toutes les phrases d'un corpus entre elles. Ainsi, un corpus redondant aura un score Self-BLEU élevé tandis qu'un corpus varié aura un score plus faible. [2]

Coûts d'entraînement et d'inférence - *Temps GPU* et Empreinte carbone Plus rarement considérés comme des métriques d'évaluation, les coûts d'entraînement et d'inférence sont deux critères importants à prendre en compte pour les performances d'un système, notamment dans un contexte de ressources computationnelles limitées. Nous présentons ces coûts selon deux mesures liées, le temps GPU et l'empreinte carbone. Le temps GPU est calculé selon le nombre de GPU utilisé lors des calculs (Temps GPU = temps de calcul $\times$ nombre de GPU utilisés).

4.3.2 . Baselines

En plus des résultats des différents modèles décodeurs et encodeurs-décodeurs, nous ajoutons cinq baselines :

- Recopie des contraintes ;
- Copie du corpus, pour connaître les valeurs de référence des métriques qualitatives ;
- Trois modèles décodeurs de différentes tailles pour observer les résultats obtenus sans contrôle.

4.3.3 . Résultats globaux

Un récapitulatif des différents niveaux d'évaluation est présenté dans le tableau 4.6. Nous avons choisi de conserver une seule métrique pour chaque dimension pour avoir

2. Toutes les métriques reposant sur BLEU considèrent ici les quadrigrammes, ce qui correspond à la notation « BLEU-4 ».

une vue moins chargée des performances globales. Nous allons maintenant passer précisément en revue les différentes dimensions.

	Méthode	Exactitude↑	Perplexité	Self-BLEU-4	Corpus-BLEU-4↑	Temps GPU↓
Baselines	Contraintes copiées	100	194,3	14,4	25,5	s/o
	Corpus copié	98,8	19,5	33,4	97,4	s/o
	BLOOM 1b1 gelé∗	s/o	11,5±1,5	86,1±0,4	64,8±0,4	03h08m
	BLOOM 1b1 dégelé∗	s/o	10,2±0,9	82,9±0,4	60,6±0,5	03h06m
	BLOOM 7b1 gelé∗	s/o	8,4±2,8	79,3±1,2	57,1±0,5	04h20m
Encodeurs-décodeurs	mT5-large gelé	78,0±0,6	13,6±0,2	53,5±0,5	55,8±0,5	41h00m
	mT5-large dégelé	73,6±0,8	13,4±0,2	53,8±0,4	56,4±0,3	41h00m
	Flan-T5-small gelé	61,6±0,4	18,9±0,4	49,1±0,4	47,1±0,4	15h45m
	Flan-T5-small dégelé	61,5±0,7	17,6±0,5	51,2±0,4	50,0±1,4	15h54m
	Flan-T5-large gelé	81,5±1,1	14,8±0,4	52,8±0,4	55,3±0,4	09h00m
	Flan-T5-large dégelé	80,3±1,0	15,6±0,5	51,9±0,2	55,0±0,4	09h00m
	Flan-T5-XL gelé	84,2±0,8	14,9±0,2	50,2±0,2	54,5±0,2	41h00m
	Flan-T5-XL dégelé	85,3±0,8	14,9±0,2	49,0±0,1	53,8±0,4	41h00m
Décodeurs	BLOOM 1b1 gelé	40,5±3,9	8,8±0,2	62,5±5,8	42,3±11,1	05h13m
	BLOOM 1b1 dégelé	29,6±0,9	9,3±0,4	63,6±4,7	50,4±9,7	05h08m
	BLOOM 7b1 gelé	43,5±2,5	9,9±0,6	54,0±2,1	47,5±2,0	6h28m
	BLOOMZ 1b1 gelé	45,4±4,2	9,2±0,2	61,9±7,6	41,8±11,0	05h13m
	BLOOMZ 1b1 dégelé	32,1±1,7	9,6±0,2	65,7±6,0	47,0±13,2	05h08m
	BLOOMZ 7b1 gelé	39,8±3,0	9,9±0,2	55,0±1,9	49,8±1,5	6h28m
	Vigogne-2-7b-instruct	65,3±1,2	43,7±28,6	34,3±0,3	32,1±0,3	01h05m
	Vigogne-2-13b-instruct	68,1±1,5	21,8±1,6	33,7±0,5	33,5±0,2	01h16m
	Llama-3.1	72,3±1,4	21,1±0,7	32,4±0,5	35,0±0,3	00h52m
	Llama-3.1-Instruct	71,6±1,4	27,1±0,5	39,0±0,3	28,2±0,4	01h04m
	BioMistral-SLERP	72,3±0,5	18,0±0,3	38,0±0,2	35,5±0,3	00h58m

Table 4.6 – Évaluation récapitulative des données générées. Modèles baselines marqués par « ∗ » : entraînement et génération sans contrainte.

4.3.4 . Respect des contraintes

Le respect des contraintes pour chaque modèle est décrit dans la colonne « Exactitude » du tableau 4.6.

Au niveau des baselines, les trois modèles BLOOM n'ont pas de valeur car les générations ne sont pas conditionnées par les contraintes. Les contraintes copiées ont bien une exactitude de 100 % et la copie du corpus n'atteint pas tout à fait les 100 %, principalement car la vérification de la contrainte de genre n'est pas parfaite.

Globalement, on remarque que les modèles encodeurs-décodeurs obtiennent en moyenne une exactitude plus élevée, avec Flan-T5-XL ayant les meilleurs scores parmi tous les modèles. Seuls les modèles fondés sur Flan-T5-small sont moins performants que certains décodeurs au niveau du respect des contraintes mais restent plus performants que tous les modèles BLOOM, qui obtiennent des résultats faibles quel que soit leur taille ou leur type (BLOOM ou BLOOMZ, gelé ou dégelé).

Les modèles décodeurs plus récents obtiennent des scores d'exactitude nettement plus satisfaisants, les meilleures performances étant obtenues par BioMistral-SLERP et

Llama-3.1, ce dernier obtenant un meilleur score d'exactitude que sa contrepartie avec instructions.

La différence de traitement des plongements lexicaux (gelés ou dégelés) présente ici des impacts variables avec de faibles différences pour les encodeurs-décodeurs, qu'elles soient positives ou négatives, tandis que la version dégelée des modèles BLOOM-1b1 diminue grandement les performances.

Malgré une importante différence de nombre de paramètres entre les modèles, les encodeurs-décodeurs respectent mieux les contraintes que les décodeurs. Comme nous l'avions mentionné dans le chapitre 2, cela semble correspondre au fait que les architectures encodeurs-décodeurs sont préférées dans les tâches de génération données vers texte.

4.3.5 . Diversité des corpus générés

La diversité est mesurée ici par le score Self-BLEU. Il s'agit donc une diversité de surface. Pour les corpus générés, l'idéal est d'atteindre une diversité proche de celle du corpus copié, c'est-à-dire 33,4. On remarque que les trois baselines BLOOM ont un score de diversité très élevé. En effet, puisque les textes ne sont pas conditionnés par des contraintes mais seulement avec des balises de début de texte, la génération n'est pas dirigée vers des éléments cliniques particuliers.

Les corpus générés par les modèles BLOOM(Z) à 1 milliard de paramètres sont les corpus les moins divers, suivis par les versions à 7 milliards de paramètres. Parmi les encodeurs-décodeurs, on ne constate pas de corrélation entre les tailles des modèles et la diversité puisque les modèles Flan-T5-small gelé et Flan-T5-XL dégelé obtiennent le Self-BLEU le plus bas et donc la meilleure diversité. Les corpus les plus divers sont obtenus avec les décodeurs autres que BLOOM, allant jusqu'à une diversité plus grande que le corpus réel pour le modèle Llama-3.1.

Au niveau de la diversité représentée par le score Self-BLEU, ce sont donc les décodeurs qui obtiennent les résultats les plus proches du corpus réel. On peut penser que ces modèles étant davantage spécialisés dans la génération de texte libre, les textes générés sont donc plus divers.

4.3.6 . « Qualité » de la langue

La qualité de la langue est représentée par la perplexité. Comme pour la diversité, nous souhaitons que les textes synthétiques obtiennent une perplexité proche de celle des données réelles, représentées par la ligne « Corpus copié » (19,5). Cela signifierait en effet que la distribution de probabilité des tokens générés est proche de la distribution des tokens réels.

Comme attendu, la perplexité sur la simple copie des contraintes est largement plus élevée (194,3), puisqu'aucune construction textuelle n'est ajoutée.

Les décodeurs BLOOM obtiennent les scores de perplexité les plus faibles, nettement en dessous du score du corpus réel. Cela signifie donc que les textes générés par ces modèles sont plus « familiers » au modèle servant à calculer la perplexité que les textes réels. Couplé à la faible performance des modèles BLOOM au niveau de l'exactitude, cela peut attester d'une adaptation au domaine peu satisfaisante, puisqu'on ne respecte pas

les contraintes cliniques tout en présentant une distribution plus proche d'un français standard que biomédical.

Les modèles encodeurs-décodeurs obtiennent des perplexités plus élevées et plus proches du corpus réel, avec les deux versions du plus petit modèle Flan-T5-small présentant pourtant un score d'exactitude plus faible que les autres encodeurs-décodeurs.

Les perplexités obtenues sur les modèles décodeurs autres que BLOOM sont hétérogènes mais globalement plus élevées que pour les autres modèles. Les trois modèles Llama-3.1, Vigogne-2-13b-Instruct et BioMistral-SLERP obtiennent pour cette métrique des résultats proches de celle du corpus réel. À part BioMistral-SLERP, les textes générés par ces modèles présentent des perplexités plus élevées que la référence 19,5. Llama-3.1-Instruct obtient une perplexité nettement plus grande et la perplexité de Vigogne-2-7b-Instruct est très irrégulière à travers les itérations de génération.

La perplexité nous permet donc d'estimer que certains corpus se rapprochent davantage de la distribution du corpus réel, sans régularité entre les différentes architectures et versions des modèles.

4.3.7 . Ressemblance avec le corpus réel

Les scores BLEU-4 et Corpus-BLEU-4, les deux métriques de comparaison directe entre le corpus réel et les corpus générés, sont présentés dans le tableau 4.7. La copie du corpus n'obtient pas tout à fait des scores de 100 car les retours à la ligne ont été retirés dans cette version. Les trois baselines fondées sur BLOOM n'ont pas de score BLEU car les textes générés ne correspondent pas à un texte de référence spécifique. Ce sont toutefois les modèles obtenant le Corpus-BLEU le plus élevé parmi les modèles, bien que ces scores restent bien inférieurs au score de référence.

Au niveau du Corpus-BLEU, les encodeurs-décodeurs obtiennent de meilleurs résultats que les décodeurs. Tous les modèles ont des performances à peu près équivalentes, mis à part le modèle Flan-T5-small, légèrement en dessous. Cette tendance s'observe également au niveau du score BLEU.

Contrairement aux autres métriques, les modèles décodeurs obtenant les meilleurs scores Corpus-BLEU sont les modèles fondés sur BLOOM. Pourtant, ce sont également ces modèles qui obtiennent les scores BLEU les plus faibles. Les autres décodeurs ont donc des scores Corpus-BLEU plus faibles mais des scores BLEU plus élevés. On remarque notamment que le modèle Llama-3.1 obtient un BLEU presque aussi élevé que les encodeurs-décodeurs malgré un Corpus-BLEU nettement plus faible.

Il est surprenant d'observer un Corpus-BLEU relativement élevé tout en ayant un BLEU faible pour les modèles fondés sur BLOOM et inversement pour les autres décodeurs. En se basant sur les scores des autres métriques, et notamment le respect des contraintes, on pourrait supposer que les textes générés par BLOOM ne correspondent pas vraiment aux profils patient donnés en entrée mais parviennent à recouper des éléments cliniques avec d'autres textes du corpus de test. À l'inverse, les autres décodeurs respectent raisonnablement les contraintes mais semblent prendre plus de libertés pour le reste de la génération.

	Méthode de génération	Corpus-BLEU-4↑	BLEU-4↑
Baselines	Contraintes copiées	25,5	1,1
	Corpus copié	97,4	97,5
	BLOOM 1b1 gelé*	64,8±0,4	s/o
	BLOOM 1b1 dégelé*	60,6±0,5	s/o
	BLOOM 7b1 gelé*	57,1±0,5	s/o
Encodeurs-décodeurs	mT5-large gelé	55,8±0,5	12,0±0,1
	mT5-large dégelé	56,4±0,3	10,9±0,2
	Flan-T5-small gelé	47,1±0,4	6,6±0,1
	Flan-T5-small dégelé	50,0±1,4	7,0±0,2
	Flan-T5-large gelé	55,3±0,4	12,0±0,1
	Flan-T5-large dégelé	55,0±0,4	11,7±0,2
	Flan-T5-XL gelé	54,5±0,2	12,8±0,1
	Flan-T5-XL dégelé	53,8±0,4	12,9±0,2
Décodeurs	BLOOM 1b1 gelé	42,3±11,1	4,7±1,0
	BLOOM 1b1 dégelé	50,4±9,7	4,0±0,5
	BLOOM 7b1 gelé	47,5±2,0	5,8±1,0
	BLOOMZ 1b1 gelé	41,8±11,0	5,2±1,3
	BLOOMZ 1b1 dégelé	47,0±13,2	4,3±0,7
	BLOOMZ 7b1 gelé	49,8±1,5	5,4±0,4
	Vigogne-2-7b-instruct	32,1±0,3	8,1±0,2
	Vigogne-2-13b-instruct	33,5±0,2	9,3±0,1
	Llama-3.1	35,0±0,3	11,0±0,2
	Llama-3.1-Instruct	28,2±0,4	6,9±0,2
	BioMistral-SLERP	35,5±0,3	9,2±0,1

Table 4.7 – Scores BLEU-4 et Corpus-BLEU-4 sur l'ensemble de test.

4.3.8 . Coûts de l'entraînement et de la génération

Les détails des temps de calcul à l'entraînement et à l'inférence pour tous les modèles génératifs, hors baselines, ainsi que leur impact carbone sont présentés dans le tableau 4.8. Les valeurs sont calculées à l'aide de l'outil MachineLearning Impact calculator (Lacoste *et al.*, 2019) en utilisant les valeurs d'émission de la France (0,101 kgCO_2éq/kWh) trouvées dans (Moro et Lonza, 2018).

Au niveau de l'entraînement, on constate une importante différence de temps de calcul entre les encodeurs-décodeurs d'un côté et les décodeurs de l'autre. Le temps d'entraînement des décodeurs est assez court, allant de 10 à 15 minutes pour les plus petits (BLOOM et BLOOMZ à 1 milliard de paramètres) jusqu'à environ 40 minutes pour le plus gros (Vigogne à 13 milliards de paramètres). En revanche, l'ordre de grandeur pour les encodeurs-décodeurs est nettement plus grand, avec plusieurs heures pour l'encodeur-décodeur le plus rapide à entraîner, jusqu'à 40 heures pour les plus longs. Nous rappelons toutefois que le modèle le plus petit, Flan-T5-small, a été entraîné sur un GPU Nvidia P6000, un GPU nettement plus petit et abordable que les GPU Nvidia A100 utilisés pour

	Modèle	Temps d'entraînement	Temps d'inférence	Total	CO2eq
Encodeurs-décodeurs	mT5-large gelé	$20{,}00 \times 2$	$1{,}00 \times 1$	41,00	2,55
	mT5-large dégelé	$20{,}00 \times 2$	$1{,}00 \times 1$	41,00	2,55
	Flan-T5-small gelé	$15{,}00 \times 1$	$0{,}75 \times 1$	15,75	0,40
	Flan-T5-small dégelé	$15{,}00 \times 1$	$0{,}75 \times 1$	15,75	0,40
	Flan-T5-large gelé	$8{,}00 \times 1$	$1{,}00 \times 1$	9,00	0,78
	Flan-T5-large dégelé	$8{,}00 \times 1$	$1{,}00 \times 1$	9,00	0,78
	Flan-T5-XL gelé	$20{,}00 \times 2$	$1{,}00 \times 1$	41,00	2,55
	Flan-T5-XL dégelé	$20{,}00 \times 2$	$1{,}00 \times 1$	41,00	2,55
Décodeurs	BLOOM 1b1 gelé	$0{,}25 \times 1$	$5{,}00 \times 1$	5,25	0,15
	BLOOM 1b1 dégelé	$0{,}17 \times 1$	$5{,}00 \times 1$	5,17	0,15
	BLOOM 7b1 gelé	$0{,}50 \times 1$	$6{,}00 \times 1$	6,50	0,25
	BLOOMZ 1b1 gelé	$0{,}25 \times 1$	$5{,}00 \times 1$	5,25	0,15
	BLOOMZ 1b1 dégelé	$0{,}17 \times 1$	$5{,}00 \times 1$	5,17	0,15
	BLOOMZ 7b1 gelé	$0{,}50 \times 1$	$6{,}00 \times 1$	6,50	0,25
	Vigogne-2-7b-instruct	$0{,}45 \times 1$	$*0{,}16 \times 4$	1,09	0,04
	Vigogne-2-13b-instruct	$0{,}63 \times 1$	$*0{,}16 \times 4$	1,27	0,05
	Llama-3.1	$0{,}36 \times 1$	$*0{,}13 \times 4$	0,87	0,04
	Llama-3.1-Instruct	$0{,}37 \times 1$	$*0{,}17 \times 4$	1,06	0,04
	BioMistral-SLERP	$0{,}38 \times 1$	$*0{,}15 \times 4$	0,97	0,04

Table 4.8 – Temps de calcul et empreintes carbone pour l'entraînement et l'inférence. Pour l'entraînement et l'inférence, le format correspond à : nombre d'heures $\times$ nombre de GPU. Les calculs utilisant vLLM sont marqués d'une étoile « * ».

les autres encodeurs-décodeurs. Les encodeurs-décodeurs sont donc beaucoup plus coûteux à entraîner que les encodeurs, malgré leur nombre de paramètres inférieur.

Au niveau de l'inférence, les encodeurs-décodeurs sont cette fois-ci plus rapides que les décodeurs lorsque vLLM n'est pas utilisé. vLLM permet d'inverser cette tendance, permettant aux décodeurs de générer du texte plus rapidement au prix d'une infrastructure de calcul plus coûteuse, ici 4 GPU (voir section 3.5.8 pour la discussion sur l'utilisation de cet outil).

Globalement, le temps GPU nécessaire à l'entraînement et l'utilisation des modèles est nettement plus élevé pour les encodeurs-décodeurs que pour les encodeurs. Cette différence de temps se traduit sur l'impact carbone des modèles, avec des valeurs beaucoup plus élevées pour les plus gros encodeurs-décodeurs. Toutefois, une grande partie de cette différence est due à l'entraînement. Ce temps est donc potentiellement fixe, sauf si le modèle est occasionnellement mis à jour, contrairement à l'inférence pour laquelle la taille des décodeurs les rend coûteux à l'utilisation.

Par conséquent, choisir un décodeur sans utiliser vLLM ne semble pas être une solution idéale si beaucoup de générations sont nécessaires, les temps d'inférence étant plus nettement longs. Si des ressources suffisantes sont disponibles, utiliser des décodeurs avec vLLM peut rendre le processus de génération rapide et ainsi limiter le blocage des

ressources et les émissions de CO_2. Enfin, Flan-T5-small semble être le plus adapté si les ressources ne sont pas suffisantes.

4.3.9 . Synthèse

Dans cette partie, nous avons présenté une évaluation automatique de plusieurs modèles, de tailles et d'architectures différentes, pour une tâche de génération de cas cliniques en français conditionnée par des profils patient. Les métriques présentées couvrent plusieurs dimensions qualitatives, que ce soit la qualité des textes synthétiques générés ou les coûts de la génération.

Nous avons constaté que les modèles à architecture encodeur-décodeur respectent davantage les contraintes du profil patient que les décodeurs. Ces derniers ont plus tendance à générer plus librement des parties de texte. En revanche, les décodeurs sont globalement moins coûteux à utiliser malgré leur nombre de paramètres plus élevé.

Dans un contexte hospitalier et selon les ressources disponibles, les choix à privilégier seraient donc de petits encodeurs-décodeurs ou des décodeurs (probablement autres que les versions de BLOOM testées).

4.4 . Impact de la pathologie et du genre sur le contrôle

Nous avons pu observer qu'il était possible de conditionner la génération de texte à l'aide de profils patient composés d'informations démographiques annotées manuellement et d'éléments cliniques extraits automatiquement. Les éléments présents dans les profils patient ne couvrent cependant pas l'intégralité de ce qui compose les cas cliniques générés. Nous espérons que les textes générés contiennent ces éléments, reliés de manière naturelle et cohérente. Toutefois, une partie du texte généré n'est pas directement contrôlée et peut potentiellement contenir des éléments inattendus.

On peut donc légitimement se demander ce qu'il advient lorsque certains éléments ne sont *pas* contrôlés. En connaissance des biais de genre des modèles présentés dans le chapitre 2 et du fait que les prévalences homme/femme des pathologies varient, nous nous intéressons à la relation entre la contrôlabilité, la pathologie et le genre. Nous avons ainsi présenté au chapitre 3 une méthodologie de génération de cas cliniques en français selon 10 pathologies aux prévalences variées pour lesquelles nous itérons sur un nombre important de générations en faisant varier le genre en amorce entre féminin, masculin ou neutre.

Nous allons dans un premier temps analyser la contrôlabilité et la ressemblance au texte d'origine selon la pathologie, le modèle et le genre en amorce. Nous étudierons ensuite plus précisément l'impact du genre en amorce sur le genre dans le texte généré, en analysant d'une part les cas où les biais des modèles surpassent le genre en amorce et d'autre part le comportement des générations lorsque le genre n'est pas précisé.

Les résultats présentés dans cette partie sont liés à la méthodologie de génération présentée à la section 3.5. Cette expérience a été réalisée en collaboration avec Fanny Ducel et a fait l'objet d'un article accepté à la conférence NAACL 2025 (Ducel *et al.*, 2025)[3].

4.4.1 . Respect des contraintes cliniques et ressemblance aux cas cliniques réels

Le tableau 4.9 présente, pour le corpus généré relatif à nos 10 pathologies cibles, le pourcentage de contraintes cliniques respectées et le score BLEU des textes générés par pathologie, indépendamment du genre dans l'amorce. Pour chaque pathologie, le nombre de contraintes cliniques utilisées est précisé. La différence dans le nombre de contraintes est notamment due à la différence de taille des cas cliniques réels correspondants.

Pathologie	**Contraintes (#)**	**Respectées (%)**	**BLEU**
Cancer de la prostate	17	71,7±11,3	10,4±3,7
Cancer de la vessie	12	57,2±11,5	8,7±3,6
COVID-19	12	57,3±13,3	5,0±2,3
Infarctus	18	68,7±12,6	6,7±2,6
Cancer du côlon	14	**90,0**±12,4	8,0±4,7
Drépanocytose	11	77,8±12,4	5,2±2,6
Dépression	22	69,7±18,7	6,4±1,7
Ostéoporose	17	69,4±7,8	10,8±2,2
Cancer du sein	19	43,4±12,4	12,9±3,0
Cancer de l'ovaire	20	55,4±18,3	**13,2**±3,7
Moyenne	16,2	66,1±18,3	8,7±4,2

Table 4.9 – Évaluation par pathologie du respect des contraintes et de la ressemblance par rapport au cas cliniques réels.

On remarque que les contraintes sont beaucoup moins respectées pour certaines pathologies, notamment le cancer de l'ovaire, le cancer de la vessie, le COVID-19 et particulièrement le cancer du sein. À l'inverse, les générations de cas de cancer du côlon présentent un pourcentage de contraintes cliniques respectées très élevé.

Pourtant, ces résultats ne semblent pas être liés aux scores BLEU, qui attestent d'une similarité surfacique des textes. Le cancer de l'ovaire et le cancer du sein ont par exemple les scores BLEU les plus élevés, tandis que le cancer du côlon est en dessous de la moyenne.

On remarque donc d'importantes différences dans la génération selon la pathologie ciblée. En outre, on observe que l'ensemble des pathologies présente une forte variabilité dans le respect des contraintes et pour les scores BLEU. Cette variabilité témoigne de

3. Pour l'évaluation, l'auteur de cette thèse a mesuré les pourcentages de contraintes respectées et les scores BLEU tandis que Fanny Ducel s'est occupée de la détection de genre dans les textes générés en adaptant l'outil présenté dans Ducel *et al.* (2024).

l'instabilité des modèles génératifs, soulignant l'importance de prendre en considération cet aspect lors de l'utilisation de tels modèles.

Le tableau 4.10 présente les résultats par modèle. Tout comme dans la section 4.3, on constate d'importantes différences entre les modèles. La version de BLOOM la plus petite présente des résultats nettement en dessous des autres modèles et les modèles plus gros et plus récents présentent de meilleures performances. On remarque toutefois que le pourcentage de contraintes respectées de BLOOM est nettement meilleur sur cette expérience tandis que les performances de BioMistral ont assez nettement diminué.

Modèle	**Respectées (%)**	**BLEU**
BLOOM-1b1	52,7±20,1	5,6±2,3
BLOOM-7b	61,6±18,6	6,5±2,8
Vigogne-2-7b	67,8±16,6	**10,7**±4,7
Vigogne-2-13b	70,8±16,2	9,4±4,0
Llama-3.1-8B	**73,4**±14,9	9,7±4,5
Llama-3.1-8B-Instruct	70,2±16,9	10,3±4,3
BioMistral-SLERP	65,9±16,1	9,1±3,7
Moyenne	66,1±18,3	8,7±4,2

Table 4.10 – Évaluation par modèle.

Enfin, le tableau 4.11 présente les résultats selon le genre utilisé dans l'amorce. On ne constate cette fois-ci pas de différence particulière selon le genre précisé dans l'amorce ou lorsqu'aucun genre n'est précisé. Le genre utilisé dans l'amorce ne semble donc pas influer sur le respect des contraintes cliniques et sur la ressemblance avec le texte réel original.

Genre en amorce	**Contraintes respectées (%)**	**BLEU**
Féminin	66,0±18,2	8,7±4,3
Masculin	65,8±18,7	8,7±4,1
Neutre	66,4±18,1	8,8±4,2
Moyenne	66,1±18,3	8,7±4,2

Table 4.11 – Évaluation selon le genre dans l'amorce.

4.4.2 . Une contrainte particulière : le genre

Outre les pathologies, cette expérience avait pour objectif d'observer comment la contrainte de genre était traitée par les modèles, sachant que les modèles génératifs sont connus pour présenter des biais genrés et les amplifier.

Nous cherchons à estimer comment les biais de genre se manifestent dans la génération de cas cliniques en français d'une part et d'autre part si une mention explicite du genre du patient souhaité permet d'annuler ces biais.

4.4.2.1. Détection automatique du genre dans les cas cliniques générés

Pour détecter automatiquement le genre des patients dans les textes générés, nous adaptons un outil développé par Ducel *et al.* (2024) s'appuyant à la fois sur des règles linguistiques, des ressources lexicales en français et de l'apprentissage automatique. Les textes sont regroupés selon quatre classes, à savoir "masculin", "féminin", "neutre" et "ambigu", selon le genre morphosyntaxique majoritaire dans le texte. Les attributs biologiques ne sont pas pris en compte dans la détection, seules les inflexions genrées sont utilisées pour la classification. Les performances de l'outil de détection ont été évaluées manuellement sur un échantillon de 350 textes générés (5 textes $\times$ 10 pathologies $\times$ 7 modèles). L'exactitude observée est de 98 %, soit 7 erreurs sur les 350 textes.

4.4.2.2. Respect de la contrainte de genre

Nous observons dans un premier temps uniquement les cas cliniques générés lorsque le genre est précisé en amorce. La figure 4.4 présente les distributions des textes générés avec les genres féminin et masculin en amorce. On constate dans les deux distributions que le genre est respecté dans une grande partie des cas, avec plus de 87 % de textes respectant la contrainte. En revanche, il reste plus de 10 % des textes pour lesquels le genre généré est différent de celui de l'amorce.

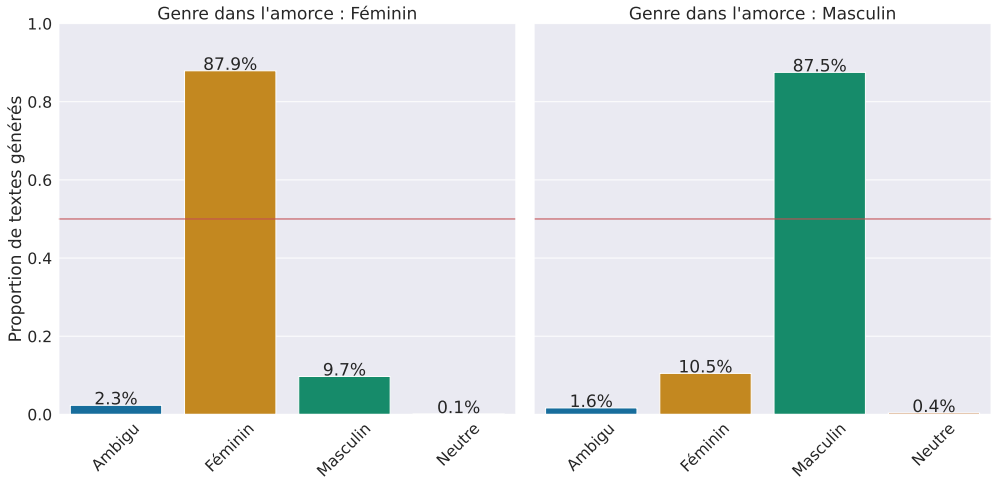


Figure 4.4 – Proportion des genres dans les textes générés selon le genre donné en amorce. La ligne rouge marque les 50 %.

En plus d'observer les distributions des genres dans les cas cliniques générés, nous calculons la proportion de mégenrage. Cela ne concerne que les textes générés avec une contrainte de genre féminin ou masculin, puisque l'on calcule la proportion de textes dont le genre est différent du genre précisé dans l'amorce.

Le tableau 4.12 présente les taux de mégenrage pour les différentes pathologies étudiées. Les pathologies pour lesquelles les modèles respectent le moins la contrainte de genre sont le cancer de la prostate, le cancer de l'ovaire et particulièrement le cancer du sein. Le risque de mégenrage est donc nettement plus faible pour les pathologies qui ne sont pas marquées du point de vue du genre. Si le cancer du sein est très largement

prévalent chez les femmes (99,3 % contre 0,7 % chez les hommes), celui-ci n'est pas directement lié à un organe masculin ou féminin, contrairement aux cancers de l'ovaire et de la prostate. Pourtant, c'est le cancer du sein qui présente le taux de mégenrage le plus élevé, avec un écart significatif par rapport au second taux le plus élevé ($+0{,}68$).

Pathologie	**Taux de mégenrage**
Ostéoporose	0,065
Dépression	0,073
Infarctus	0,077
Cancer du côlon	0,086
COVID-19	0,100
Cancer de la vessie	0,109
Drépanocytose	0,118
Cancer de la prostate	0,167
Cancer de l'ovaire	0,170
Cancer du sein	**0,238**

Table 4.12 – Taux de mégenrage par pathologie.

Le tableau 4.13 présente les taux de mégenrage par modèle. Nous remarquons que les modèles BLOOM présentent des taux de mégenrage plus importants que les modèles Llama. On remarque également un écart important entre les taux de mégenrage des modèles Vigogne, pourtant de la même famille. Enfin, la très faible différence entre le modèle de base Llama-3.1 et sa version *Instruct* suggère que la combinaison de l'instruction et de l'alignement n'a pas d'influence significative dans ce cadre, ce qui est un peu surprenant.

Modèle	**Taux de mégenrage**
Vigogne-2-13b	0,093
Llama-3.1-8B	0,104
Llama-3.1-8B-Instruct	0,105
BioMistral-7b-SLERP	0,119
BLOOM-1b1	0,126
Vigogne-2-7b	0,145
BLOOM-7b1	**0,152**

Table 4.13 – Taux de mégenrage par modèle.

4.4.2.3. Lorsqu'on ne contrôle pas le genre

Lorsque l'on précise un genre dans l'amorce, celui-ci n'est pas toujours respecté, particulièrement pour certaines pathologies. Nous analysons désormais les cas où le genre n'est pas précisé.

La figure 4.5 présente la distribution des textes générés sans précision de genre en amorce. Si la distribution est logiquement plus équilibrée que lorsqu'un genre est précisé, on remarque une nette tendance à favoriser la génération de textes à propos d'un patient

plutôt que d'une patiente avec 64,4 % de textes masculins contre 33,5 % de textes féminins. Lorsqu'on ne précise pas de genre, les modèles sont donc en moyenne biaisés vers la génération de patients masculins.

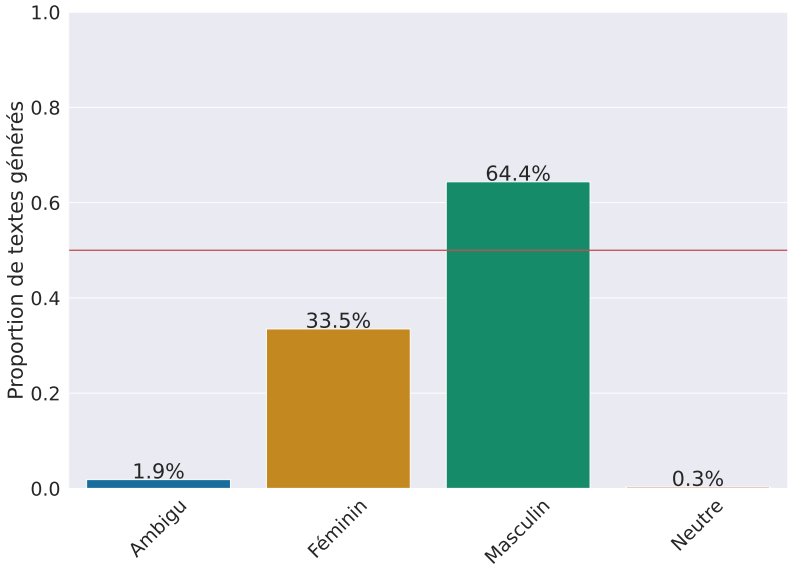


Figure 4.5 – Proportion des genres dans les textes générés lorsque le genre n'est pas précisé dans l'amorce. La ligne rouge marque les 50 %.

La figure 4.6 permet de rentrer dans les détails par pathologie, en comparant la distribution du genre des textes générés avec les prévalences réelles des pathologies.

On peut voir sur cette figure que les textes générés présentent une proportion plus élevée de patients masculins que les distributions réelles, sauf pour le cancer de la prostate. Dans certains cas comme l'ostéoporose et la dépression, le genre majoritaire est inversé par rapport aux données réelles où les femmes sont majoritaires. On peut aussi observer que pour l'infarctus et la drépanocytose, la proportion de textes féminins est presque aussi faible que pour les cancers du sein, de l'ovaire et de la prostate, bien que l'infarctus et la drépanocytose présentent des prévalences réelles beaucoup plus équilibrées. Enfin, les cancers de la vessie, de l'ovaire, du sein et de la prostate ont des prévalences générées et réelles relativement proches.

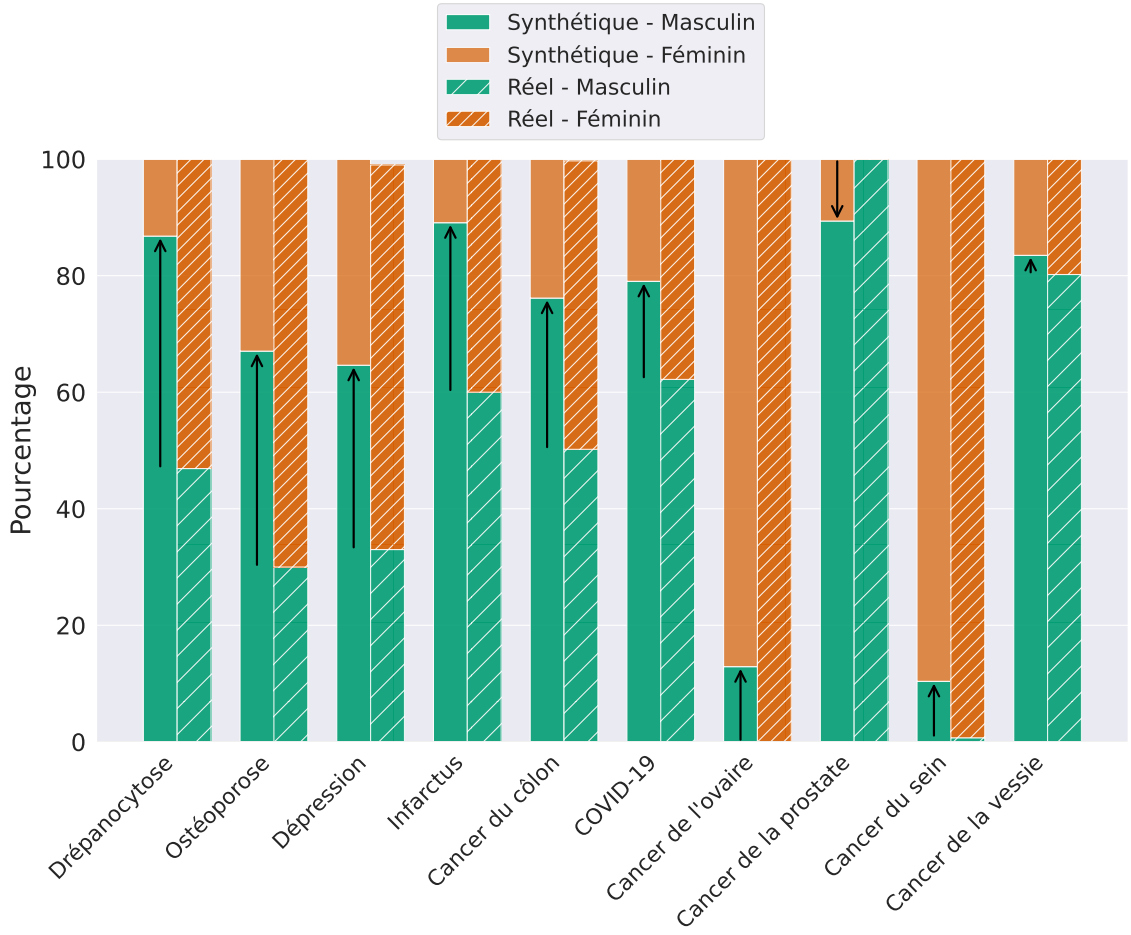


Figure 4.6 – Comparaison des distributions des genres dans les textes générés avec les distributions réelles pour chaque pathologie. Les flèches marquent l'écart entre les distributions masculines générées et réelles.

4.4.3 . Synthèse

Dans cette partie, nous nous sommes intéressés à deux éléments particuliers lors de la définition du profil patient : la pathologie et le genre. Nous avons observé d'importantes différences dans les générations de textes selon les pathologies, notamment sur deux pathologies liées au genre féminin (cancers du sein et de l'ovaire) pour lesquelles les contraintes cliniques sont moins respectées que pour les autres pathologies.

Nous avons observé que la pathologie influe énormément sur le genre du patient généré. Lorsque le genre n'est pas précisé dans l'amorce, nous observons globalement une majorité de générations de cas cliniques de patients masculins. On constate également une invisibilisation du genre minoritaire, en fonction de la prévalence de la pathologie. Par exemple, les cas d'infarctus générés ne sont que très minoritairement des femmes. Lorsque l'on précise un genre dans l'amorce, il n'est pas rare que celui-ci ne soit pas respecté, particulièrement lorsque la pathologie présente une forte prévalence. Cela permet néanmoins de limiter grandement le déséquilibre par rapport aux cas clinique générés sans précision de genre.

Certains éléments peuvent donc avoir un impact important sur les textes générés. Nous avons ici étudié le genre et la pathologie mais d'autres éléments d'influence existent potentiellement, tels que l'âge ou la situation socioprofessionnelle. Il est donc crucial de contrôler et de vérifier les textes générés afin de ne pas laisser de tels biais se propager.

4.5 . Évaluation manuelle à l'aide d'un jeu ayant un but

Les évaluations présentées jusqu'à maintenant étaient principalement des évaluations automatiques. Si ces dernières présentent des limites, elles permettent néanmoins de se faire une idée de certaines caractéristiques d'un ensemble de textes générés à une échelle que l'évaluation manuelle peut difficilement atteindre. L'évaluation manuelle n'en reste pas moins très importante, malgré les nombreux défis qu'elle soulève.

Nous avons mentionné dans la section 2.6.3 du chapitre 2 que l'évaluation manuelle de la génération de texte est une tâche complexe et que plusieurs critères de qualité peuvent être pris en compte. Évaluer un texte long en détail est cognitivement exigeant et peut rapidement devenir pénible et sujet à erreurs. Manipuler des textes d'un domaine spécialisé comme le domaine clinique ajoute une contrainte supplémentaire, des connaissances cliniques pouvant en effet être nécessaires à la compréhension et à l'analyse des textes évalués.

Nous choisissons d'appréhender l'évaluation manuelle de la génération à l'aide d'un jeu ayant un but (*Game With A Purpose - GWAP*). Notre objectif est de faciliter la tâche d'évaluation et d'annotation des textes et d'en réduire la pénibilité. Dans cette partie, nous commençons par présenter le jeu `HostoMytho`, développé dans le cadre du projet CODEINE. Le jeu est multiplateforme (navigateur web, IOS, Android) et le code source est librement disponible[4]. La programmation du jeu a été réalisée par Bertrand Remy tandis que la conception a bénéficié des contributions de Karën Fort et de Bruno Guillaume, ainsi que celles de Jules Steelandt lors d'un stage durant son cursus à l'IUT Charlemagne à Nancy. Nous analysons ensuite les annotations obtenues jusqu'à présent. Bien que la quantité d'annotations recueillies ne permette pas encore une évaluation complète, nous présentons les tendances observées dans les choix d'annotation.

Nous avons eu l'occasion, durant cette thèse, de participer aux discussions autour de la création du jeu et de fournir les textes synthétiques à ajouter dans le jeu. La création du jeu a donné lieu à une publication à l'atelier *Games and NLP* de la conférence LREC 2024 (Hiebel *et al.*, 2024).

4.5.1 . Présentation d'`HostoMytho`

4.5.1.1. Histoire et univers

L'univers d'`HostoMytho` a été pensé sur la base de la tâche de différenciation entre les textes cliniques réels et les textes cliniques synthétiques.

Cela prend la forme d'un scénario d'enquête, imaginé par Jules Steelandt durant son travail de stage. Dans l'univers du jeu, des criminels se sont échappés et se sont réfugiés dans un hôpital. Ils se cachent en se faisant passer pour des médecins. Les joueurs prennent le rôle d'enquêteurs chargés de démasquer les criminels cachés dans l'hôpital.

4. https://github.com/HostomythoApp/hostomytho-app



Figure 4.7 – Menu principal du jeu `HostoMytho`.

Les joueurs mènent l'enquête en analysant les documents cliniques produits par l'hôpital et en cherchant de potentielles erreurs. Au fur et à mesure que les joueurs accumulent des indices, l'enquête progresse et conduit à l'arrestation de suspects de plus en plus coriaces.

Le menu principal du jeu est présenté à la figure 4.7. On peut y voir un tableau de liège avec les différents éléments cliquables et des objets de bureau pour évoquer un bureau d'enquêteur. Les dessins ont été réalisés par le dessinateur Yan Lindingre et donnent au jeu une identité graphique marquée et cohérente.

4.5.1.2. Jeux disponibles

`HostoMytho` dispose actuellement de trois jeux différents pour collecter différents types d'annotations. Nous présentons ici ces trois premiers jeux. Néanmoins, la plateforme va sans doute s'enrichir de nouveaux jeux à l'avenir.

Évaluation de plausibilité avec Mytho Ou Pas Le jeu Mytho Ou Pas est le principal jeu faisant office d'évaluation pour les textes cliniques générés. Le but du jeu est d'estimer la plausibilité d'un texte donné. La plausibilité est évaluée sur une échelle de cinq valeurs, allant de « Complètement faux » à « Complètement plausible ». C'est une échelle assez simple et facilement compréhensible par n'importe quel joueur.

Une capture d'écran du jeu Mytho Ou Pas est présentée à la figure 4.8. L'exemple présenté est un texte de contrôle [5], que nous avons rédigé pour l'occasion, avec des incohérences médicales le rendant très peu plausible.

Les textes cliniques réels comme synthétiques pouvant être relativement longs, ils sont découpés et présentés en plusieurs fois aux utilisateurs. Cela permet de réduire la pénibilité de l'annotation pour les joueurs. L'annotation obtenue est donc plus précise : un même texte aura des annotations pour chacun de ces segments. Il est alors possible

5. Un texte de contrôle est un texte dont la réponse correcte pour la tâche en question est connue.



Figure 4.8 – Mytho Ou Pas : un jeu pour évaluer la plausibilité des textes.

d'estimer la qualité globale d'un texte en observant la qualité moyenne de ses segments. Néanmoins, une combinaison incohérente de plusieurs segments cohérents ne sera peut-être pas détectée. C'est une limite actuelle du jeu Mytho Ou Pas que nous allons essayer de corriger, par exemple en ajoutant un nouveau jeu à `HostoMytho` visant à évaluer le lien entre les différents segments des textes.

Outre la sélection d'un degré de plausibilité pour le texte, les joueurs peuvent optionnellement indiquer la partie du texte justifiant leur choix lorsque le texte n'est pas jugé totalement plausible. Cette information supplémentaire sera utilisée dans le jeu Mytho-Typo.

Classification d'erreurs avec Mytho-Typo Mytho-Typo est un jeu de classification d'erreurs où le but est de déterminer le type d'erreur détectée par les joueurs dans le jeu Mytho Ou Pas. Utiliser les annotations obtenues dans Mytho Ou Pas permet à la fois de ne pas complexifier la tâche de plausibilité tout en ajoutant une étape de validation des erreurs détectées dans ce premier jeu. En effet, les erreurs présentées dans Mytho-Typo doivent avoir été détectées à plusieurs reprises dans Mytho Ou Pas avant d'être présentées pour classification. Pour des raisons de simplicité, nous avons limité le nombre d'options de classification, que nous présentons ci-dessous.

Français : pour les fautes d'orthographe ou les erreurs grammaticales.

(2) Extrait d'un texte généré avec Vigogne-2 à 7 milliards de paramètres.
Monsieur R, âgé de 54 ans, sans antécédents, avait comme antécédent chirurgical un geste urologique pour vessie le 09-09-2005 à l'âge de 53 ans : cystoprostatectomie radicale avec lymphadénectomie iliaque et obturatrice associée à une omphalectomie à cause d'une tumeur de la vessie dérivant de l'ouraque droit. Les suites opératoires étaient simples. Le patient est perdu de vue ***jusqu'au découverte*** *en avril 2008, d'une masse de 4 cm de diamètre, douloureuse et mobile, de consistance molle, adhérente à l'aire vésicale d'origine prostatique et latéroutérine.*

Médicale : pour les incohérences médicales.

(3) Extrait d'un texte généré avec LLF à 1 milliard de paramètres.
[...] Elle note également avoir pris conscience peu avant chaque tentative de résolution de problèmes anxiogènes récurrents notamment ***neuroconvulsifs*** *exacerbés type syndrome délirant* ***post-hyperglycémiant*** *[...]*

Répétition : pour les répétition de segments de texte.

(4) Extrait d'un texte généré avec BLOOMZ à 7 milliards de paramètres.
[...] ***La décision de la patiente est de subir une surveillance radiologique tous les six mois****. Il n'y a pas encore de nécessité de chirurgie ni de radiothérapie.* ***La décision de la patiente est de faire un suivi radiologique tous les six mois****. On envisage également de faire une chirurgie en fonction de l'évolution de la taille et de l'activité des nodules.* ***La décision de la patiente est de subir une surveillance radiologique tous les six mois****.[...]*

Nous terminons avec deux catégories. Tout d'abord, la catégorie ***Autre*** est prévue pour couvrir les erreurs ne rentrant pas dans les trois premières catégories, ces dernières ayant été définies pour regrouper le plus largement possible les différentes erreurs observées dans les textes générés. Enfin, la catégorie ***Pas d'erreur*** sert à indiquer que le segment à classifier a été faussement annoté en tant qu'erreur.

Une capture d'écran du jeu Mytho-Typo est présentée à la figure 4.9. Sur cet exemple de contrôle, l'erreur soulignée est une faute d'accord du verbe « soulager ». Le type d'erreur à sélectionner sera donc « Français ».

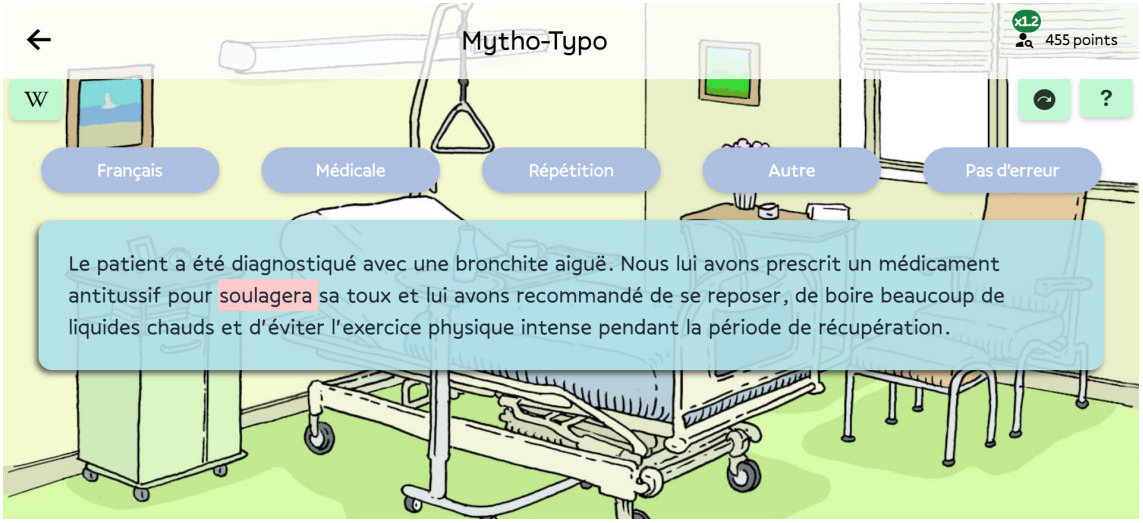


Figure 4.9 – Mytho-Typo : un jeu de classification d'erreurs.

Détection des négations avec Mytho-No Les deux premiers jeux présentés sont directement liés à l'évaluation de la qualité des textes. Le jeu Mytho-No répond à un objectif plus large de la création d'`HostoMytho` : la création d'annotations pour les textes cliniques. Ce jeu se penche sur les négations et les résultats négatifs. Ce sont en effet des éléments essentiels à détecter. Diagnostiquer et suivre un patient consiste souvent à réaliser différentes analyses selon les symptômes observés, la suite de la procédure dépendant des résultats de ces analyses.

Un traitement différent pourra être prescrit à un patient présentant ou non un symptôme particulier. On peut par exemple imaginer une différence entre un mal de ventre avec ou sans nausées associées. Or, les outils d'extraction d'informations cliniques, telles que les symptômes et procédures, vont généralement repérer l'entité sans analyser si l'élément en question est présent ou absent, positif ou négatif.

Dans l'énoncé : « *Il n'y avait pas de nausées associées* », un outil d'extraction détectera probablement « nausées » comme symptôme. C'est cependant *l'absence de nausées* qui est importante ici. Un exemple complet est donné à la figure 4.10. Le texte présenté ici contient un nombre important de négations, dont certaines ont été annotées par le joueur.

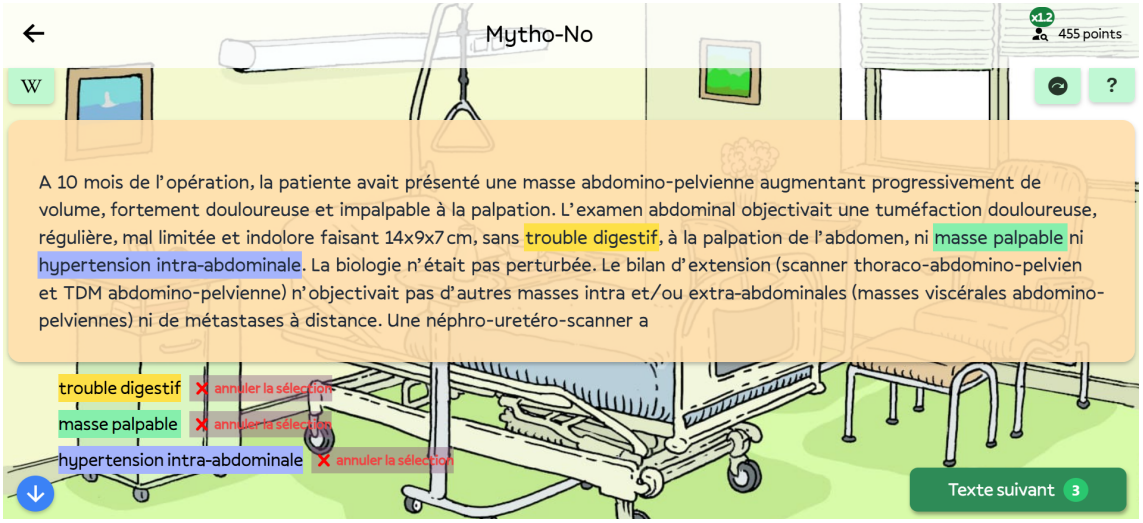


Figure 4.10 – Mytho-No : un jeu de détection de négations.

Ajout de nouveaux jeux Comme mentionné plus tôt, il est possible d'enrichir `HostoMytho` avec de nouveaux jeux afin d'obtenir d'autres annotations utiles pour le traitement de textes cliniques. Nous pensons par exemple ajouter des jeux autour de l'annotation d'hypothèses, de relations temporelles et d'implications textuelles.

4.5.1.3. Mécanismes de jeu

L'un des objectif des jeux ayant un but est de trouver des éléments ludiques à intégrer autour de la tâche afin de motiver les joueurs et les encourager à jouer au jeu.

Score et classement `HostoMytho` dispose d'un système de points représentant la progression globale des joueurs. Les points sont obtenus en jouant aux différents jeux et les joueurs peuvent consulter leur classement parmi les autres joueurs. Cela encourage les joueurs à jouer afin d'obtenir plus de points et progresser dans le classement.



Figure 4.11 – Classement général dans `HostoMytho`.

Outre le classement accessible sous forme de liste comme présenté à la figure 4.11, nous avons ajouté un emplacement sur le menu principal pour afficher les trois meilleurs enquêteurs du mois, à savoir les trois joueurs ayant obtenu le plus de points sur le mois précédent. Visible sur le menu (cf. figure 4.7), un zoom de cet emplacement est présenté à la figure 4.12.

Un classement mensuel en plus d'un classement global peut motiver les joueurs à revenir régulièrement sur le jeu. D'ailleurs, les joueurs obtiennent une médaille supplémentaire à chaque fois qu'ils terminent premier du mois (cf. figure 4.11). De plus, avoir une chance d'avoir son pseudo et son avatar affichés sur le menu principal, à la vue de tous, peut motiver les joueurs à jouer pour plus de points.

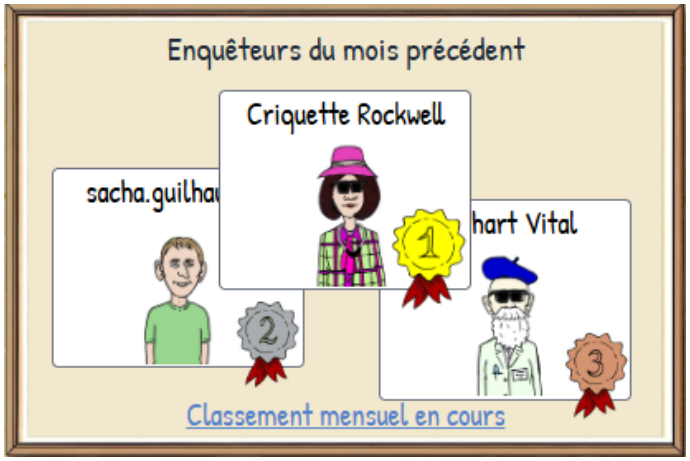


Figure 4.12 – Meilleurs enquêteurs du mois précédent (zoom sur le menu principal).

Progression de l'enquête et hauts faits L'objectif principal des joueurs dans `HostoMytho` est d'arrêter autant de criminels que possible. Les joueurs peuvent tenter d'attraper le criminel qu'ils sont en train de traquer à tout moment du jeu en accédant à un menu dédié contenant un bouton d'arrestation. Chaque arrestation a une certaine chance de réussir, dépendant du niveau de « certitude » du joueur. Ce niveau de certitude correspond à un score qui augmente au fur et à mesure que le joueur accomplit des tâches, c'est-à-dire en jouant aux différents jeux. Nous espérons que les joueurs essaieront de maximiser leurs chances de réussite en accomplissant plus de tâches.

Les joueurs traquent un criminel à la fois et passent au criminel suivant à chaque arrestation réussie. Les criminels sont de plus en plus difficiles à arrêter, encourageant le joueur à réaliser plus de tâches pour chaque arrestation. Nous espérons ainsi donner aux joueurs l'impression qu'ils progressent dans l'enquête en arrêtant des criminels de plus en plus coriaces, et que cela les motive à progresser davantage.

Un exemple de criminel est présenté à la figure 4.13. En plus de son apparence caricaturale, chaque criminel dispose d'une biographie amusante, que nous ne dévoilons pas ici.



Figure 4.13 – Un criminel dans `HostoMytho`.

HostoMytho propose aussi des hauts faits pour motiver les joueurs et récompenser les joueurs réguliers. Les hauts faits peuvent être obtenus en remplissant des objectifs divers tels qu'arrêter des criminels ou se connecter au jeu plusieurs jours consécutifs. De plus, débloquer des hauts faits augmente la vitesse à laquelle les joueurs obtiennent des points. Cela rend les hauts faits utiles en plus d'être gratifiants.

Avatar et personnalisation Dans HostoMytho, les joueurs utilisent un avatar qui représente leur enquêteur. Ces avatars peuvent être personnalisés avec différents éléments cosmétiques tels que des coiffures, des chapeaux, des vêtements et autres accessoires. Les joueurs débloquent régulièrement de nouveaux éléments de personnalisation en gagnant des points.

Un exemple de personnalisation de personnage est présenté à la figure 4.14, avec quelques éléments déjà débloqués. Personnaliser son avatar peut être ludique pour les joueurs, d'autant plus si leur avatar est affiché parmi les meilleurs enquêteurs du mois. Les éléments de personnalisation ont un niveau de rareté et découvrir de nouveaux éléments peut stimuler la curiosité des joueurs.

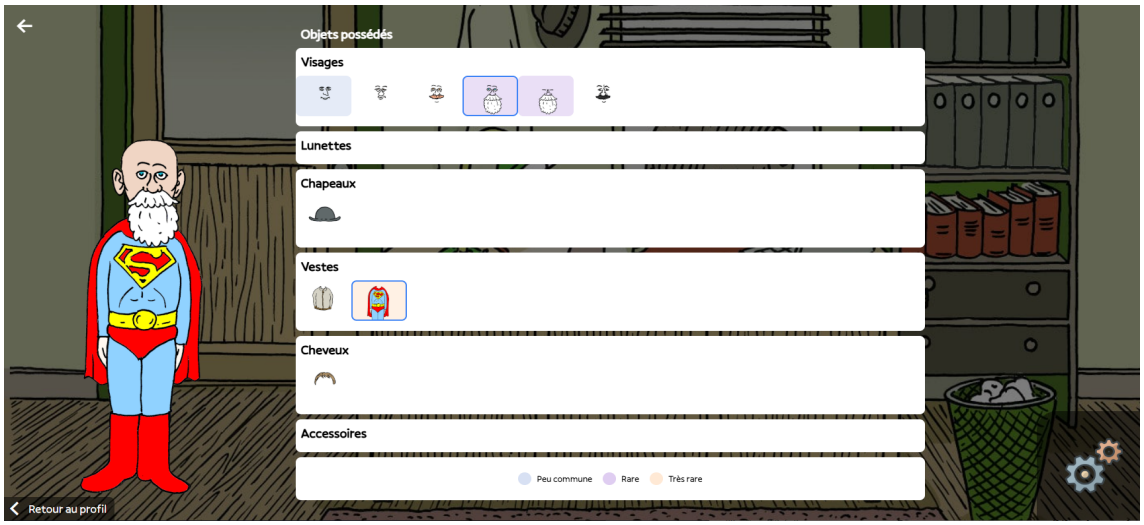


Figure 4.14 – Personnalisation de l'avatar.

4.5.1.4. Formation des joueurs

Une étape importante pour obtenir des annotations de bonne qualité est de former les joueurs aux différentes tâches proposées (Guillaume *et al.*, 2016). Pour former les joueurs, chaque jeu dispose d'un tutoriel en quelques étapes. Outre les explications, il est nécessaire que le joueur réponde correctement à un certain nombre de textes de contrôle avant de pouvoir passer à l'annotation de nouveaux textes. Cela nous permet de nous assurer que les joueurs ont correctement compris les consignes avant de produire de nouvelles annotations. Une capture d'écran du tutoriel pour le jeu Mytho ou pas est présentée à la figure 4.15.

Le tutoriel se lance automatiquement la première fois que les joueurs lancent un nouveau jeu. À tout moment, les joueurs peuvent accéder à un résumé des instructions et

peuvent relancer le tutoriel. En outre, il est possible de rapidement rechercher la définition de mots sur Wikipédia. Les textes cliniques contiennent en effet beaucoup de vocabulaire spécialisé, la définition de certains termes peut faciliter la compréhension des textes à des non initiés.



Figure 4.15 – Tutoriel au début du jeu Mytho ou pas.

4.5.2 . Conception du jeu

4.5.2.1. Diviser (les tâches) pour mieux régner

Puisque notre évaluation prend la forme d'un jeu, il est important de ne pas proposer des tâches trop complexes et des guides d'annotation trop précis, quitte à réduire la précision et la reproductibilité des résultats. Pour cette raison, nous avons décidé de décomposer le processus d'évaluation en plusieurs jeux (sous-tâches). Cela permet à la fois de réduire la charge mentale des joueurs, d'obtenir des annotations de meilleure qualité et d'avoir plus de contrôle sur ces dernières (Guillaume *et al.*, 2016). Les sous-tâches sont précises et les joueurs peuvent uniquement jouer aux tâches qui les intéressent.

4.5.2.2. Contrôler la qualité des annotations

Il est nécessaire de pouvoir estimer la qualité des annotations obtenues. Pour cela, nous prenons en compte plusieurs critères. Tout d'abord, les textes sont proposés à plusieurs joueurs afin de déterminer leur accord. Cela permet en outre d'estimer la difficulté des différentes tâches.

Ensuite, nous assignons un score de confiance à chaque joueur lors de la création de compte. Des textes de contrôle sont occasionnellement proposés aux joueurs et le score de confiance est modifié en fonction de leurs réponses. Les annotations réalisées par un joueur ayant un haut score de confiance auront plus de poids que celles générées par un joueur ayant un faible score de confiance. Les textes de contrôle peuvent être de vrais cas cliniques tirés des corpus `E3C` ou `CAS`, des textes hors sujets tirés du corpus de l'`Est Républicain`, ou bien de faux cas cliniques rédigés spécifiquement dans ce but.

4.5.2.3. S'adapter aux différents types de joueurs

Il existe plusieurs types de joueurs, qui vont apprécier plus particulièrement différents éléments de ludification. Plusieurs taxonomies ont été proposées pour classifier les différents profils (Bartle, 1996 ; Tondello *et al.*, 2016).

La figure 4.16 présente la taxonomie de Bartle (1996). Elle distingue quatre types de joueurs selon deux axes représentant les préférences des joueurs. L'axe horizontal représente la préférence de l'interaction avec le monde (à droite) ou de l'interaction avec les autres joueurs (à gauche), et l'axe vertical représente la préférence du type d'interaction, l'action (en haut) ou l'interaction (en bas).

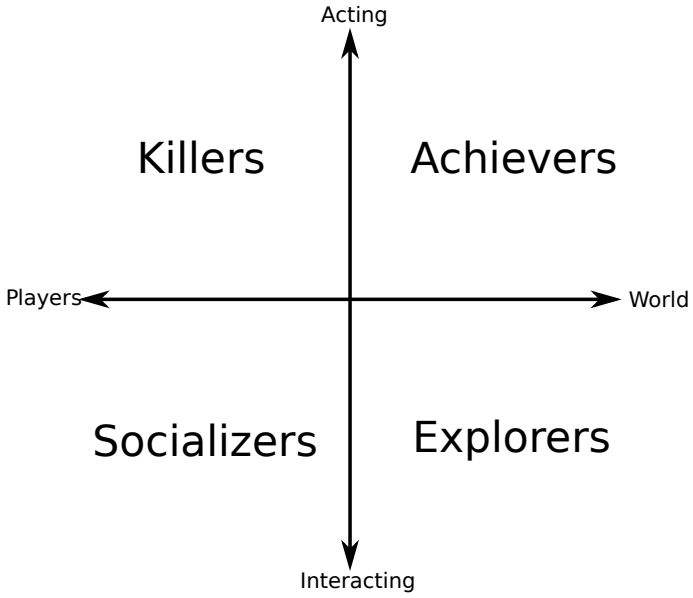


Figure 4.16 – Classification des types de joueurs selon Bartle (1996).

Plus précisément, les quatre types de joueurs sont les suivants :

Les accomplisseurs (*achievers*) se focalisent sur les objectifs du jeu, comme gagner des points, des prix, ou d'autres mesures de réussite. C'est le type de joueur à vouloir compléter le jeu à $100\ \%$.

Les explorateurs (*explorers*) aiment découvrir toutes les possibilités et secrets d'un jeu. Ce type de joueur aime expérimenter et en apprendre davantage sur l'univers du jeu.

Les socialisateurs (*socializers*) apprécient l'aspect social d'un jeu et aiment interagir avec les autres joueurs, par exemple dans des activités coopératives ou tout simplement pour former des relations sociales.

Les tueurs (*killers*) cherchent à avoir le dessus sur les autres joueurs, en les « attaquant », ou sur le jeu lui-même, en exploitant par exemple des mécanismes qui n'étaient pas prévus par les développeurs.

Par rapport aux éléments ludiques présentés dans la partie 4.5.1.3, nous pensons que le jeu `HostoMytho` pourra plaire aux accomplisseurs, aux explorateurs et aux socialisateurs.

Le système de score et de classement cible particulièrement les accomplisseurs, qui pourront être particulièrement motivés à l'idée de voir apparaître leur nom et personnage à la vue de tous sur le menu principal. La progression dans l'enquête et la collection de hauts faits ciblent également les accomplisseurs, tandis que la découverte de nouveaux criminels pourra plaire aux explorateurs. Enfin, la personnalisation de l'avatar cible particulièrement les socialisateurs et les explorateurs, qui pourraient souhaiter collectionner les éléments de personnalisation rares et montrer leurs trouvailles à d'autres joueurs.

4.5.3 . Analyse des données collectées

Nous présentons dans cette partie une première analyse des annotations récoltées sur `HostoMytho`, qui seront à terme librement partagées. Nous identifions plusieurs applications pour ces annotations. Tout d'abord, elles servent d'évaluation humaine, afin de connaître les méthodologies de génération et les modèles produisant les textes de meilleure qualité. Elles pourront également être exploitées pour améliorer la génération, en permettant par exemple de l'apprentissage par renforcement sur les textes jugés de bonne qualité. En outre, la classification des erreurs permettra de mieux cibler les limites des modèles pour améliorer la génération. Enfin, certaines annotations spécifiques (comme les négations) pourront être utilisées pour évaluer ou entraîner des systèmes d'extraction d'information. Ces systèmes pourront à leur tour contribuer à la construction de corpus plus complets pour la génération conditionnée.

4.5.3.1. Statistiques globales

Joueurs La répartition des différentes catégories de joueurs dans l'application est présentée à la figure 4.17. Sur un total de 269 comptes créés, 52 (19 %) se sont décrits comme médecin ou étudiant en médecine, 199 (75 %) se sont décrits comme ni l'un ni l'autre, et les 18 (6 %) restants n'ont pas souhaité répondre.

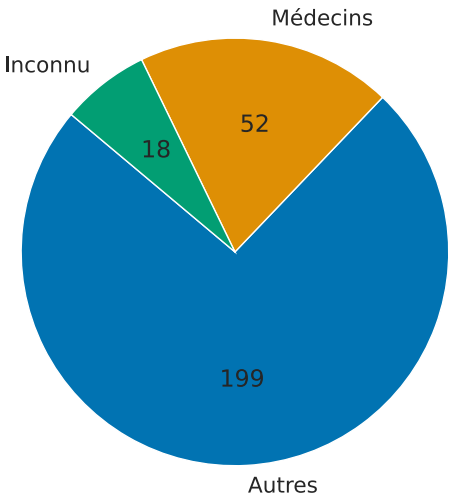


Figure 4.17 – Distribution des catégories de joueurs.

Annotations par jeu La figure 4.18 présente le nombre d'annotations obtenues pour chaque jeu actuellement disponible dans `HostoMytho`, pour un total de 5 729 annotations.

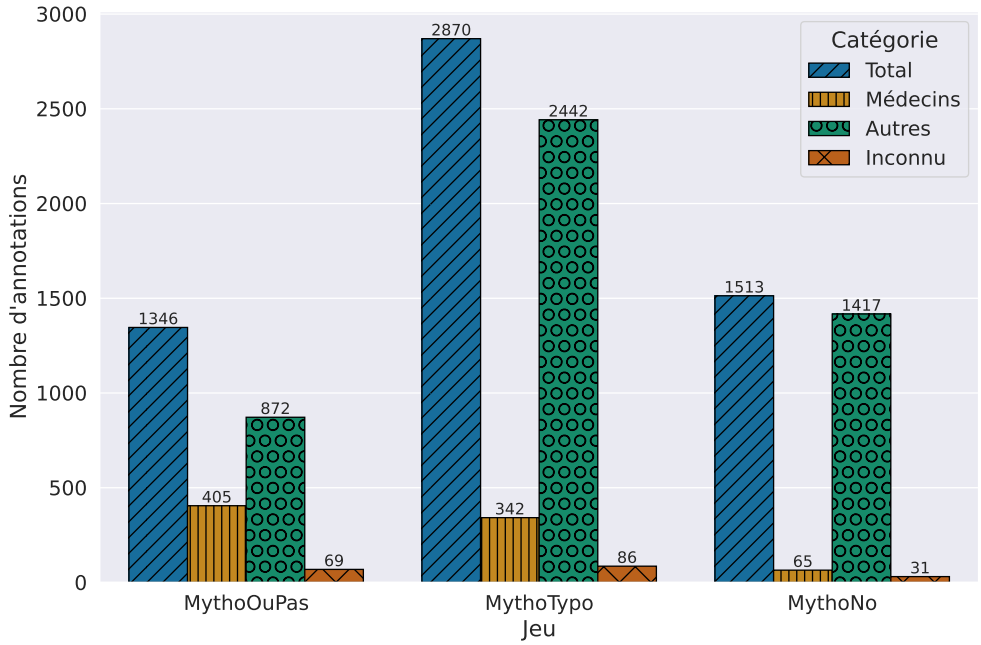


Figure 4.18 – Nombre d'annotations par jeu et par catégorie de joueurs.

On remarque que le jeu le plus joué est MythoTypo, le jeu de caractérisation d'erreur, principalement grâce à l'activité des joueurs « Autres ». Ce jeu consistant à sélectionner le type de l'erreur mise en évidence parmi cinq choix possibles est en effet nettement plus simple que les deux autres jeux. Contrairement à ces derniers, les informations sont directement mises en évidence, nécessitant ainsi moins d'attention. Cela peut expliquer pourquoi les joueurs « Autres » ont particulièrement joué à ce jeu. Les médecins ont quant à eux joué en proportion équivalente aux jeux MythoTypo et Mytho Ou Pas, le jeu de plausibilité textuelle. Cependant, le jeu MythoNo a très peu été joué par les médecins.

Dans le cadre de cette thèse, les tâches d'évaluation de la qualité des textes nous intéressent davantage pour l'instant. L'évaluation correspond aux jeux MythoTypo et Mytho Ou Pas. Il n'est donc ici pas problématique que les médecins délaissent le jeu MythoNo.

Pour la suite des analyses, nous supposons que les comptes « Inconnus » ne sont pas des médecins. Cela représente donc une large majorité de 81 % de non médecins contre 19 % de comptes médecins.

Scores de confiance À travers les scores de confiance, nous tentons de refléter la fiabilité des joueurs en modifiant ce score en fonction des réponses aux textes de contrôle auxquels les joueurs sont régulièrement confrontés. La figure 4.19 permet d'observer la répartition des scores de confiance parmi les joueurs selon leur catégorie. Pour cette fi-

gure, nous avons retiré les joueurs n'ayant pas produit d'annotation et ayant donc un score de confiance inchangé à 50.

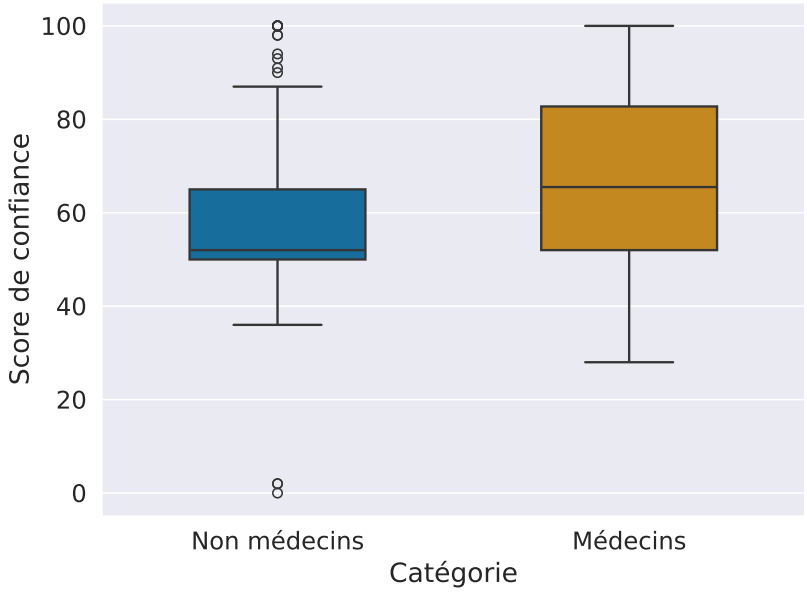


Figure 4.19 – Distribution des scores de confiance pour les médecins et les non médecins.

On constate que les médecins présentent des scores de confiance en moyenne plus élevés que les non médecins, ce qui encourage l'argument que des connaissances médicales sont utiles pour l'évaluation de la plausibilité des textes. Les scores de confiance des médecins présentent toutefois une distribution plus dispersée que les non médecins. Les scores de confiance de plusieurs joueurs, médecins comme non médecins, sont en effet nettement en dessous de la valeur de départ de 50, indiquant des réponses régulièrement erronées aux textes de contrôle. Les scores de certains médecins et non médecins atteignent le score de confiance maximum de 100. Il serait intéressant de savoir si les joueurs non médecins atteignant ce score ont finalement des connaissances médicales ou s'ils ne s'appuient pas sur de telles connaissances pour y parvenir.

Annotations par joueur La figure 4.20 illustre la participation des joueurs en montrant quelle proportion de joueur a réalisé quelle proportion d'annotations, tous jeux confondus. On remarque un phénomène connu des plateformes participatives, ou un petit nombre de participants (joueurs) réalise une majeure partie des annotations (Chamberlain *et al.*, 2013). Le joueur le plus actif d'`HostoMytho` a par exemple réalisé presque 30 % de toutes les annotations des deux jeux. En englobant tous les joueurs, on constate que 10 % des joueurs ont réalisé plus de 50 % des annotations, 30 % des joueurs ont réalisé environ 80 % des annotations et 60 % des joueurs ont réalisé plus de 90 % des annotations. Ce phénomène se remarque particulièrement chez les non médecins, dont le joueur le plus actif fait partie.

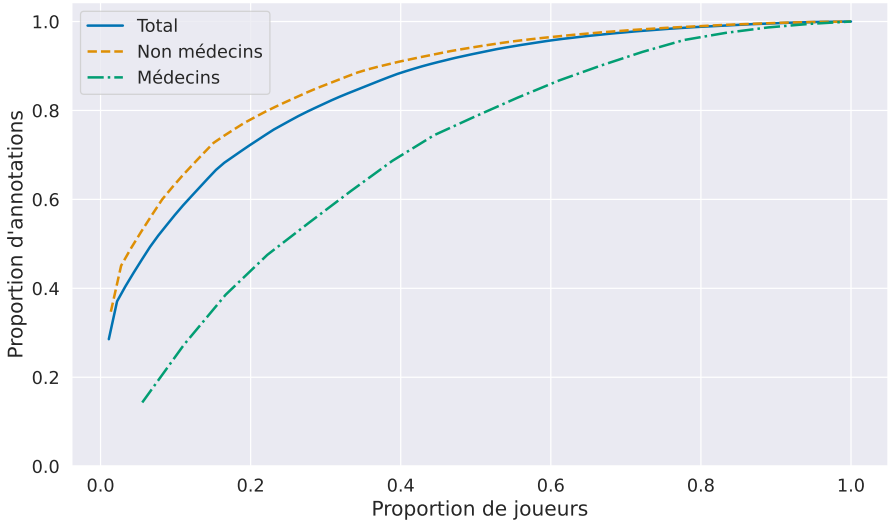


Figure 4.20 – Participation des joueurs.

4.5.3.2. Comparaison des annotations entre médecins et non médecins

Plausibilité La figure 4.21 présente la distribution des annotations récoltées dans Mytho Ou Pas.

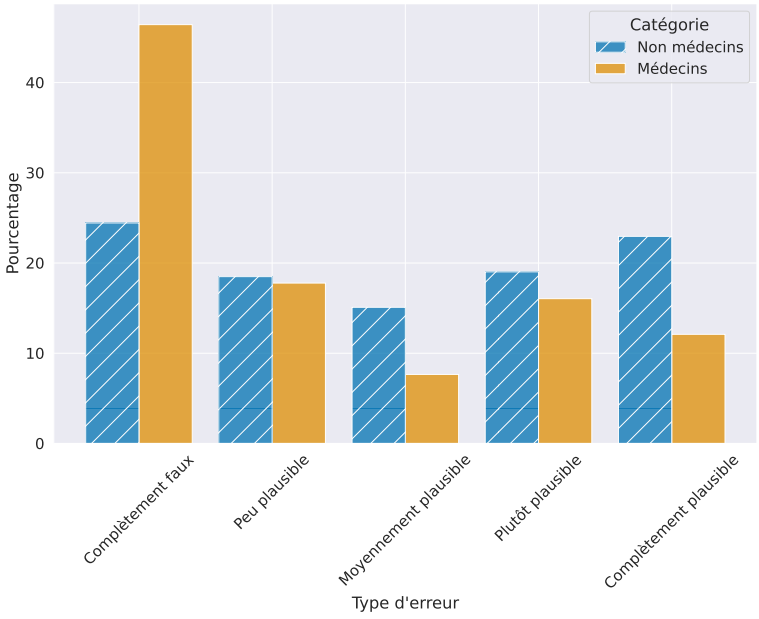


Figure 4.21 – Distribution des annotations de plausibilité dans Mytho Ou Pas.

Globalement, on constate que plausibilité la plus couramment annotée est « Complètement faux ». Cela est particulièrement vrai pour les médecins qui choisissent cette

annotations environ 45 % du temps. Les non médecins annotent de manière plus homogène entre les différents niveaux de plausibilité, avec une légère préférence pour les deux plausibilités extrêmes. En revanche, pour les deux catégories de joueur, l'annotation médiane « Moyennement plausible » est la moins représentée, les joueurs préférant choisir des plausibilités plus hautes ou plus basses. Nous calculons les accords inter-annotateurs entre les joueurs pour la tâche de plausibilité. Afin de ne conserver que les annotations des joueurs les plus performants, nous sélectionnons uniquement les joueurs dont le score de confiance est supérieur ou égal à 80 (le palier a été choisi en fonction des distributions observées à la figure 4.19). Nous utilisons pour cela un α de Krippendorff, permettant notamment de gérer le fait que tous les joueurs n'ont pas annoté tous les textes.

Sur l'ensemble des joueurs ayant un score de confiance supérieur à 80, l'α calculé est à 0,41, indiquant une faible entente entre les annotateurs. Pour les médecins, cet accord monte à 0,6 tandis qu'il vaut 0,4 pour les non médecins. Malgré des accords faibles, les médecins semblent en moyenne davantage en accord sur les annotations de plausibilité. Il faudrait cependant un nombre plus important d'annotations pour confirmer cette observation.

Classification d'erreur La figure 4.22 présente la distribution des différents types d'erreurs annotées dans MythoTypo.

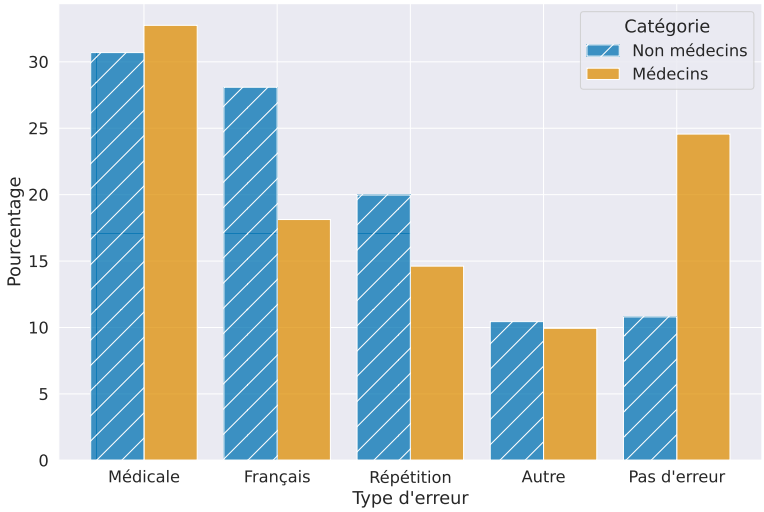


Figure 4.22 – Distribution des différents types d'erreurs annotées dans MythoTypo.

On constate que la catégorie « Médicale » est la plus utilisée, quelle que soit la catégorie de joueurs. On remarque également un nombre important d'annotations dans les catégories « Français » et « Répétition » que les non médecins utilisent régulièrement. Lorsque les médecins jugent que la séquence à classifier n'est pas une erreur médicale, on remarque un nombre important d'annotations pour la catégorie « Pas d'erreur », nettement moins représentée chez les non médecins. Enfin, l'annotation « Autre » est la plus

rarement utilisée chez les deux catégories de joueurs. Il serait intéressant d'analyser les erreurs classées dans cette dernière catégorie. Leur faible représentation montre néanmoins que les catégories choisies permettent de couvrir une grande partie des erreurs dans les textes synthétiques générés.

Nous calculons l'accord inter-annotateur sur cette tâche de classification avec un α de Krippendorff, en observant uniquement les joueurs avec un score de confiance supérieur à 80. Sur cet ensemble de joueur, l'α observé est de 0,32, indiquant un accord encore plus faible que pour le jeu Mytho Ou Pas. Cette fois-ci, ce sont les non médecins qui présentent un accord annotateur plus élevé que les médecins, avec un α de 0,34 contre 0,22. Cette tendance doit une fois encore être confirmée par un nombre plus important d'annotations.

4.6 . Conclusion

Dans ce chapitre, nous avons abordé la question de l'évaluation de la génération de texte. Pour chaque méthodologie de génération présentée dans le chapitre 3, nous avons proposé des métriques d'évaluation différentes, ciblant des critères pertinents pour les objectifs de chaque méthodologie.

Nos résultats montrent que nous sommes parvenus à adapter les méthodes de génération de texte sur des cas cliniques français, avec la possibilité de conditionner la génération à partir de profils patient constitués d'éléments cliniques. En outre, nous avons souligné le besoin de prendre en compte les biais des modèles génératifs pré-entraînés, les textes générés pouvant nuire à certains groupes sociaux. Les protocoles d'évaluation proposés dans ce chapitre sont, comme les méthodologies de génération, facilement applicables à d'autres domaines ou langues dès lors que des outils d'analyse adaptés sont disponibles.

Pour complémenter ces évaluations, nous avons présenté le jeu `HostoMytho`, dont l'objectif est l'évaluation et l'annotation de textes synthétiques dans le domaine clinique. Nous ne disposons pas encore d'assez d'annotations pour pouvoir faire des analyses robustes. Nous avons toutefois présenté l'état actuel du jeu et les tendances dans les annotations récoltées. Nous espérons collecter davantage d'annotations, permettant de mieux analyser les performances des modèles de génération, voire d'entraîner des modèles d'évaluation automatique.

5 - Conclusion

5.1 . Résumé des contributions

Dans cette thèse, nous nous sommes intéressés à la génération automatique de cas cliniques en français afin de pallier le manque de corpus partageables dans ce domaine.

Nous avons commencé dans le chapitre 2 par présenter l'évolution de la génération automatique de texte, en débutant par les méthodes symboliques, très contrôlables mais pour lesquelles il est difficile de générer des textes naturels, jusqu'aux méthodes statistiques et neuronales actuelles présentant des caractéristiques inverses. Nous avons décrit en détail le fonctionnement de ces méthodes neuronales, qui, bien qu'elles obtiennent des performances à l'état de l'art pour la génération de texte, présentent intrinsèquement des faiblesses et des biais. Nous avons également évoqué les difficultés liées à l'évaluation automatique des textes générés, qu'elle soit automatique ou manuelle. Enfin, nous avons discuté des applications de la génération de texte dans le domaine clinique et réfléchi aux implications de l'utilisation de telles méthodes et de leurs faiblesses dans un domaine sensible comme la santé.

Dans cette thèse, notre question de recherche principale était : **comment générer des textes ressemblant à des textes cliniques réels ?** Dans le chapitre 3, nous avons présenté plusieurs méthodologies de génération de cas cliniques synthétiques en français, répondant ainsi à la première question de recherche plus précise, à savoir : (1) **comment adapter les méthodes de génération de texte au domaine clinique en français ?** Pour cela, nous avons utilisé des corpus de cas cliniques en français librement disponibles.

Nous avons exploré trois méthodologies de génération dont l'objectif était la production de corpus de cas cliniques synthétiques représentatifs des corpus réels. La possibilité de contrôler la génération en fonction de thématiques spécifiques étant un point central, nous avons proposé un protocole de construction de corpus permettant l'affinage de modèles sur une tâche de génération de cas cliniques conditionnée par des profils patient. Nous utilisons pour cela des outils de reconnaissance d'entités cliniques pour construire à moindre coût les profils patient à partir des textes réels. Ce protocole est applicable à d'autres domaines, à condition de disposer d'outils d'analyse adaptés. Nous souhaitions également étudier la robustesse de ce conditionnement en ciblant des variables sensibles associées à des biais et stéréotypes : le genre et la pathologie. Pour cela, nous sélectionnons 10 pathologies plus ou moins stéréotypées pour lesquelles nous avons manuellement construit les profils patient. Pour chaque pathologie, nous générons plusieurs cas cliniques à partir du profil patient en faisant varier le genre dans l'amorce entre féminin, masculin et neutre.

Pour toutes ces expériences de génération, nous avons utilisé des modèles de langue génératifs pré-entraînés en nous appuyant sur leur capacité à générer du texte car nous ne disposions pas de corpus suffisamment grands pour pouvoir les entraîner à partir de zéro.

Le chapitre 4 porte sur l'évaluation des textes synthétiques générés, cherchant ainsi à répondre à notre dernière question de recherche : (2) **comment évaluer la qualité des modèles définis et des textes générés ?** Ce chapitre est toutefois étroitement lié au chapitre précédent puisque l'évaluation est nécessaire pour connaître les performances des méthodologies de génération. C'est pourquoi nous proposons des évaluations différentes pour chacune des trois méthodologies de génération, en adaptant les dimensions évaluées aux objectifs de génération.

Nous avons commencé par évaluer l'adaptation au domaine en nous intéressant au recouvrement lexical avec le corpus réel dont les données synthétiques s'inspirent. Nous avons constaté que les textes générés sont raisonnablement éloignés des textes réels sans copier de longs segments de texte. Cette observation est confirmée par l'analyse des plongements de phrases des corpus réels et synthétiques, répondant partiellement à la partie évaluation de la question : (4) **comment générer des textes ne comportant pas de risque pour la confidentialité des patients ?** . Cette évaluation n'apporte toutefois pas de garantie quant aux réels risques liés à la confidentialité des textes générés. Nous avons en outre proposé un protocole pour évaluer l'utilité des textes synthétiques sur une tâche de reconnaissance d'entités cliniques sans nécessiter l'annotation manuelle des textes synthétiques. Ce protocole peut également être appliqué à d'autres tâches et domaines à l'aide d'outils d'analyse adaptés. Enfin, nous avons constaté à l'aide d'une analyse manuelle de plusieurs échantillons que les textes synthétiques contiennent un nombre important d'erreurs et d'incohérences. Les textes ainsi générés sont donc utiles dans un cadre précis, mais ils sont probablement peu adaptés à d'autres tâches, nécessitant plus de cohérence.

L'évaluation de la contrôlabilité des modèles a confirmé la pertinence de notre méthodologie de construction de corpus, permettant d'obtenir des modèles capables de générer des cas cliniques conditionnés par des profils patient. L'évaluation a été réalisée à l'aide d'un ensemble de métriques automatiques. Pour cette expérience, nous avons comparé les performances de plusieurs modèles, dont deux architectures différentes : les encodeurs-décodeurs et les encodeurs seuls. Nous avons constaté que les encodeurs-décodeurs sont globalement plus contrôlables que les décodeurs et génèrent des textes plus proches des textes réels tandis que les textes générés par les décodeurs s'écartent davantage des textes réels, et ce même lorsque les contraintes sont respectées. Cependant, les encodeurs-décodeurs sont nettement plus coûteux à entraîner que les décodeurs et les études actuelles visant à améliorer la génération de texte se concentrent davantage sur les décodeurs, permettant également une optimisation des coûts de génération. Cette optimisation nécessite toutefois une infrastructure de calcul adaptée. Ainsi, si peu de ressources sont disponibles, nous conseillons plutôt d'utiliser un petit encodeur-décodeur ou un décodeur seul selon les moyens à disposition, répondant ainsi à la question : (3) **comment générer des textes avec des contraintes de temps et de puissance de calcul ?**

Pour mieux connaître les conditions de contrôlabilité, nous avons observé l'influence du genre et de la pathologie sur les générations. Nous avons mesuré la contrôlabilité des modèles utilisés selon la pathologie et nous avons constaté que certaines pathologies, notamment stéréotypées féminines, obtiennent de nettement moins bonnes performances.

Nous avons également analysé le genre dans les cas cliniques générés à l'aide d'un outil de détection automatique du genre en français. Nous avons observé que pour certaines pathologies, il est relativement fréquent que le genre donné en amorce soit ignoré. Lorsque le genre n'est pas précisé en amorce, les générations sont particulièrement biaisées et ne respectent ni la parité, ni les prévalences observées, en mettant majoritairement en scène des hommes. Par exemple, très peu de cas cliniques de crises cardiaques générés correspondent à des femmes, ce qui peut renforcer des problèmes de diagnostics déjà existants (Pelletier *et al.*, 2014 ; Pagidipati et Peterson, 2016). Certains biais et stéréotypes peuvent donc influer sur la contrôlabilité des modèles. Il est important d'en tenir compte lors de l'utilisation des modèles génératifs, qui nécessite une supervision, particulièrement dans un domaine comme le domaine clinique.

Nous avons terminé le chapitre 4 avec la présentation du jeu ayant un but `HostoMytho`, visant à évaluer manuellement les textes synthétiques générés. Nous avons commencé par présenter le jeu et les notions derrière sa conception avant d'analyser les annotations récoltées jusqu'à maintenant. À l'heure actuelle, les annotations sont encore trop éparses et ne permettent pas une analyse pertinente des textes synthétiques. Nous observons toutefois des tendances dans les annotations, en constatant par exemple un faible accord entre les joueurs de confiance dans toutes les tâches analysées.

5.2 . Limites et perspectives

Au cours de cette thèse, nous avons tenté de générer des cas cliniques en français et de proposer une évaluation aussi complète que possible. Nous présentons dans cette section les limites de ce travail, associées à des perspectives de travaux futurs cherchant à les pallier.

5.2.1 . Contrôle de la génération

Nous avions décrit au chapitre 2 les deux catégories de méthodes visant à contrôler les modèles de génération : le contrôle par l'entraînement et la génération coopérative. Notre travail s'est concentré sur la première catégorie avec la construction de corpus permettant l'entraînement de modèles pouvant ensuite être conditionnés vers des profils patient. L'utilisation d'outils d'analyses différents pourrait donc permettre de construire des corpus et de conditionner la génération vers des éléments différents. Il serait également pertinent de s'intéresser à la génération coopérative pour contrôler la génération et de comparer autant les textes générés que les coûts de génération liés à ces approches.

5.2.2 . Coûts de génération

Nous avons dans le chapitre 4 présenté l'évaluation des temps de calcul et l'impact environnemental des modèles de génération de texte pour la tâche de génération de cas cliniques conditionnée par des profils patient. Cette évaluation permet d'estimer les coûts d'utilisation des différents modèles, mais pourrait bénéficier d'un approfondissement. En effet, il serait intéressant d'observer plus précisément les besoins de chaque méthode au niveau de la puissance de calcul, en explorant par exemple la quantité minimale de mémoire nécessaire pour l'utilisation des modèles.

5.2.3 . Application à d'autres corpus

Enfin, nous avons dans cette thèse exploré exclusivement la génération de cas cliniques. Les cas cliniques se rapprochent en effet des documents cliniques stockés dans les hôpitaux et présentent l'avantage d'être plus faciles à partager. Il serait toutefois intéressant de tester les méthodes de génération présentées dans cette thèse sur d'autres types de textes cliniques.

Nous discernons pour cela deux pistes intéressantes. La première serait simplement d'utiliser les modèles sur un corpus de textes internes à un hôpital en utilisant les statistiques de l'hôpital (par exemple, le nombre de patients touchés par une pathologie particulière) pour construire un corpus avec le moins de risques possible pour la confidentialité des patients. Cette logique devra également être appliquée à la construction des profils patient afin de conditionner le modèle vers un texte sans risque. Des vérifications conséquentes devront toutefois être réalisées avant de pouvoir partager les textes ainsi générés.

La seconde piste serait d'utiliser les modèles entraînés sur la génération contrainte de cas cliniques, cette fois-ci en construisant des profils patient à l'aide des données internes d'un hôpital, permettant ainsi de générer un texte correspondant à ce profil mais ne risquant pas de divulguer des informations sensibles de l'hôpital, puisque le modèle n'aura été entraîné que sur des cas cliniques publics. Cette approche offrirait en amont une garantie que les textes générés ne contiennent pas d'informations provenant de l'hôpital.

5.2.4 . Évaluation

Nous avons mentionné de nombreuses fois dans ce manuscrit que l'évaluation de la génération de texte posait un nombre important de difficultés, que celle-ci soit automatique ou manuelle. Bien que nous proposions des évaluations adaptées aux objectifs de génération, il est possible d'en approfondir certains aspects.

Avec `HostoMytho`, nous proposons une interface pour l'évaluation manuelle de textes synthétiques dans un domaine spécialisé comme le domaine médical. Afin de réduire la charge cognitive et la pénibilité de la tâche, nous avons choisi de diviser l'évaluation en plusieurs tâches et de proposer un panel restreint de choix aux différentes tâches. La tâche d'évaluation étant chronophage, il est difficile pour les cliniciens d'y consacrer du temps, leurs patients passant bien évidemment en priorité. Une évaluation plus précise par des experts en santé aurait néanmoins pu apporter davantage d'éléments pour identifier les erreurs, particulièrement médicales, trouvées dans les textes synthétiques. Ces éléments pourraient contribuer à l'amélioration des modèles de génération.

L'étude des risques au niveau de la confidentialité des textes générés pourrait être approfondie. Si nous avons tenté d'observer le recouvrement lexical et la similarité phrastique entre les corpus synthétiques et le corpus réel, ces évaluations ne permettent pas d'affirmer ou d'infirmer la présence d'éléments à risque dans les textes synthétiques. De la même manière, conditionner la génération vers des profils patient spécifiques ne garantit pas l'absence d'éléments à risque. C'est pourquoi une exploration plus poussée de cette dimension d'évaluation est une perspective importante. Cette évaluation n'est cependant pas triviale, les méthodes existantes cherchant à attaquer les modèles géné-

ratifs et non pas seulement un ensemble fixe de textes générés, correspondant à notre objectif de partage. En outre, cette évaluation relève du champ de la sécurité, dans lequel on assiste continuellement à un jeu du chat et de la souris, avec d'un côté les personnes cherchant à protéger les données et de l'autre celles cherchant à les attaquer. L'étude des méthodes d'attaque et de protection des données est donc vaste et justifierait un travail de thèse à part entière. Le projet CODEINE a été l'occasion d'encadrer Foucauld Estignard au cours d'un stage, en collaboration avec Julien Girard du CEA, travaillant sur la sécurité des données. Ce stage a été l'occasion d'explorer une méthodologie d'attaque par inférence d'appartenance (*Membership Inference Attack*) sur un corpus synthétique en utilisant un modèle affiné sur ce corpus synthétique. Si les résultats ont montré qu'il n'était pas possible d'identifier les données du corpus d'entraînement, cette approche est, à notre connaissance, l'une des premières à cibler directement un corpus de textes synthétiques plutôt qu'un modèle. Cette méthodologie pourrait donc être améliorée et évoluer conjointement avec les méthodologies de génération, afin de produire des données synthétiques partageables avec certaines garanties de confidentialité.

Bibliographie

Abedi, M., Hempel, L., Sadeghi, S. et Kirsten, T. (2022). GAN-Based Approaches for Generating Structured Data in the Medical Domain. *Applied Sciences*, 12(14).

Abrahamsson, E., Forni, T., Skeppstedt, M. et Kvist, M. (2014). Medical text simplification using synonym replacement : Adapting assessment of word difficulty to a compounding language. *In* Williams, S., Siddharthan, A. et Nenkova, A., éditeurs : *Proceedings of the 3rd Workshop on Predicting and Improving Text Readability for Target Reader Populations (PITR)*, pages 57–65, Göteborg, Suède. Association for Computational Linguistics.

AI@Meta (2024). Llama 3 model card.

Alavoine, N., Coavoux, M., Esperança-Rodier, E., Gallienne, R., González-Gallardo, C.-E., Goulian, J., Moreno, J. G., Névéol, A., Schwab, D., Segonne, V. et Simoens, J. (2024). Limitations of human identification of automatically generated text. *In* Calzolari, N., Kan, M.-Y., Hoste, V., Lenci, A., Sakti, S. et Xue, N., éditeurs : *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pages 10511–10516, Turin, Italie. ELRA and ICCL.

Amin-Nejad, A., Ive, J. et Velupillai, S. (2020). Exploring transformer text generation for medical dataset augmentation. *In* Calzolari, N., Béchet, F., Blache, P., Choukri, K., Cieri, C., Declerck, T., Goggi, S., Isahara, H., Maegaard, B., Mariani, J., Mazo, H., Moreno, A., Odijk, J. et Piperidis, S., éditeurs : *Proceedings of the Twelfth Language Resources and Evaluation Conference*, pages 4699–4708, Marseille, France. European Language Resources Association.

Arndt, B. G., Beasley, J. W., Watkinson, M. D., Temte, J. L., Tuan, W.-J., Sinsky, C. A. et Gilchrist, V. J. (2017). Tethered to the EHR : Primary Care Physician Workload Assessment Using EHR Event Log Data and Time-Motion Observations. *The Annals of Family Medicine*, 15(5): 419–426.

ATILF et CLLE (2020). Corpus journalistique issu de l'est républicain. ORTOLANG (Open Resources and TOols for LANGuage) –www.ortolang.fr.

Banerjee, S. et Lavie, A. (2005). METEOR : An automatic metric for MT evaluation with improved correlation with human judgments. *In* Goldstein, J., Lavie, A., Lin, C.-Y. et Voss, C., éditeurs : *Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization*, pages 65–72, Ann Arbor, Michigan, États-Unis. Association for Computational Linguistics.

Bannour, N., Wajsbürt, P., Rance, B., Tannier, X. et Névéol, A. (2022). Privacy-preserving mimic models for clinical named entity recognition in french. *Journal of Biomedical Informatics*, 130:104073.

Bartle, R. (1996). Hearts, clubs, diamonds, spades : Players who suit MUDs. *The Journal of Virtual Environments*, 1(1).

Bateman, J. et Zock, M. (2022). Natural language generation. *In The Oxford Handbook of Computational Linguistics*, pages 747—769. Oxford University Press.

Ben Abacha, A., Yim, W.-w., Adams, G., Snider, N. et Yetisgen, M. (2023a). Overview of the MEDIQA-chat 2023 shared tasks on the summarization & generation of doctor-patient conversations. *In* Naumann, T., Ben Abacha, A., Bethard, S., Roberts, K. et Rumshisky, A., éditeurs : *Proceedings of the 5th Clinical Natural Language Processing Workshop*, pages 503–513, Toronto, Canada. Association for Computational Linguistics.

Ben Abacha, A., Yim, W.-w., Fan, Y. et Lin, T. (2023b). An empirical study of clinical note generation from doctor-patient encounters. *In* Vlachos, A. et Augenstein, I., éditeurs : *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 2291–2302, Dubrovnik, Croatie. Association for Computational Linguistics.

Ben Abacha, A., Yim, W.-w., Michalopoulos, G. et Lin, T. (2023c). An investigation of evaluation methods in automatic medical note generation. *In* Rogers, A., Boyd-Graber, J. et Okazaki, N., éditeurs : *Findings of the Association for Computational Linguistics : ACL 2023*, pages 2575–2588, Toronto, Canada. Association for Computational Linguistics.

Bender, E. M., Gebru, T., McMillan-Major, A. et Shmitchell, S. (2021). On the dangers of stochastic parrots : Can language models be too big ? *In Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, FAccT '21, page 610–623, New York, NY, États-Unis. Association for Computing Machinery.

Bengio, Y., Ducharme, R., Vincent, P. et Jauvin, C. (2003). A neural probabilistic language model. *Journal of Machine Learning Research*, 3:1137–1155.

Berg, N. et Dalianis, H. (2024). Using BART to automatically generate discharge summaries from Swedish clinical text. *In* Demner-Fushman, D., Ananiadou, S., Thompson, P. et Ondov, B., éditeurs : *Proceedings of the First Workshop on Patient-Oriented Language Processing (CL4Health) @ LREC-COLING 2024*, pages 246–252, Turin, Italie. ELRA and ICCL.

Boubdir, M., Kim, E., Ermis, B., Hooker, S. et Fadaee, M. (2023). Elo uncovered : Robustness and best practices in language model evaluation. *In* Gehrmann, S., Wang, A., Sedoc, J., Clark, E., Dhole, K., Chandu, K. R., Santus, E. et Sedghamiz, H., éditeurs : *Proceedings of the Third Workshop on Natural Language Generation, Evaluation, and Metrics (GEM)*, pages 339–352, Singapour. Association for Computational Linguistics.

Boulanger, H., Hiebel, N., Ferret, O., Fort, K. et Névéol, A. (2024). Using structured health information for controlled generation of clinical cases in French. *In* Naumann, T., Ben Abacha, A., Bethard, S., Roberts, K. et Bitterman, D., éditeurs : *Proceedings of the 6th Clinical Natural Language Processing Workshop*, pages 172–184, Mexico, Mexique. Association for Computational Linguistics.

Brown, H., Lee, K., Mireshghallah, F., Shokri, R. et Tramèr, F. (2022). What does it mean for a language model to preserve privacy ? *In Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency*, FAccT '22, page 2280–2292, New York, NY, États-Unis. Association for Computing Machinery.

Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I. et Amodei, D. (2020). Language models are few-shot learners. *In* Larochelle, H., Ranzato, M., Hadsell, R., Balcan, M. et Lin, H., éditeurs : *Advances in Neural Information Processing Systems*, volume 33, pages 1877–1901, En ligne. Curran Associates, Inc.

Buolamwini, J. et Gebru, T. (2018). Gender shades : Intersectional accuracy disparities in commercial gender classification. *In* Friedler, S. A. et Wilson, C., éditeurs : *Proceedings of the 1st Conference on Fairness, Accountability and Transparency*, volume 81 de *Proceedings of Machine Learning Research*, pages 77–91. PMLR.

Campillos, L., Deléger, L., Grouin, C., Hamon, T., Ligozat, A.-L. et Névéol, A. (2018). A French clinical corpus with comprehensive semantic annotations : development of the Medical Entity and Relation LIMSI annOtated Text corpus (MERLOT). *Language Resources and Evaluation*, 52(2):571–601.

Cardon, R. et Grabar, N. (2020). A French corpus for semantic similarity. *In Proceedings of the 12th Language Resources and Evaluation Conference*, pages 6889–6894, Marseille, France. European Language Resources Association.

Carlini, N., Ippolito, D., Jagielski, M., Lee, K., Tramer, F. et Zhang, C. (2023). Quantifying memorization across neural language models. *In The Eleventh International Conference on Learning Representations*, Kigali, Rwanda.

Carrell, D. S., Cronkite, D. J., Li, M. R., Nyemba, S., Malin, B. A., Aberdeen, J. S. et Hirschman, L. (2019). The machine giveth and the machine taketh away : a parrot attack on clinical text deidentified with hiding in plain sight. *Journal of the American Medical Informatics Association*, 26(12):1536–1544.

Casal, J. E. et Kessler, M. (2023). Can linguists distinguish between chatgpt/ai and human writing ? : A study of research ethics and academic publishing. *Research Methods in Applied Linguistics*, 2(3):100068.

Chaffin, A., Claveau, V. et Kijak, E. (2022). PPL-MCTS : Constrained textual generation through discriminator-guided MCTS decoding. *In* Carpuat, M., de Marneffe, M.-C. et Meza Ruiz, I. V., éditeurs : *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies*, pages 2953–2967, Seattle, États-Unis. Association for Computational Linguistics.

Chamberlain, J., Fort, K., Kruschwitz, U., Lafourcade, M. et Poesio, M. (2013). *Using Games to Create Language Resources : Successes and Limitations of the Approach*, pages 3–44. Springer Berlin Heidelberg, Berlin, Heidelberg.

Chen, I. Y., Pierson, E., Rose, S., Joshi, S., Ferryman, K. et Ghassemi, M. (2021a). Ethical machine learning in healthcare. *Annual Review of Biomedical Data Science*, 4(Volume 4, 2021):123–144.

Chen, Z., Shen, Y., Song, Y. et Wan, X. (2021b). Cross-modal memory networks for radiology report generation. *In* Zong, C., Xia, F., Li, W. et Navigli, R., éditeurs : *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1 : Long Papers)*, pages 5904–5914, En ligne. Association for Computational Linguistics.

Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H. et Bengio, Y. (2014). Learning phrase representations using RNN encoder–decoder for statistical machine translation. *In* Moschitti, A., Pang, B. et Daelemans, W., éditeurs : *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1724–1734, Doha, Qatar. Association for Computational Linguistics.

Choi, E., Biswal, S., Malin, B., Duke, J., Stewart, W. F. et Sun, J. (2017). Generating multi-label discrete patient records using generative adversarial networks. *In* Doshi-Velez, F., Fackler, J., Kale, D., Ranganath, R., Wallace, B. et Wiens, J., éditeurs : *Proceedings of the 2nd Machine Learning for Healthcare Conference*, volume 68 de *Proceedings of Machine Learning Research*, pages 286–305, Boston, Massachusetts, États-Unis. PMLR.

Chowdhury, M., Lim, E., Higham, A., McKinnon, R., Ventoura, N., He, Y. et De Pennington, N. (2023). Can large language models safely address patient questions following cataract surgery ? *In* Naumann, T., Ben Abacha, A., Bethard, S., Roberts, K. et Rumshisky, A., éditeurs : *Proceedings of the 5th Clinical Natural Language Processing Workshop*, pages 131–137, Toronto, Canada. Association for Computational Linguistics.

Clarke, M. A., Steege, L. M., Moore, J. L., Belden, J. L., Koopman, R. J. et Kim, M. S. (2013). Addressing human computer interaction issues of electronic health record in clinical encounters. *In* Marcus, A., éditeur : *Design, User Experience, and Usability. Health, Learning, Playing, Cultural, and Cross-Cultural User Experience*, pages 381–390, Berlin, Heidelberg, Allemagne. Springer Berlin Heidelberg.

Claveau, V., Chaffin, A. et Kijak, E. (2022). Generating artificial texts as substitution or complement of training data. *In Proceedings of the Language Resources and Evaluation Conference*, pages 4260–4269, Marseille, France. European Language Resources Association.

Clynch, N. et Kellett, J. (2015). Medical documentation : Part of the solution, or part of the problem ? a narrative review of the literature on the time spent on and value of medical documentation. *International Journal of Medical Informatics*, 84(4):221–228.

Cohen, G. R., Friedman, C. P., Ryan, A. M., Richardson, C. R. et Adler-Milstein, J. (2019). Variation in physicians' electronic health record documentation and potential patient harm from that variation. *Journal of General Internal Medicine*, 34(11):2355–2367.

Cohen, R., Elhadad, M. et Elhadad, N. (2013). Redundancy in electronic health record corpora : Analysis, impact on text mining performance and mitigation strategies. *BMC bioinformatics*, 14:10.

Danlos, L. (1985). Un survol des recherches en génération automatique. *Revue québécoise de linguistique*, 14(2):65–102.

Danlos, L. (2000). Linguistique informatique. *In* Michaud, Y., éditeur : *Qu'est-ce que l'humain ?*, volume 2. Odile Jacob.

Dathathri, S., Madotto, A., Lan, J., Hung, J., Frank, E., Molino, P., Yosinski, J. et Liu, R. (2020). Plug and play language models : A simple approach to controlled text generation. *In International Conference on Learning Representations*, En ligne.

Delbanco, T., Walker, J., Bell, S. K., Darer, J. D., Elmore, J. G., Farag, N., Feldman, H. J., Mejilla, R., Ngo, L., Ralston, J. D., Ross, S. E., Trivedi, N., Vodicka, E. et Leveille, S. G. (2012). Inviting patients to read their doctors' notes : A quasi-experimental study and a look ahead. *Annals of Internal Medicine*, 157(7):461–470. PMID : 23027317.

Devlin, J., Chang, M.-W., Lee, K. et Toutanova, K. (2019). BERT : Pre-training of deep bidirectional transformers for language understanding. *In* Burstein, J., Doran, C. et Solorio, T., éditeurs : *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota, États-Unis. Association for Computational Linguistics.

Dratsch, T., Chen, X., Rezazade Mehrizi, M., Kloeckner, R., Mähringer-Kunz, A., Püsken, M., Baeßler, B., Sauer, S., Maintz, D. et Pinto dos Santos, D. (2023). Automation bias in mammography : the impact of artificial intelligence bi-rads suggestions on reader performance. *Radiology*, 307(4):e222176.

Ducel, F., Hiebel, N., Ferret, O., Fort, K. et Névéol, A. (2025). "Women do not have heart attacks !" Gender Biases in Automatically Generated Clinical Cases in French. *In Findings of the 2025 Annual Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics*, Albuquerque, United States.

Ducel, F., Névéol, A. et Fort, K. (2023). Bias Identification in Language Models is Biased. *In Workshop on Algorithmic Injustice 2023*, Amsterdam, Pays-Bas.

Ducel, F., Névéol, A. et Fort, K. (2024). "you'll be a nurse, my son !" automatically assessing gender biases in autoregressive language models in french and italian. *Language Resources and Evaluation*, pages 1–29.

Dwork, C., Kenthapadi, K., McSherry, F., Mironov, I. et Naor, M. (2006). Our data, ourselves : Privacy via distributed noise generation. *In* Vaudenay, S., éditeur : *Advances in Cryptology - EUROCRYPT 2006*, pages 486–503, Berlin, Heidelberg, Allemagne. Springer Berlin Heidelberg.

Fabbri, A. R., Kryściński, W., McCann, B., Xiong, C., Socher, R. et Radev, D. (2021). SummEval : Re-evaluating Summarization Evaluation. *Transactions of the Association for Computational Linguistics*, 9:391–409.

Fessler, J.-M. et Grémy, F. (2001). Opinion paper : Ethical problems in health information systems. *Methods of information in medicine*, 40(04):359–361.

Frisoni, G., Carbonaro, A., Moro, G., Zammarchi, A. et Avagnano, M. (2022). NLG-metricverse : An end-to-end library for evaluating natural language generation. *In Proceedings of the 29th International Conference on Computational Linguistics*, pages 3465–3479, Gyeongju, Corée du Sud. International Committee on Computational Linguistics.

Gatt, A. et Krahmer, E. (2018). Survey of the State of the Art in Natural Language Generation : Core tasks, applications and evaluation. *Journal of Artificial Intelligence Research*, 61:65–170.

Gehrmann, S., Clark, E. et Sellam, T. (2023). Repairing the cracked foundation : A survey of obstacles in evaluation practices for generated text. *J. Artif. Int. Res.*, 77.

Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A. et Bengio, Y. (2014). Generative adversarial nets. *In* Ghahramani, Z., Welling, M., Cortes, C., Lawrence, N. et Weinberger, K., éditeurs : *Advances in Neural Information Processing Systems*, volume 27, Montréal, Canada. Curran Associates, Inc.

Grabar, N. et Cardon, R. (2018). CLEAR – simple corpus for medical French. *In Proceedings of the 1st Workshop on Automatic Text Adaptation (ATA)*, pages 3–9, Tilbourg, Pays-Bas. Association for Computational Linguistics.

Grabar, N., Claveau, V. et Dalloux, C. (2018). CAS : French corpus with clinical cases. *In Proceedings of the Ninth International Workshop on Health Text Mining and Information Analysis*, pages 122–128, Bruxelles, Belgique. Association for Computational Linguistics.

Guerreiro, N. M., Voita, E. et Martins, A. (2023). Looking for a needle in a haystack : A comprehensive study of hallucinations in neural machine translation. *In* Vlachos, A. et Augenstein, I., éditeurs : *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 1059–1075, Dubrovnik, Croatie. Association for Computational Linguistics.

Guillaume, B., Fort, K. et Lefebvre, N. (2016). Crowdsourcing complex language resources : Playing to annotate dependency syntax. *In* Matsumoto, Y. et Prasad, R., éditeurs : *Proceedings of COLING 2016, the 26th International Conference on Computational Linguistics : Technical Papers*, pages 3041–3052, Osaka, Japon. The COLING 2016 Organizing Committee.

Harris, Z. S. (1954). Distributional structure. *WORD*, 10(2-3):146–162.

Hiebel, N., Ferret, O., Fort, K. et Névéol, A. (2023a). Can synthetic text help clinical named entity recognition ? a study of electronic health records in French. *In* Vlachos, A. et Augenstein, I., éditeurs : *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 2320–2338, Dubrovnik, Croatie. Association for Computational Linguistics.

Hiebel, N., Ferret, O., Fort, K. et Névéol, A. (2025). Clinical text generation : Are we there yet ? *Annual Review of Biomedical Data Science*.

Hiebel, N., Fort, K., Névéol, A. et Ferret, O. (2022). CLISTER : Un corpus pour la similarité sémantique textuelle dans des cas cliniques en français (CLISTER : A corpus for semantic textual similarity in French clinical narratives). *In Actes de la 29e Conférence sur le Traitement Automatique des Langues Naturelles. Volume 1 : conférence principale*, pages 287–296, Avignon, France. ATALA.

Hiebel, N., Olivier, F., Fort, K. et Névéol, A. (2023b). Les textes cliniques français générés sont-ils dangereusement similaires à leur source ? analyse par plongements de phrases. *In* Servan, C. et Vilnat, A., éditeurs : *Actes de CORIA-TALN 2023. Actes de la 30e Conférence sur le Traitement Automatique des Langues Naturelles (TALN), volume 2 : travaux de recherche originaux – articles courts*, pages 46–54, Paris, France. ATALA.

Hiebel, N., Remy, B., Guillaume, B., Ferret, O., Névéol, A. et Fort, K. (2024). Hostomytho : A GWAP for synthetic clinical texts evaluation and annotation. *In* Madge, C., Chamberlain, J., Fort, K., Kruschwitz, U. et Lukin, S., éditeurs : *Proceedings of the 10th Workshop on Games and Natural Language Processing @ LREC-COLING 2024*, pages 14–20, Turin, Italie. ELRA and ICCL.

Hochreiter, S. et Schmidhuber, J. (1997). Long short-term memory. *Neural computation*, 9:1735–80.

Holtzman, A., Buys, J., Du, L., Forbes, M. et Choi, Y. (2020). The curious case of neural text degeneration. *In International Conference on Learning Representations*, En ligne.

Hovy, D. et Prabhumoye, S. (2021). Five sources of bias in natural language processing. *Language and Linguistics Compass*, 15(8):e12432.

Howcroft, D. M., Belz, A., Clinciu, M.-A., Gkatzia, D., Hasan, S. A., Mahamood, S., Mille, S., van Miltenburg, E., Santhanam, S. et Rieser, V. (2020). Twenty years of confusion in human evaluation : NLG needs evaluation sheets and standardised definitions. *In Proceedings of the 13th International Conference on Natural Language Generation*, pages 169–182, Dublin, Irlande. Association for Computational Linguistics.

Hripcsak, G., Vawdrey, D. K., Fred, M. R. et Bostwick, S. B. (2011). Use of electronic clinical documentation : time spent and team interactions. *Journal of the American Medical Informatics Association*, 18(2):112–117.

Hu, E. J., yelong shen, Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L. et Chen, W. (2022). LoRA : Low-rank adaptation of large language models. *In International Conference on Learning Representations*, En ligne.

Huang, B. (2023). Vigogne : French instruction-following and chat models. https://github.com/bofenghuang/vigogne.

Irfan, A. A., Khatim, N. A. et Arief, M. M. (2024). Using llm for real-time transcription and summarization of doctor-patient interactions into epuskesmas in indonesia.

Ive, J., Viani, N., Kam, J., Yin, L., Verma, S., Puntis, S., Cardinal, R., Roberts, A., Stewart, R. et Velupillai, S. (2020). Generation and evaluation of artificial mental health records for natural language processing. *npj Digital Medicine*, 3.

Jeblick, K., Schachtner, B., Dexl, J., Mittermeier, A., Stüber, A. T., Topalis, J., Weber, T., Wesp, P., Sabel, B. O., Ricke, J. et Ingrisch, M. (2024). Chatgpt makes medicine easy to swallow : an exploratory case study on simplified radiology reports. *European Radiology*, 34:2817–2825.

Jiang, A. Q., Sablayrolles, A., Mensch, A., Bamford, C., Chaplot, D. S., de las Casas, D., Bressand, F., Lengyel, G., Lample, G., Saulnier, L., Lavaud, L. R., Lachaux, M.-A., Stock, P., Scao, T. L., Lavril, T., Wang, T., Lacroix, T. et Sayed, W. E. (2023). Mistral 7b.

Jiang, A. Q., Sablayrolles, A., Roux, A., Mensch, A., Savary, B., Bamford, C., Chaplot, D. S., de las Casas, D., Hanna, E. B., Bressand, F., Lengyel, G., Bour, G., Lample, G., Lavaud, L. R., Saulnier, L., Lachaux, M.-A., Stock, P., Subramanian, S., Yang, S., Antoniak, S., Scao, T. L., Gervet, T., Lavril, T., Wang, T., Lacroix, T. et Sayed, W. E. (2024). Mixtral of experts. *arXiv preprint arXiv :2401.04088*.

Johnson, A. E., Pollard, T. J., Shen, L., Lehman, L.-w. H., Feng, M., Ghassemi, M., Moody, B., Szolovits, P., Anthony Celi, L. et Mark, R. G. (2016). Mimic-iii, a freely accessible critical care database. *Scientific data*, 3(1):1–9.

Johnson, J., Douze, M. et Jégou, H. (2021). Billion-scale similarity search with gpus. *IEEE Transactions on Big Data*, 7(3):535–547.

Keselman, A., Logan, R., Smith, C. A., Leroy, G. et Zeng-Treitler, Q. (2008). Developing Informatics Tools and Strategies for Consumer-centered Health Communication. *Journal of the American Medical Informatics Association*, 15(4):473–483.

Keskar, N. S., McCann, B., Varshney, L. R., Xiong, C. et Socher, R. (2019). CTRL : A conditional transformer language model for controllable generation. *CoRR*, abs/1909.05858.

Khashabi, D., Stanovsky, G., Bragg, J., Lourie, N., Kasai, J., Choi, Y., Smith, N. A. et Weld, D. (2022). GENIE : Toward reproducible and standardized human evaluation for text generation. *In* Goldberg, Y., Kozareva, Z. et Zhang, Y., éditeurs : *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 11444–11458, Abu Dhabi, Émirats arabes unis. Association for Computational Linguistics.

Kingma, D. P. et Welling, M. (2014). Auto-Encoding Variational Bayes. *In 2nd International Conference on Learning Representations, ICLR 2014, Banff, AB, Canada, April 14-16, 2014, Conference Track Proceedings*.

Kiritchenko, S. et Mohammad, S. (2017). Best-worst scaling more reliable than rating scales : A case study on sentiment intensity annotation. *In* Barzilay, R. et Kan, M.-Y., éditeurs : *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 2 : Short Papers)*, pages 465–470, Vancouver, Canada. Association for Computational Linguistics.

Kneser, R. et Ney, H. (1995). Improved backing-off for m-gram language modeling. *In 1995 International Conference on Acoustics, Speech, and Signal Processing*, volume 1, pages 181–184 vol.1, Détroit, Michigan, États-Unis.

Knoll, T., Moramarco, F., Papadopoulos Korfiatis, A., Young, R., Ruffini, C., Perera, M., Perstl, C., Reiter, E., Belz, A. et Savkov, A. (2022). User-driven research of medical note generation software. *In* Carpuat, M., de Marneffe, M.-C. et Meza Ruiz, I. V., éditeurs : *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies*, pages 385–394, Seattle, États-Unis. Association for Computational Linguistics.

Krause, B., Gotmare, A. D., McCann, B., Keskar, N. S., Joty, S., Socher, R. et Rajani, N. F. (2021). GeDi : Generative discriminator guided sequence generation. *In Findings of the Association for Computational Linguistics : EMNLP 2021*, pages 4929–4952, Punta Cana, République dominicaine. Association for Computational Linguistics.

Kreutzer, J., Caswell, I., Wang, L., Wahab, A., van Esch, D., Ulzii-Orshikh, N., Tapo, A., Subramani, N., Sokolov, A., Sikasote, C., Setyawan, M., Sarin, S., Samb, S., Sagot, B., Rivera, C., Rios, A., Papadimitriou, I., Osei, S., Suarez, P. O., Orife, I., Ogueji, K., Rubungo, A. N., Nguyen, T. Q., Müller, M., Müller, A., Muhammad, S. H., Muhammad, N., Mnyakeni, A., Mirzakhalov, J., Matangira, T., Leong, C., Lawson, N., Kudugunta, S., Jernite, Y., Jenny, M., Firat, O., Dossou, B. F. P., Dlamini, S., de Silva, N., Çabuk Ballı, S., Biderman, S., Battisti, A., Baruwa, A., Bapna, A., Baljekar, P., Azime, I. A., Awokoya, A., Ataman, D., Ahia, O., Ahia, O., Agrawal, S. et Adeyemi, M. (2022). Quality at a glance : An audit of web-crawled multilingual datasets. *Transactions of the Association for Computational Linguistics*, 10:50–72.

Kusner, M., Sun, Y., Kolkin, N. et Weinberger, K. (2015). From word embeddings to document distances. *In* Bach, F. et Blei, D., éditeurs : *Proceedings of the 32nd International Conference on Machine Learning*, volume 37 de *Proceedings of Machine Learning Research*, pages 957–966, Lille, France. PMLR.

Kwon, W., Li, Z., Zhuang, S., Sheng, Y., Zheng, L., Yu, C. H., Gonzalez, J., Zhang, H. et Stoica, I. (2023). Efficient memory management for large language model serving with pagedattention. *In Proceedings of the 29th Symposium on Operating Systems Principles*, SOSP '23, page 611–626, New York, NY, États-Unis. Association for Computing Machinery.

Labrak, Y., Bazoge, A., El Khettari, O., Rouvier, M., Constant Dit Beaufils, P., Grabar, N., Daille, B., Quiniou, S., Morin, E., Gourraud, P.-A. et Dufour, R. (2024a). DrBenchmark : A large language understanding evaluation benchmark for French biomedical domain. *In* Calzolari, N., Kan, M.-Y., Hoste, V., Lenci, A., Sakti, S. et Xue, N., éditeurs : *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pages 5376–5390, Turin, Italie. ELRA and ICCL.

Labrak, Y., Bazoge, A., Morin, E., Gourraud, P.-A., Rouvier, M. et Dufour, R. (2024b). BioMistral : A collection of open-source pretrained large language models for medical domains. *In* Ku, L.-W., Martins, A. et Srikumar, V., éditeurs : *Findings of the Association for Computational Linguistics ACL 2024*, pages 5848–5864, Bangkok, Thaïlande et en ligne. Association for Computational Linguistics.

Lacoste, A., Luccioni, A., Schmidt, V. et Dandres, T. (2019). Quantifying the carbon emissions of machine learning. *arXiv preprint arXiv :1910.09700*.

Lee, P., Bubeck, S. et Petro, J. (2023). Benefits, limits, and risks of gpt-4 as an ai chatbot for medicine. *New England Journal of Medicine*, 388(13):1233–1239.

Lester, B., Al-Rfou, R. et Constant, N. (2021). The power of scale for parameter-efficient prompt tuning. *In Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 3045–3059, En ligne et Punta Cana, République dominicaine. Association for Computational Linguistics.

Levenshtein, V. I. (1966). Binary Codes Capable of Correcting Deletions, Insertions and Reversals. *Soviet Physics Doklady*, 10:707.

Li, X. L. et Liang, P. (2021). Prefix-tuning : Optimizing continuous prompts for generation. *In Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1 : Long Papers)*, pages 4582–4597, En ligne. Association for Computational Linguistics.

Lin, C.-Y. (2004). ROUGE : A package for automatic evaluation of summaries. *In Text Summarization Branches Out*, pages 74–81, Barcelone, Espagne. Association for Computational Linguistics.

Lindberg, D. A., Humphreys, B. L. et McCray, A. T. (1993). The Unified Medical Language System. *Methods of Information in Medecine*, 4(32):281–91.

Lison, P. et Tiedemann, J. (2016). OpenSubtitles2016 : Extracting large parallel corpora from movie and TV subtitles. *In Proceedings of the Tenth International Conference on Language Resources and Evaluation (LREC'16)*, pages 923–929, Portorož, Slovénie. European Language Resources Association (ELRA).

Liu, A., Sap, M., Lu, X., Swayamdipta, S., Bhagavatula, C., Smith, N. A. et Choi, Y. (2021). DExperts : Decoding-time controlled text generation with experts and anti-experts. *In Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and*

the 11th International Joint Conference on Natural Language Processing (Volume 1 : Long Papers), pages 6691–6706, En ligne. Association for Computational Linguistics.

Liu, X., Segonne, V., Mannion, A., Schwab, D., Goeuriot, L. et Portet, F. (2024). MedDialog-FR : A French version of the MedDialog corpus for multi-label classification and response generation related to women's intimate health. *In* Demner-Fushman, D., Ananiadou, S., Thompson, P. et Ondov, B., éditeurs : *Proceedings of the First Workshop on Patient-Oriented Language Processing (CL4Health) @ LREC-COLING 2024*, pages 173–183, Turin, Italie. ELRA and ICCL.

Lu, X., Welleck, S., West, P., Jiang, L., Kasai, J., Khashabi, D., Le Bras, R., Qin, L., Yu, Y., Zellers, R., Smith, N. A. et Choi, Y. (2022a). NeuroLogic a*esque decoding : Constrained text generation with lookahead heuristics. *In* Carpuat, M., de Marneffe, M.-C. et Meza Ruiz, I. V., éditeurs : *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies*, pages 780–799, Seattle, États-Unis. Association for Computational Linguistics.

Lu, Y., Bartolo, M., Moore, A., Riedel, S. et Stenetorp, P. (2022b). Fantastically ordered prompts and where to find them : Overcoming few-shot prompt order sensitivity. *In* Muresan, S., Nakov, P. et Villavicencio, A., éditeurs : *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1 : Long Papers)*, pages 8086–8098, Dublin, Irlande. Association for Computational Linguistics.

Luo, R., Sun, L., Xia, Y., Qin, T., Zhang, S., Poon, H. et Liu, T.-Y. (2022). BioGPT : generative pre-trained transformer for biomedical text generation and mining. *Briefings in Bioinformatics*, 23(6):bbac409.

Magnini, B., Altuna, B., Lavelli, A., Speranza, M. et Zanoli, R. (2020). The E3C Project : Collection and Annotation of a Multilingual Corpus of Clinical Cases. *In* Monti, J., dell'Orletta, F. et Tamburini, F., éditeurs : *Proceedings of the Seventh Italian Conference on Computational Linguistics, CLiC-it 2020*, volume 2769 de *CEUR Workshop Proceedings*, Bologne, Italie. CEUR-WS.org.

Marco, G., Gonzalo, J., Mateo-Girona, M. et Santos, R. D. C. (2024). Pron vs prompt : Can large language models already challenge a world-class fiction author at creative text writing ? *In* Al-Onaizan, Y., Bansal, M. et Chen, Y.-N., éditeurs : *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 19654–19670, Miami, Floride, États-Unis. Association for Computational Linguistics.

Martin, L., Muller, B., Ortiz Suárez, P. J., Dupont, Y., Romary, L., de la Clergerie, É., Seddah, D. et Sagot, B. (2020). CamemBERT : a tasty French language model. *In* Jurafsky, D., Chai, J., Schluter, N. et Tetreault, J., éditeurs : *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 7203–7219, En ligne. Association for Computational Linguistics.

McDonald, D. D. (2010). Natural Language Generation. *In* Indurkhya, N. et Damerau, F. J., éditeurs : *Handbook of Natural Language Processing*, pages 121–144. Chapman and Hall/CRC.

Melamud, O. et Shivade, C. (2019). Towards automatic generation of shareable synthetic clinical notes using neural language models. *In* Rumshisky, A., Roberts, K., Bethard, S. et Naumann, T., éditeurs : *Proceedings of the 2nd Clinical Natural Language Processing Workshop*, pages 35–45, Minneapolis, Minnesota, États-Unis. Association for Computational Linguistics.

Meoni, S., De la Clergerie, É. et Ryffel, T. (2024). Generating synthetic documents with clinical keywords : A privacy-sensitive methodology. *In* Demner-Fushman, D., Ananiadou, S., Thompson, P. et Ondov, B., éditeurs : *Proceedings of the First Workshop on Patient-Oriented Language Processing (CL4Health) @ LREC-COLING 2024*, pages 115–123, Turin, Italie. ELRA and ICCL.

Min, S., Lyu, X., Holtzman, A., Artetxe, M., Lewis, M., Hajishirzi, H. et Zettlemoyer, L. (2022). Rethinking the role of demonstrations : What makes in-context learning work ? *In* Goldberg, Y., Kozareva, Z. et Zhang, Y., éditeurs : *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 11048–11064, Abu Dhabi, Émirats arabes unis. Association for Computational Linguistics.

Moramarco, F., Papadopoulos Korfiatis, A., Perera, M., Juric, D., Flann, J., Reiter, E., Belz, A. et Savkov, A. (2022). Human evaluation and correlation with automatic metrics in consultation note generation. *In* Muresan, S., Nakov, P. et Villavicencio, A., éditeurs : *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1 : Long Papers)*, pages 5739–5754, Dublin, Irlande. Association for Computational Linguistics.

Moro, A. et Lonza, L. (2018). Electricity carbon intensity in european member states : Impacts on ghg emissions of electric vehicles. *Transportation Research Part D : Transport and Environment*, 64:5–14. The contribution of electric vehicles to environmental challenges in transport. WCTRS conference in summer.

Nasr, M., Carlini, N., Hayase, J., Jagielski, M., Cooper, A. F., Ippolito, D., Choquette-Choo, C. A., Wallace, E., Tramèr, F. et Lee, K. (2023). Scalable extraction of training data from (production) language models. *arXiv preprint arXiv :2311.17035*.

Netzel, R., Perez-Iratxeta, C., Bork, P. et Andrade, M. A. (2003). The way we write. *EMBO reports*, 4(5):446–451.

Névéol, A., Dalianis, H., Velupillai, S., Savova, G. et Zweigenbaum, P. (2018). Clinical natural language processing in languages other than english : opportunities and challenges. *Journal of Biomedical Semantics*, 9(1):12.

Novikova, J., Dušek, O., Cercas Curry, A. et Rieser, V. (2017). Why we need new evaluation metrics for NLG. *In Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pages 2241–2252, Copenhague, Danemark. Association for Computational Linguistics.

Obermeyer, Z., Powers, B., Vogeli, C. et Mullainathan, S. (2019). Dissecting racial bias in an algorithm used to manage the health of populations. *Science*, 366(6464):447–453.

Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C. L., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., Schulman, J., Hilton, J., Kelton, F., Miller, L., Simens, M., Askell, A., Welinder, P., Christiano, P., Leike, J. et Lowe, R. (2022). Training language models to follow instructions with human feedback. *In Proceedings of the 36th International Conference on Neural Information Processing Systems*, NIPS '22, Red Hook, NY, États-Unis. Curran Associates Inc.

Pagidipati, N. J. et Peterson, E. D. (2016). Acute coronary syndromes in women and men. *Nature Reviews Cardiology*, 13(8):471–480.

Papineni, K., Roukos, S., Ward, T. et Zhu, W.-J. (2002). BLEU : a method for automatic evaluation of machine translation. *In Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, pages 311–318, Philadelphie, Pennsylvanie, États-Unis. Association for Computational Linguistics.

Pelletier, R., Humphries, K. H., Shimony, A., Bacon, S. L., Lavoie, K. L., Rabi, D., Karp, I., Tsadok, M. A. et Pilote, L. (2014). Sex-related differences in access to care among patients with premature acute coronary syndrome. *CMAJ*, 186(7):497–504.

Pillutla, K., Swayamdipta, S., Zellers, R., Thickstun, J., Welleck, S., Choi, Y. et Harchaoui, Z. (2021). MAUVE : Measuring the Gap Between Neural Text and Human Text using Divergence Frontiers. *In Advances in Neural Information Processing Systems*, volume 34, pages 4816–4828, En ligne.

Popović, M. (2015). chrF : character n-gram F-score for automatic MT evaluation. *In* Bojar, O., Chatterjee, R., Federmann, C., Haddow, B., Hokamp, C., Huck, M., Logacheva, V. et Pecina, P., éditeurs : *Proceedings of the Tenth Workshop on Statistical Machine Translation*, pages 392–395, Lisbonne, Portugal. Association for Computational Linguistics.

Popović, M. (2017). chrF++ : words helping character n-grams. *In* Bojar, O., Buck, C., Chatterjee, R., Federmann, C., Graham, Y., Haddow, B., Huck, M., Yepes, A. J., Koehn, P. et Kreutzer, J., éditeurs : *Proceedings of the Second Conference on Machine Translation*, pages 612–618, Copenhague, Danemark. Association for Computational Linguistics.

Potamianos, G. et Jelinek, F. (1998). A study of n-gram and decision tree letter language modeling methods. *Speech Communication*, 24(3):171–192.

Qenam, B., Kim, T. Y., Carroll, M. J. et Hogarth, M. (2017). Text simplification using consumer health vocabulary to generate patient-centered radiology reporting : Translation and evaluation. *J Med Internet Res*, 19(12):e417.

Radford, A., Wu, J., Child, R., Luan, D., Amodei, D. et Sutskever, I. (2019). Language models are unsupervised multitask learners. Rapport technique, OpenAI.

Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., Zhou, Y., Li, W. et Liu, P. J. (2020). Exploring the limits of transfer learning with a unified text-to-text transformer. *J. Mach. Learn. Res.*, 21(1).

Ramadier, L. et Lafourcade, M. (2018). Radiological text simplification using a general knowledge base. *In* Gelbukh, A., éditeur : *Computational Linguistics and Intelligent Text Processing*, pages 617–627, Cham, Suisse. Springer International Publishing.

Reimers, N. et Gurevych, I. (2019). Sentence-BERT : Sentence embeddings using Siamese BERT-networks. *In* Inui, K., Jiang, J., Ng, V. et Wan, X., éditeurs : *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 3982–3992, Hong Kong, Chine. Association for Computational Linguistics.

Reiter, E. (2010). Natural Language Generation. *In The Handbook of Computational Linguistics and Natural Language Processing*, chapitre 20, pages 574–598. John Wiley & Sons, Ltd.

Reiter, E. (2018). A structured review of the validity of BLEU. *Computational Linguistics*, 44(3):393–401.

Reiter, E. et Dale, R. (1997). Building applied natural language generation systems. *Natural Language Engineering*, 3(1):57–87.

Reiter, E. et Dale, R. (2000). *Building Natural Language Generation Systems*. Studies in Natural Language Processing. Cambridge University Press, Cambridge.

Reiter, E., Sripada, S., Hunter, J., Yu, J. et Davy, I. (2005). Choosing words in computer-generated weather forecasts. *Artificial Intelligence*, 167(1):137–169. Connecting Language to the World.

Rosenfeld, R. (1994). *Adaptive statistical language modeling : A maximum entropy approach*. Thèse de doctorat, School of Computer Science, Carnegie Mellon University.

Ruinelli, L., Colombo, A., Rochat, M., Popeskou, S. G., Franchini, A., Mitrović, S., Lithgow, O. W., Cornelius, J. et Rinaldi, F. (2024). Experiments in automated generation of discharge summaries in Italian. *In* Demner-Fushman, D., Ananiadou, S., Thompson, P. et Ondov, B., éditeurs : *Proceedings of the First Workshop on Patient-Oriented Language Processing (CL4Health) @ LREC-COLING 2024*, pages 137–144, Turin, Italie. ELRA and ICCL.

Rumelhart, D. E., Hinton, G. E. et Williams, R. J. (1986). *Learning internal representations by error propagation*, page 318–362. MIT Press, Cambridge, Massachusetts, États-Unis.

Sahoo, P., Meharia, P., Ghosh, A., Saha, S., Jain, V. et Chadha, A. (2024). A comprehensive survey of hallucination in large language, image, video and audio foundation models. *In* Al-Onaizan, Y., Bansal, M. et Chen, Y.-N., éditeurs : *Findings of the Association for Computational Linguistics : EMNLP 2024*, pages 11709–11724, Miami, Floride, États-Unis. Association for Computational Linguistics.

Scao, T. L. *et al.* (2022). Bloom : A 176b-parameter open-access multilingual language model.

Sellam, T., Das, D. et Parikh, A. (2020). BLEURT : Learning robust metrics for text generation. *In* Jurafsky, D., Chai, J., Schluter, N. et Tetreault, J., éditeurs : *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 7881–7892, En ligne. Association for Computational Linguistics.

Shor, J., Bi, R. A., Venugopalan, S., Ibara, S., Goldenberg, R. et Rivlin, E. (2023). Clinical BERTScore : An improved measure of automatic speech recognition performance in clinical settings. *In* Naumann, T., Ben Abacha, A., Bethard, S., Roberts, K. et Rumshisky, A., éditeurs : *Proceedings of the 5th Clinical Natural Language Processing Workshop*, pages 1–7, Toronto, Canada. Association for Computational Linguistics.

Simoulin, A. et Crabbé, B. (2021). Un modèle Transformer Génératif Pré-entrainé pour le _____ français. *In* Denis, P., Grabar, N., Fraisse, A., Cardon, R., Jacquemin, B., Kergosien, E. et Balvet, A., éditeurs : *Traitement Automatique des Langues Naturelles*, pages 246–255, Lille, France. ATALA.

Stadler, T., Oprisanu, B. et Troncoso, C. (2022). Synthetic data – anonymisation groundhog day. *In 31st USENIX Security Symposium (USENIX Security 22)*, Boston, Massachusetts, États-Unis. USENIX Association.

Stenetorp, P., Pyysalo, S., Topić, G., Ohta, T., Ananiadou, S. et Tsujii, J. (2012). brat : a web-based tool for NLP-assisted text annotation. *In Proceedings of the Demonstrations at the 13th Conference of the European Chapter of the Association for Computational Linguistics*, pages 102–107, Avignon, France. Association for Computational Linguistics.

Su, K.-Y., Wu, M.-W. et Chang, J.-S. (1992). A new quantitative quality measure for machine translation systems. *In COLING 1992 Volume 2 : The 14th International Conference on Computational Linguistics*, Nantes, France.

Thomson, C. et Reiter, E. (2021). Generation challenges : Results of the accuracy evaluation shared task. *In* Belz, A., Fan, A., Reiter, E. et Sripada, Y., éditeurs : *Proceedings of the 14th International Conference on Natural Language Generation*, pages 240–248, Aberdeen, Écosse, Royaume-Uni. Association for Computational Linguistics.

Tondello, G. F., Wehbe, R. R., Diamond, L., Busch, M., Marczewski, A. et Nacke, L. E. (2016). The gamification user types hexad scale. *In Proceedings of the 2016 Annual Symposium on Computer-Human Interaction in Play*, CHI PLAY'16, pages 229–243, New York, NY, États-Unis. Association for Computing Machinery.

Torfi, A., Fox, E. A. et Reddy, C. K. (2022). Differentially private synthetic medical data generation using convolutional GANs. *Information Sciences*, 586:485–500.

Touvron, H. *et al.* (2023). Llama 2 : Open foundation and fine-tuned chat models.

van der Lee, C., Gatt, A., Miltenburg, E. et Krahmer, E. (2021). Human evaluation of automatically generated text : Current trends and best practice guidelines. *Computer Speech & Language*, 67:101151.

van der Lee, C., Gatt, A., van Miltenburg, E., Wubben, S. et Krahmer, E. (2019). Best practices for the human evaluation of automatically generated text. *In* van Deemter, K., Lin, C. et Takamura, H., éditeurs : *Proceedings of the 12th International Conference on Natural Language Generation*, pages 355–368, Tokyo, Japon. Association for Computational Linguistics.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L. et Polosukhin, I. (2017). Attention is all you need. *In Proceedings of the 31st International Conference on Neural Information Processing Systems*, NIPS'17, page 6000–6010, Red Hook, NY, États-Unis. Curran Associates Inc.

Wan, Y., Pu, G., Sun, J., Garimella, A., Chang, K.-W. et Peng, N. (2023). "kelly is a warm person, joseph is a role model" : Gender biases in LLM-generated reference letters. *In* Bouamor, H., Pino, J. et Bali, K., éditeurs : *Findings of the Association for Computational Linguistics : EMNLP 2023*, pages 3730–3748, Singapour. Association for Computational Linguistics.

Wang, C. et Sennrich, R. (2020). On exposure bias, hallucination and domain shift in neural machine translation. *In* Jurafsky, D., Chai, J., Schluter, N. et Tetreault, J., éditeurs : *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 3544–3552, En ligne. Association for Computational Linguistics.

Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E. H., Le, Q. V. et Zhou, D. (2024). Chain-of-thought prompting elicits reasoning in large language models. *In Proceedings of the 36th International Conference on Neural Information Processing Systems*, NIPS '22, Red Hook, NY, États-Unis. Curran Associates Inc.

Wei, Z., Liu, Q., Peng, B., Tou, H., Chen, T., Huang, X., Wong, K.-f. et Dai, X. (2018). Task-oriented dialogue system for automatic diagnosis. *In* Gurevych, I. et Miyao, Y., éditeurs : *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 2 : Short Papers)*, pages 201–207, Melbourne, Australie. Association for Computational Linguistics.

Weng, Y., Zhu, M., Xia, F., Li, B., He, S., Liu, S., Sun, B., Liu, K. et Zhao, J. (2023). Large language models are better reasoners with self-verification. *In* Bouamor, H., Pino, J. et Bali, K., éditeurs : *Findings of the Association for Computational Linguistics : EMNLP 2023*, pages 2550–2575, Singapour. Association for Computational Linguistics.

Wu, Y., Lei, J., Wei, W.-Q., Tang, B., Denny, J. C., Rosenbloom, S. T., Miller, R. A., Giuse, D. A., Zheng, K. et Xu, H. (2013). Analyzing differences between chinese and english clinical text : A cross-institution comparison of discharge summaries in two languages. *Studies in health technology and informatics*, 192:662–666.

Xu, J., Chen, Z., Johnston, A., Blankemeier, L., Varma, M., Hom, J., Collins, W. J., Modi, A., Lloyd, R., Hopkins, B., Langlotz, C. et Delbrouck, J.-B. (2024). Overview of the first shared task on clinical text generation : RRG24 and "discharge me!". *In* Demner-Fushman, D., Ananiadou, S., Miwa, M., Roberts, K. et Tsujii, J., éditeurs : *Proceedings of the 23rd*

Workshop on Biomedical Natural Language Processing, pages 85–98, Bangkok, Thaïlande. Association for Computational Linguistics.

Xu, L., Zhou, Q., Gong, K., Liang, X., Tang, J. et Lin, L. (2019). End-to-end knowledge-routed relational dialogue system for automatic diagnosis. *In Proceedings of the Thirty-Third AAAI Conference on Artificial Intelligence and Thirty-First Innovative Applications of Artificial Intelligence Conference and Ninth AAAI Symposium on Educational Advances in Artificial Intelligence*, AAAI'19/IAAI'19/EAAI'19, Honolulu, Hawaii, USA. AAAI Press.

Xue, L., Constant, N., Roberts, A., Kale, M., Al-Rfou, R., Siddhant, A., Barua, A. et Raffel, C. (2021). mT5 : A massively multilingual pre-trained text-to-text transformer. *In* Toutanova, K., Rumshisky, A., Zettlemoyer, L., Hakkani-Tur, D., Beltagy, I., Bethard, S., Cotterell, R., Chakraborty, T. et Zhou, Y., éditeurs : *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies*, pages 483–498, En ligne. Association for Computational Linguistics.

Yang, K. et Klein, D. (2021). FUDGE : Controlled text generation with future discriminators. *In Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics : Human Language Technologies*, pages 3511–3535, En ligne. Association for Computational Linguistics.

Yim, W.-w., Fu, Y., Ben Abacha, A., Snider, N., Lin, T. et Yetisgen, M. (2023). Aci-bench : a novel ambient clinical intelligence dataset for benchmarking automatic visit note generation. *Scientific Data*, 10(1):586.

Yu, L., Zhang, W., Wang, J. et Yu, Y. (2017). Seqgan : sequence generative adversarial nets with policy gradient. *In Proceedings of the Thirty-First AAAI Conference on Artificial Intelligence*, AAAI'17, page 2852–2858, San Francisco, Californie, États-Unis. AAAI Press.

Zack, T., Lehman, E., Suzgun, M., Rodriguez, J. A., Celi, L. A., Gichoya, J., Jurafsky, D., Szolovits, P., Bates, D. W., Abdulnour, R.-E. E. *et al.* (2024). Assessing the potential of GPT-4 to perpetuate racial and gender biases in health care : a model evaluation study. *The Lancet Digital Health*, 6(1):e12–e22.

Zeng, G., Yang, W., Ju, Z., Yang, Y., Wang, S., Zhang, R., Zhou, M., Zeng, J., Dong, X., Zhang, R., Fang, H., Zhu, P., Chen, S. et Xie, P. (2020). MedDialog : Large-scale medical dialogue datasets. *In* Webber, B., Cohn, T., He, Y. et Liu, Y., éditeurs : *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 9241–9250, En ligne. Association for Computational Linguistics.

Zhang, C., Ippolito, D., Lee, K., Jagielski, M., Tramèr, F. et Carlini, N. (2023). Counterfactual memorization in neural language models. *In Thirty-seventh Conference on Neural Information Processing Systems*, La Nouvelle-Orléans, Louisiane, États-Unis.

Zhang*, T., Kishore*, V., Wu*, F., Weinberger, K. Q. et Artzi, Y. (2020). Bertscore : Evaluating text generation with bert. *In International Conference on Learning Representations*, En ligne.

Zhang, Y., Tiňo, P., Leonardis, A. et Tang, K. (2021). A survey on neural network interpretability. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 5(5):726–742.

Zhou, C., Neubig, G., Gu, J., Diab, M., Guzmán, F., Zettlemoyer, L. et Ghazvininejad, M. (2021). Detecting hallucinated content in conditional neural sequence generation. *In* Zong, C., Xia, F., Li, W. et Navigli, R., éditeurs : *Findings of the Association for Computational Linguistics : ACL-IJCNLP 2021*, pages 1393–1404, En ligne. Association for Computational Linguistics.

Zhu, Y., Lu, S., Zheng, L., Guo, J., Zhang, W., Wang, J. et Yu, Y. (2018). Texygen : A benchmarking platform for text generation models. *In The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval*, SIGIR '18, page 1097–1100, New York, NY, États-Unis. Association for Computing Machinery.

Zock, M. et Sabah, G. (1992). La génération automatique de textes : trente ans déjà, ou presque. *Langages*, 26(106):8–35. Included in a thematic issue : La génération de textes.